

Pengantar Pemodelan Inversi Geofisika

Dr. Hendra Grandis
Institut Teknologi Bandung



Himpunan Ahli Geofisika Indonesia (HAGI)
2009

Pengantar Pemodelan Inversi Geofisika

Oleh: Dr. Hendra Grandis

Hak Cipta © 2009 pada Penulis

Hak Cipta dilindungi undang-undang. Dilarang memperbanyak atau memindahkan sebagian atau seluruh isi buku ini dalam bentuk apapun, baik secara elektronik maupun mekanis, termasuk memfoto-kopi, merekam atau dengan sistem penyimpanan lainnya, tanda seizin tertulis dari Penulis.

Penerbit:

Himpunan Ahli Geofisika Indonesia (HAGI)
Sekretariat: Graha Simatupang Tower II B lt. 9
Jl. TB. Simatupang Kav. 38
Jakarta 12540
e-mail: secretariat@hagi.or.id
<http://www.hagi.or.id>

Percetakan:

CV. Bhumi Printing
Jl. Pagarsih No. 80/90
Bandung

Kata Pengantar

Dengan mengucapkan puji syukur kehadiran Allah SWT akhirnya buku berjudul **Pengantar Pemodelan Inversi Geofisika** ini berhasil Penulis selesaikan. Buku ini merupakan revisi dan penyempurnaan dari buku yang telah diterbitkan oleh Pusat Penelitian dan Pengembangan Badan Meteorologi dan Geofisika (BMG) ISBN-978-979-1241-17-5 pada tahun 2008. Contoh-contoh aplikasi ditambahkan untuk melengkapi teori dan konsep dasar tersebut.

Materi yang disajikan dalam buku ini pada dasarnya berawal dari bahan kuliah Inversi Geofisika untuk mahasiswa Program Studi Geofisika / Teknik Geofisika ITB pada beberapa tahun terakhir. Buku ini banyak terinspirasi oleh *textbook* berjudul **Geophysical data analysis: Discrete inverse theory** oleh **W. Menke (Academic Press, 1984)**, terutama pada bagian awal. Meskipun demikian sistematika dan materi dalam buku ini telah disusun sedemikian hingga mencakup aspek-aspek yang esensial bagi penguasaan materi pemodelan inversi dalam bidang Geofisika.

Penulis menyampaikan penghargaan dan ucapan terima kasih kepada semua pihak yang telah membantu penulisan dan penerbitan buku ini. Penghargaan tinggi Penulis sampaikan khusus kepada Himpunan Ahli Geofisika Indonesia (HAGI) yang telah memfasilitasi penerbitan buku ini. Tentu saja masih banyak kekurangan yang terdapat dalam buku ini. Oleh karena itu Penulis mengharapkan masukan, koreksi dan kritik bagi penyempurnaannya di masa mendatang. Semoga buku ini bermanfaat bagi para pembaca.

Bandung, Agustus 2009

Dr. Hendra Grandis

Daftar Isi

1 Pendahuluan	1
1.1 Konsep Dasar Geofisika	1
1.2 Pemodelan Geofisika	2
Pemodelan Kedepan	3
Pemodelan Inversi	6
Ketidak-unikan Solusi Pemodelan Geofisika	7
1.3 Aspek-aspek Pemodelan	9
1.4 Aplikasi Metode Inversi	12
2 Regresi Linier dan Inversi Linier	13
2.1 Regresi Linier	13
2.2 Formulasi Inversi Linier	17
2.3 Contoh Inversi Linier	24
Regresi Garis Lurus	24
Regresi Polinom	25
Tomografi Akustik	28
Tomografi Kedokteran	29
3 Resolusi Inversi Linier	31
3.1 Konsep Jarak / Norm	31
3.2 Inversi Linier Berbobot	33
3.3 Estimasi Kesalahan Solusi Inversi Linier	36
3.4 Matriks Resolusi Data	41
3.5 Matriks Resolusi Model	43
3.6 Resolusi dan Ko-variansi Inversi Linier	44
4 Inversi Linier dengan Informasi "A Priori"	45
4.1 Eksistensi Solusi Inversi Linier	45
4.2 Inversi Linier <i>Under-Determined</i>	48
4.3 Inversi Linier <i>Mixed-Determined</i>	53
4.4 Beberapa Model "A Priori"	56
Model Referensi	56
Model <i>Flat</i> dan <i>Smooth</i>	58

Bentuk Umum Model "A Priori"	62
4.5 Informasi "A Priori" dalam Bentuk Lain	64
5 Inversi Non-Linier	69
5.1 Parameterisasi Pemodelan	69
5.2 Inversi Non-Linier dengan Pendekatan Linier	72
5.3 Metode Newton	77
5.4 Metode Gradien	81
5.5 Keterbatasan Pendekatan Linier	82
6 Inversi Non-Linier dengan Pendekatan Global	85
6.1 Pencarian Sistematis	85
6.2 Pencarian Acak	90
6.3 Metode <i>Guided Random Search</i>	93
<i>Simulated Annealing</i>	93
Algoritma Genetika	100
7 Aplikasi Inversi Linier pada Data Gravitasi	105
7.1 Model Bola Homogen	105
7.2 Pemodelan Inversi Gravitasi 2-D	110
Model 2-D	110
Inversi tanpa Kendala Tambahan	112
Inversi dengan Kendala Tambahan	113
8 Aplikasi Inversi Linier pada Data Magnetik	119
8.1 Teknik Sumber Ekuivalen 3-D	119
Pemodelan Inversi Magnetik 3-D	119
Transformasi Data Magnetik	122
8.2 Inversi Data Magnetik dengan Distribusi 3-D	128
Resolusi Vertikal Data Magnetik	128
Inversi Data Magnetik Sintetik	129
Inversi Data Magnetik Lapangan	134
9 Aplikasi Inversi Non-Linier dengan Pendekatan Linier	137
9.1 Penentuan Episenter Gempa	137
9.2 Inversi Data Geolistrik 1-D	142
9.3 Inversi Data Magnetotellurik 2-D	147

10 Aplikasi Metode <i>Simulated Annealing</i>	155
10.1 Minimum <i>Peaks Function</i>	155
10.2 Inversi Data Magnetotellurik 1-D	160
Pemodelan Kedepan MT 1-D	160
Parameterisasi Model	162
Fungsi Obyektif	164
Model dan Data Sintetik	166
Hasil dan Pembahasan	167
11 Aplikasi Algoritma Genetika	171
11.1 Maksimum <i>Peaks Function</i>	171
11.2 Inversi Data Magnetotellurik 1-D	179
Parameterisasi dan Representasi Model	179
Implementasi Algoritma Genetika	179
Hasil dan Pembahasan	181
Daftar Pustaka	185

A journey of thousand miles begins with the first step.

- Chinese proverb

1.1 Konsep Dasar Geofisika

Dalam geofisika, pengukuran data di permukaan bumi dilakukan untuk memperkirakan kondisi bawah-permukaan. Data pengamatan merupakan respons dari struktur atau formasi geologi bawah-permukaan. Respons tersebut timbul karena adanya variasi sifat fisis yang relevan (seperti rapat massa, resistivitas, sifat kemagnetan, kecepatan rambat gelombang seismik dan sebagainya) yang berasosiasi dengan struktur atau formasi geologi bawah-permukaan.

Untuk menerjemahkan data geofisika menjadi besaran yang menggambarkan distribusi sifat fisis bawah-permukaan pada awalnya dilakukan secara kualitatif dan semi-kuantitatif. Data dengan pola tertentu berasosiasi dengan benda anomali (*anomalous source*) bawah-permukaan dengan geometri tertentu. Parameter yang diperoleh dari data (amplitudo, kemiringan kurva, lebar kurva) berkaitan dengan parameter model berbentuk sederhana (posisi, kedalaman, magnitudo atau kontras sifat fisis). Untuk itu digunakan formulasi atau perhitungan sederhana, perhitungan yang sudah ditabulasikan maupun nomogram (kurva standar) yang tersedia dari literatur.

Saat ini, untuk memperoleh distribusi sifat fisis bawah-permukaan secara lebih kuantitatif umumnya dilakukan melalui pemodelan. Dalam hal ini, model adalah representasi keadaan geologi bawah-permukaan oleh benda anomali dengan besaran fisis dan geometri tertentu. Tujuan representasi menggunakan model adalah agar permasalahan dapat disederhanakan dan respons model dapat diperkirakan atau dihitung


secara teoritis dengan memanfaatkan teori-teori fisika. Secara lebih umum, model menyatakan suatu besaran atau parameter fisis yang bervariasi terhadap posisi (variasi spasial). Dengan demikian model dapat dinyatakan oleh parameter model yang terdiri dari parameter fisis dan geometri yang menggambarkan distribusi spasial parameter fisis tersebut.

Hubungan antara respons model dengan parameter model bawah-permukaan dinyatakan oleh persamaan matematis yang diturunkan dari konsep fisika yang mendasari fenomena yang ditinjau. Misalnya dalam permasalahan gravitasi, suatu distribusi rapat massa dengan geometri sederhana berupa bola homogen menyebabkan efek berupa anomali percepatan gravitasi di permukaan bumi. Anomali gravitasi tersebut dapat dihitung menggunakan persamaan matematis yang diturunkan dari Hukum Newton mengenai gravitasi. Dalam hal ini parameter model adalah rapat massa (parameter fisis), jari-jari dan kedalaman bola dari permukaan bumi (geometri), sedangkan respons model adalah percepatan gravitasi yang ditimbulkan oleh bola tersebut di permukaan bumi. Respons model dihitung pada posisi sepanjang lintasan (x) yang merupakan variabel bebas (Gambar 1.1).

Contoh lain, pada metode magnetotellurik (MT) model resistivitas bawah-permukaan di bawah suatu titik dapat dianggap sebagai model berlapis horizontal dimana resistivitas hanya bervariasi sebagai fungsi dari kedalaman (sumbu z). Respons model tersebut berupa resistivitas-semu sebagai fungsi dari periode yang dapat dihitung dengan menyelesaikan persamaan Maxwell yang berlaku pada medium 1-D.

1.2 Pemodelan Geofisika

Dalam geofisika, model dan parameter model digunakan untuk mengkarakterisasi suatu kondisi geologi bawah-permukaan. Pemodelan merupakan proses estimasi model dan parameter model berdasarkan data yang diamati di permukaan bumi. Dalam beberapa referensi istilah model tidak hanya menyatakan representasi kondisi geologi oleh besaran fisis tetapi mencakup pula hubungan matematik atau teoritik antara parameter model dengan respons model.



Gambar 1.1

Ilustrasi hubungan antara model, parameter model dan respons model dalam pemodelan anomali gravitasi.

Pemodelan ke Depan

Pemodelan ke depan (*forward modeling*) menyatakan proses perhitungan "data" yang secara teoritis akan teramati di permukaan bumi jika diketahui harga parameter model bawah-permukaan tertentu (Gambar 1.2a). Perhitungan data teoritis tersebut menggunakan persamaan matematik yang diturunkan dari konsep fisika yang mendasari fenomena yang ditinjau. Dalam pemodelan data geofisika, dicari suatu model yang menghasilkan respons yang cocok atau *fit* dengan data pengamatan atau data lapangan. Dengan demikian, model tersebut dapat dianggap mewakili kondisi bawah-permukaan di tempat pengukuran data.

Untuk memperoleh kesesuaian antara data teoritis (respons model) dengan data lapangan dapat dilakukan proses coba-coba (*trial and error*) dengan mengubah-ubah harga parameter model. Seringkali istilah


pemodelan ke depan atau *forward modeling* digunakan untuk menyatakan pemodelan data geofisika dengan cara coba-coba tersebut. Dengan kata lain, istilah pemodelan ke depan tidak hanya mencakup perhitungan respons model tetapi juga proses coba-coba secara manual untuk memperoleh model yang memberikan respons yang cocok dengan data (Gambar 1.2b).

Kecepatan dan keberhasilan teknik pemodelan ke depan dengan cara coba-coba sangat bergantung pada pengalaman subyektif seseorang yang melakukan pemodelan tersebut. Dalam hal ini harga parameter model awal dan perubahan harga parameter model tersebut perlu diperkirakan dengan baik agar diperoleh respons yang makin dekat dengan data. Semakin kompleks hubungan antara data dengan parameter model maka semakin sulit proses coba-coba tersebut. Adanya informasi tambahan dari data geologi maupun data geofisika lainnya dapat membantu penentuan model awal. Sementara itu, pengetahuan mengenai karakteristik fenomena atau mekanisme fisis yang ditinjau dapat membantu perkiraan parameter yang perlu diubah dan sejauhmana perubahan perlu dilakukan.

Secara umum metoda pemodelan ke depan membutuhkan waktu cukup lama karena sifatnya yang tidak otomatis sebagaimana pemodelan inversi (yang akan dijelaskan kemudian). Namun pada kasus-kasus tertentu metode pemodelan ke depan cukup efektif. Pada kasus dimana data mengandung *noise* yang cukup besar maka metode yang bersifat otomatis dan sangat "obyektif" seperti metode inversi akan berusaha mencari model yang responsnya *fit* data data, termasuk *noise*-nya. Hal tersebut akan menghasilkan solusi yang tidak dikehendaki atau kurang layak secara geologi. Kasus lain adalah dimana informasi geologi harus dijadikan pertimbangan utama dalam menentukan model. Pada kedua kasus tersebut model dianggap optimal jika responsnya telah cocok secara garis besar dengan pola data lapangan.

Beberapa teknik dikembangkan untuk memodifikasi model secara otomatis berdasarkan perbedaan antara data perhitungan dengan data pengamatan. Misalnya, perubahan parameter model dibuat proporsional

atau berbanding lurus dengan selisih antara data dan respons model pada titik pengamatan tertentu yang relevan. Modifikasi model dengan cara tersebut dilakukan secara iteratif hingga dicapai kesesuaian antara data dan respons model. Namun teknik-teknik tersebut tidak termasuk dalam kategori pemodelan inversi dan tidak dibahas dalam buku ini.



Gambar 1.2

- (a) Proses pemodelan ke depan (*forward modeling*) untuk menghitung respons (data teoritik atau data perhitungan) dari suatu model tertentu.
- (b) Teknik pemodelan dengan cara mencoba-coba dan memodifikasi parameter model hingga diperoleh kecocokan antara data perhitungan dan data lapangan.

Pemodelan Inversi

Pemodelan inversi (*inverse modeling*) sering dikatakan sebagai "kebalikan" dari pemodelan ke depan karena dalam pemodelan inversi parameter model diperoleh secara langsung dari data. Menke (1984) mendefinisikan teori inversi sebagai suatu kesatuan teknik atau metode matematika dan statistika untuk memperoleh informasi yang berguna mengenai suatu sistem fisika berdasarkan observasi terhadap sistem tersebut. Sistem fisika yang dimaksud adalah fenomena yang kita tinjau, hasil observasi terhadap sistem adalah data sedangkan informasi yang ingin diperoleh dari data adalah model atau parameter model.

Pemodelan inversi pada dasarnya adalah proses sebagaimana digambarkan pada Gambar 1.2b namun mekanisme modifikasi model agar diperoleh kecocokan data perhitungan dan data pengamatan yang lebih baik dilakukan secara otomatis. Pemodelan inversi sering pula disebut sebagai *data fitting* karena dalam prosesnya dicari parameter model yang menghasilkan respons yang *fit* dengan data pengamatan.

Kesesuaian antara respons model dengan data pengamatan umumnya dinyatakan oleh suatu fungsi obyektif yang harus diminimumkan. Proses pencarian minimum fungsi obyektif tersebut berasosiasi dengan proses pencarian model optimum. Dalam kalkulus jika suatu fungsi mencapai minimum maka turunannya terhadap variabel yang tidak diketahui di titik minimum tersebut berharga nol. Karakteristik minimum suatu fungsi tersebut digunakan untuk pencarian parameter model. Secara lebih umum, model dimodifikasi sedemikian hingga respons model menjadi *fit* dengan data. Dalam proses tersebut jelas bahwa pemodelan inversi hanya dapat dilakukan jika hubungan antara data dan parameter model (fungsi pemodelan ke depan) telah diketahui.

Untuk memberikan gambaran perbedaan antara pemodelan ke depan dengan pemodelan inversi maka kita tinjau suatu masalah sederhana yaitu variasi temperatur tanah terhadap kedalaman. Jika diketahui bahwa temperatur bervariasi secara linier terhadap kedalaman maka persamaan matematik yang merepresentasikan fenomena tersebut

adalah persamaan garis lurus T (temperatur) sebagai fungsi dari z (kedalaman), atau $T = a + b z$. Dalam hal ini parameter model adalah a yang menyatakan perpotongan garis terhadap ordinat (sumbu T) dan b yang menyatakan kemiringan atau gradien garis tersebut.

Pada pemodelan ke depan diasumsikan bahwa a dan b diketahui sehingga harga T (data) pada z tertentu dapat dihitung atau diprediksi (oleh karena itu respons model sering pula disebut sebagai *predicted data*). Dalam hal ini z adalah variabel bebas. Sebaliknya, dalam pemodelan inversi parameter model a dan b diperkirakan berdasarkan data T pada beberapa kedalaman yang berbeda, (T_i, z_i) ; $i = 1, 2, \dots, N$. Pada kasus ini solusi inversi (model) dapat diperoleh dengan cara yang identik dengan regresi garis lurus yang sudah sangat dikenal.

Ketidak-unikan Solusi Pemodelan Geofisika

Dalam pemodelan geofisika umumnya diasumsikan bahwa model yang menghasilkan respons yang cocok dengan data pengamatan adalah model representatif bawah-permukaan. Namun sebenarnya terdapat banyak model lain yang juga menghasilkan respons hampir sama yang dapat dianggap *fit* dengan data. Dengan demikian solusi pemodelan geofisika dalam bentuk model umumnya tidak unik (tidak tunggal). Ketidak-unikan (*non-uniqueness*) solusi pemodelan geofisika adalah akibat dari paling tidak tiga hal utama, yaitu: sifat fisika fenomena yang ditinjau, adanya kesalahan atau bising (*noise*) pada data dan kekurangan data dalam membatasi atau mendefinisikan (menjadi *constrain*) solusi.

Pada kasus pertama, secara inheren pada fenomena tertentu data atau anomali geofisika tidak dapat mendefinisikan sumber penyebabnya (benda anomali) secara unik. Hal tersebut berlaku pada fenomena medan potensial (gravitasi dan magnetik) dan ketidak-unikan solusi pada kasus ini sering disebut sebagai ambiguitas. Contoh klasik untuk kasus ini adalah pemodelan gravitasi dimana kombinasi parameter model benda anomali yang berbeda (misalnya bola homogen dengan parameter kedalaman, ukuran dan rapat massa) dapat menghasilkan anomali gravitasi yang sama (atau hampir sama) di permukaan bumi.

Contoh lain adalah pemodelan geolistrik 1-dimensi (1-D) dimana tahanan-jenis atau resistivitas hanya bervariasi sebagai fungsi dari kedalaman. Ketidak-unikan solusi tercermin dalam fenomena yang disebut ekivalensi dimana kombinasi tahanan-jenis dan ketebalan lapisan yang berbeda dapat menghasilkan data kurva sounding (resistivitas-*semu* sebagai fungsi spasi elektroda) yang sama atau hampir sama.

Pada kasus kedua, ketidak-unikan solusi pemodelan geofisika disebabkan oleh data yang tidak sempurna atau kurang akurat karena mengandung kesalahan (kesalahan pengukuran, kesalahan sistematis dan sebagainya). Kesalahan pada data dapat digeneralisasi sebagai *noise* atau bising. Hal tersebut berlaku pada semua data geofisika sehingga tidak ada contoh spesifik sebagaimana ketidak-unikan inheren seperti dibahas di atas. Secara umum dapat dikatakan bahwa terdapat banyak model yang menghasilkan respons yang masih dalam batas-batas kesalahan atau akurasi data sehingga tetap dapat dianggap *fit* dengan data tersebut.

Ketidak-unikan solusi akibat kesalahan data tercermin dalam solusi yang memiliki interval harga tertentu sebagai hasil "pemetaan" kesalahan data ke dalam kesalahan solusi. Oleh karena itu informasi yang diperoleh dari data geofisika akan lebih berguna jika tidak hanya berupa harga parameter model secara tunggal tetapi juga tingkat tingkat akurasinya.

Pada kasus ke tiga, jumlah maupun sifat data tidak cukup untuk mendefinisikan solusi. Contoh yang paling sederhana adalah regresi garis lurus dengan jumlah data hanya 1 titik. Pada kasus ini terdapat tak-hingga solusi berupa garis lurus yang melalui titik tersebut.

Cara untuk mengatasi masalah ketidak-unikan solusi (terutama yang bersifat inheren) pada pemodelan geofisika adalah dengan menyertakan informasi tambahan yang dapat memberi batasan atau kendala (*constrain*) bagi solusi atau model. Informasi tersebut dapat diperoleh dari data geologi atau data geofisika lainnya sebagaimana dilakukan untuk menentukan model awal pada metoda pemodelan ke depan. Misalnya dalam pemodelan gravitasi dapat dimasukkan informasi mengenai interval (harga minimum dan maksimum) rapat massa dan kedalaman yang dibolehkan secara geologi. Informasi tersebut sering

disebut pula sebagai informasi “a priori” karena dapat diperoleh sebelum dilakukan pemodelan.

Ketidak-unikannya solusi pemodelan geofisika juga menuntut interpreter untuk lebih berhati-hati dalam memanfaatkan dan menarik kesimpulan dari hasil pemodelan. Solusi atau model yang baik harus dapat menjelaskan data secara fisis dan layak (*feasible*) secara geologi.

1.3 Aspek-Aspek Pemodelan

Sebagaimana telah dijelaskan sebelumnya bahwa pemodelan secara umum merupakan representasi suatu fenomena atau sistem oleh suatu model melalui pendekatan fisika dan matematika dengan tujuan untuk menyederhanakan permasalahan dan memudahkan pemahaman fenomena atau sistem tersebut. Pemahaman sistem merupakan bagian penting untuk dapat melakukan prediksi “kelakuan” sistem yang melandasi bekerjanya suatu fenomena. Hal tersebut merupakan salah satu kajian dalam berbagai bidang ilmu dan rekayasa secara umum. Dalam bidang ilmu kebumihantaran sistem yang ditinjau adalah sistem atau fenomena alam.

Dalam tataran yang lebih umum pemodelan secara lebih komprehensif mencakup beberapa aspek berikut :

- **Representasi**

Dalam representasi dirumuskan hubungan antara parameter hasil observasi (*observed parameter*) atau data dari suatu sistem dengan parameter yang mengkarakterisasi sistem tersebut (*model parameter*). Hasilnya berupa formulasi matematis yang diturunkan dari teori fisika yang mendasari fenomena atau sistem tersebut. Model matematis sebagai representasi sistem memungkinkan prediksi data atau respons sistem jika parameter model diketahui. Berdasarkan pembahasan sebelumnya maka aspek representasi mencakup pemodelan ke depan atau *forward modeling*. Di samping itu, representasi dapat pula diartikan sebagai penyederhanaan kondisi bawah-permukaan yang direpresentasikan oleh model.

- **Pengukuran**

Salah satu cara untuk mengkaji apakah representasi fenomena atau sistem oleh suatu model telah sesuai dengan kenyataan yang sebenarnya maka dilakukan pengukuran data. Data merupakan respons dari fenomena atau sistem yang sebenarnya.

- **Estimasi**

Dalam aspek estimasi diperkirakan parameter model yang dapat mengkarakterisasi fenomena atau sistem yang ditinjau. Perkiraan dapat didasarkan pada informasi awal yang relevan, misalnya dari data pendukung (geologi, geofisika). Dalam aspek estimasi diperkirakan pula modifikasi parameter model untuk mencapai kesesuaian antara respons model dengan data lapangan.

- **Validasi**

Validasi dilakukan untuk menguji apakah parameter model yang dipilih dapat “menjelaskan” data hasil observasi. Apabila data hasil prediksi (berdasarkan representasi fisika dan parameter model yang diperkirakan) belum sesuai dengan data yang diukur di lapangan maka parameter model harus dimodifikasi. Proses validasi dan modifikasi parameter model dapat diulang hingga diperoleh kesesuaian antara data teoritis dengan data lapangan.

Dalam proses yang melibatkan aspek-aspek pemodelan di atas, modifikasi terutama dilakukan terhadap perkiraan awal harga parameter model dengan asumsi bahwa representasi fisika dari fenomena atau sistem telah dianggap benar. Dengan demikian ketidak-sesuaian data teoritis dengan data lapangan lebih disebabkan oleh kesalahan estimasi parameter model. Hal tersebut merupakan asumsi dasar yang menjadi landasan utama pemodelan dalam geofisika.

Meskipun demikian tidak tertutup kemungkinan adanya kesalahan dalam merumuskan representasi fisika dan matematika sehingga hubungan antara data dengan parameter model tidak relevan dengan fenomena atau sistem yang ditinjau. Pada beberapa bidang ilmu tertentu,

pemodelan lebih diartikan sebagai pencarian representasi yang optimum dari suatu sistem tertentu.

Sebagai ilustrasi kita tinjau permasalahan sederhana mengenai distribusi temperatur di dalam bumi. Diasumsikan bahwa temperatur bervariasi secara linier terhadap kedalaman dan direpresentasikan oleh persamaan $T = a + bz$ dengan a dan b adalah parameter model. Pengukuran dilakukan untuk memperoleh data berupa temperatur pada beberapa kedalaman yang dinyatakan oleh pasangan harga (T_i, z_i) $i = 1, 2, \dots, N$ dimana N adalah jumlah data. Parameter model a dan b diperkirakan misalnya berdasarkan temperatur normal di permukaan bumi dan gradien geotermal dari literatur. Kemudian dibandingkan untuk a dan b tersebut apakah temperatur hasil perhitungan sudah cukup dekat dengan hasil pengamatan ($T_i^{cal} \approx T_i^{obs}$) $i = 1, 2, \dots, N$. Jika belum sesuai maka a dan / atau b harus diubah. Ada pula kemungkinan variasi temperatur terhadap kedalaman memerlukan representasi oleh fungsi yang lebih kompleks, tidak cukup dinyatakan sebagai variasi linier.

Contoh lain adalah fenomena variasi harga anomali gravitasi di permukaan bumi sebagai respons terhadap distribusi massa bawah-permukaan. Hubungan antara data dengan parameter model bergantung model bawah-permukaan yang dipilih, namun untuk kasus bola homogen dapat direpresentasikan oleh suatu fungsi $g(x) = f(\rho, x_0, h, r, x)$ dimana parameter model adalah geometri benda (x_0, h, r) dan rapat massa (ρ). Selanjutnya proses perbandingan data teoritis dan data lapangan untuk validasi model dilakukan sebagaimana contoh di atas, yaitu dengan memodifikasi parameter model.

Dalam konteks pemodelan inversi, modifikasi model dilaksanakan secara sistematis sehingga solusi atau model diperoleh secara otomatis dari data. Dalam hal ini, modifikasi model didasarkan pada selisih antara data pengamatan dengan data teoritik untuk model tersebut sehingga modifikasi model diharapkan dapat memperkecil selisih tersebut. Terlihat bahwa pemodelan inversi dapat dilakukan jika kita dapat memprediksi data untuk suatu model tertentu (metoda pemodelan ke depan telah tersedia atau diketahui).

1.4 Aplikasi Metode Inversi

Permasalahan geofisika pada dasarnya adalah masalah inversi karena kita dituntut untuk dapat memperkirakan model atau parameter model berdasarkan hasil pengamatan data. Dengan demikian pemodelan inversi merupakan fokus kebanyakan atau hampir semua bidang geofisika. Pemodelan inversi dapat pula digunakan untuk menyelesaikan permasalahan pencarian parameter model secara lebih umum dengan catatan bahwa permasalahan tersebut dapat dimodelkan secara kuantitatif (hubungan antara parameter model dengan parameter observasi jelas).

Permasalahan inversi dapat dijumpai dalam berbagai cabang sains dan rekayasa lainnya, diantaranya adalah :

- Tomografi kedokteran
- Pengolahan citra digital
- Penentuan episenter gempa bumi
- Navigasi satelit menggunakan Global Positioning System (GPS)
- Pemetaan sumber gelombang EM angkasa luar (astronomi) menggunakan metoda interferometri
- Analisis struktur molekul menggunakan difraksi sinar - x
- Prediksi fluktuasi indeks pasar modal

Aplikasi metoda inversi pada bidang-bidang tersebut di atas memiliki karakteristik yang berbeda sesuai dengan masalah yang dihadapi. Oleh karena itu penyelesaian masalah inversi memerlukan pendekatan yang berbeda pula.

Meskipun pemodelan inversi bersifat umum, namun masalah yang dapat diselesaikan menggunakan metoda inversi adalah masalah yang dapat direpresentasikan secara kuantitatif dengan pendekatan fisika dan / atau matematika (data dan parameter model adalah besaran numerik). Di samping itu, untuk menyederhanakan masalah maka data dan parameter model yang ditinjau adalah besaran diskret atau hasil diskretisasi suatu fungsi kontinyu. Hal ini sesuai dengan representasi data atau variabel lain yang umumnya sudah merupakan besaran diskret agar dapat diproses menggunakan komputer.

*Make up your mind to be happy.
Learn to find pleasure in simple things.*

– Robert Louis Stevenson

2.1 Regresi Linier

Kita sering menghadapi masalah estimasi parameter atau variabel yang mirip dengan fenomena variasi temperatur terhadap kedalaman, sebagaimana telah disinggung secara singkat pada Bab 1. Jika temperatur bervariasi secara linier terhadap kedalaman maka persamaan matematik yang merepresentasikan fenomena tersebut adalah persamaan garis lurus T (temperatur) sebagai fungsi z (kedalaman), yaitu $T = a + b z$. Namun, permasalahan tersebut umumnya dibahas sebagai permasalahan regresi garis lurus biasa yang sering pula disebut sebagai regresi linier.

Pada bab ini kita tinjau kembali permasalahan regresi garis lurus sebagaimana umumnya kita kenal dan menggunakan fenomena variasi temperatur terhadap kedalaman sebagai contoh. Kemudian konsep tersebut digunakan untuk memformulasikan masalah inversi linier yang berlaku lebih umum.

Misalkan prediksi temperatur pada beberapa kedalaman menggunakan persamaan $T = a + b z$ disebut T_i^{cal} ; $i = 1, 2, \dots, N$. Dari hasil pengukuran di lapangan diperoleh data temperatur T_i^{obs} pada titik atau kedalaman z_i , $i = 1, 2, \dots, N$. Model $\mathbf{m} = (a, b)$ yang representatif adalah model yang menghasilkan $T_i^{cal} \approx T_i^{obs}$; untuk semua kedalaman z_i , $i = 1, 2, \dots, N$. Tanda " $\approx$ " dimaksudkan untuk menyatakan bahwa tidak semua hasil perhitungan atau prediksi temperatur cocok (*fit*) seluruhnya dengan hasil pengukuran (data) dari lapangan karena adanya kesalahan (*error*) atau bising (*noise*).

Sumber kesalahan diantaranya adalah kesalahan representasi oleh model (misalnya variasi temperatur terhadap kedalaman sebenarnya tidak linier), kesalahan alat, kesalahan pengukuran dan sebagainya. Diskusi mengenai sumber kesalahan secara lebih rinci akan dibahas kemudian. Namun demikian untuk penyederhanaan masalah semua kesalahan terakumulasi sebagai selisih antara data pengamatan dengan data perhitungan dapat dianggap sebagai *noise* atau *error* yang harus diminimumkan. Model terbaik atau model optimum diperoleh jika kesalahan tersebut minimum.

Agar model terbaik yang diperoleh berasosiasi dengan kesalahan minimum untuk semua data maka dalam menentukan atau mencari model (solusi) perhitungan kesalahan tersebut harus melibatkan semua data. Hal tersebut diperoleh dengan cara menjumlahkan semua selisih antara data perhitungan dan data pengamatan, sehingga *error function* dapat dirumuskan sebagai:

$$E = \sum_{i=1}^N (T_i^{cal} - T_i^{obs})^2 = \sum_{i=1}^N (e_i)^2 \quad (2.1)$$

dimana pengkuadratan selisih antara T_i^{cal} dan T_i^{obs} dimaksudkan untuk tidak membedakan selisih positif atau negatif ($T_i^{cal} > T_i^{obs}$ atau sebaliknya $T_i^{cal} < T_i^{obs}$). Pencarian model optimum dengan kriteria kesalahan (atau selisih) kuadrat minimum lebih dikenal sebagai metode kuadrat terkecil (*least-squares method*). Gambar 2.1 memperlihatkan ilustrasi mengenai konsep regresi linier dengan metode kuadrat terkecil.


Substitusi persamaan $T_i^{cal} = a + b z_i$ ke dalam persamaan (2.1) dan dengan menyatakan T_i^{obs} hanya sebagai T_i (mengingat hanya ada satu variabel T_i yaitu data) maka diperoleh secara lebih eksplisit kuantitas *error* yang harus diminimumkan sebagai berikut:

$$E = \sum_{i=1}^N (a + b z_i - T_i)^2 \quad (2.2)$$

dimana E merupakan fungsi dari parameter model (a, b) yang tidak diketahui atau dicari.

Fungsi E yang harus diminimumkan sering disebut sebagai *misfit function* atau fungsi obyektif. Berdasarkan prinsip kalkulus, jika suatu fungsi bernilai minimum maka turunan fungsi tersebut terhadap variabel bebas akan berharga nol (meskipun tidak setiap turunan fungsi berharga nol selalu berkaitan dengan harga minimum fungsi tersebut):

$$[f(x)]_{x=x_0} \min \longrightarrow \left[\frac{\partial f}{\partial x} \right]_{x=x_0} = 0 \quad (2.3)$$



Gambar 2.1

Konsep regresi linier untuk pasangan data (T, z) dan ilustrasi selisih antara data pengamatan antara (T_i^{obs}) dengan data perhitungan (T_i^{cal}) .

Dalam mencari parameter model (a, b) maka turunan fungsi E terhadap a dan b dibuat sama dengan nol sebagaimana persamaan (2.3). Hasilnya adalah dua persamaan berikut:

$$\begin{aligned} \frac{\partial E}{\partial a} &= \frac{\partial}{\partial a} \left(\sum_{i=1}^N (a + b z_i - T_i)^2 \right) = 2 \left(\sum_{i=1}^N (a + b z_i - T_i) \right) \\ 2 \left(N a + b \sum_{i=1}^N z_i - \sum_{i=1}^N T_i \right) &= 0 \end{aligned} \quad (2.4a)$$

$$\begin{aligned} \frac{\partial E}{\partial b} &= \frac{\partial}{\partial b} \left(\sum_{i=1}^N (a + b z_i - T_i)^2 \right) = 2 \left(\sum_{i=1}^N (a + b z_i - T_i) \right) \sum_{i=1}^N z_i \\ 2 \left(a \sum_{i=1}^N z_i + b \sum_{i=1}^N z_i^2 - \sum_{i=1}^N T_i z_i \right) &= 0 \end{aligned} \quad (2.4b)$$

Persamaan (2.4a) dan (2.4b) pada dasarnya adalah dua persamaan dengan dua variabel yang tidak diketahui, yaitu parameter model a dan b . Sistem persamaan tersebut dapat diselesaikan dengan cara substitusi atau cara lain sehingga diperoleh:

$$a = \frac{\sum_{i=1}^N z_i^2 \sum_{i=1}^N T_i - \sum_{i=1}^N z_i \sum_{i=1}^N T_i z_i}{N \sum_{i=1}^N z_i^2 - \sum_{i=1}^N z_i \sum_{i=1}^N z_i} \quad (2.5a)$$

$$b = \frac{N \sum_{i=1}^N T_i z_i - \sum_{i=1}^N T_i \sum_{i=1}^N z_i}{N \sum_{i=1}^N z_i^2 - \sum_{i=1}^N z_i \sum_{i=1}^N z_i} \quad (2.5b)$$

Persamaan (2.5) merupakan solusi regresi garis lurus klasik yang sudah sangat dikenal. Pada *programmable calculator* biasanya terdapat prosedur yang sudah diprogramkan secara *built-in* untuk menghitung solusi regresi linier. Hanya dengan memasukkan pasangan variabel bebas dan data secara berurutan, kemudian hasilnya dapat diperoleh langsung berupa harga a dan b , standar deviasi dari masing-masing estimasi a dan b , dan koefisien korelasi.

Prosedur yang sama dapat diterapkan pada sistem dengan representasi persamaan yang lebih kompleks, yaitu polinom dari variabel bebas (z) ber-orde 2, 3 dan seterusnya. Jika asumsi bahwa temperatur bervariasi secara linier terhadap kedalaman dianggap kurang memadai, maka temperatur sebagai fungsi kedalaman dapat dinyatakan oleh

persamaan $T = a + b z + c z^2$ (orde 2) atau $T = a + b z + c z^2 + d z^3$ (orde 3), demikian seterusnya. Kurva $T(z)$ tidak lagi berupa garis lurus, namun berupa parabola atau kurva yang semakin kompleks sesuai dengan orde polinom.

Pada kasus dimana polinom berorde-2 atau lebih, hubungan antara data dengan parameter model (a , b dan seterusnya) tetap bersifat linier meskipun pangkat terbesar atau orde dari z adalah 2, 3 dan seterusnya. Hal ini disebabkan operasi terhadap parameter model (a , b dan seterusnya) hanya bersifat perkalian dengan variabel bebas. Dengan kata lain operasi pemangkatan hanya dilakukan terhadap variabel bebas dan bukan pada parameter model. Oleh karena itu permasalahan tersebut sebenarnya tetap dapat disebut sebagai regresi linier.

Contoh lain dari regresi linier dengan polinom ber-orde tinggi adalah representasi anomali gravitasi regional yang dapat dinyatakan oleh polinom ber-orde n dari koordinat (x, y) . Untuk $n = 2$ misalnya anomali gravitasi regional dinyatakan oleh $g(x, y) = a + b x + c y + d x y + e x^2 + f y^2$. Demikian seterusnya untuk orde yang lebih besar. Semakin besar orde polinom maka jumlah parameter model yang dicari lebih banyak sehingga perhitungan seperti pada persamaan (2.4) dan (2.5) menjadi lebih sulit dilakukan secara analitik atau manual. Oleh karena itu diperlukan formulasi yang lebih umum sehingga penyelesaiannya dapat dilakukan secara otomatis menggunakan program komputer.

2.2 Formulasi Inversi Linier

Regresi linier pada dasarnya adalah masalah inversi. Mengingat hubungan antara data dengan parameter model adalah linier maka pemodelan inversinya disebut pula sebagai inversi linier. Untuk memformulasikan permasalahan inversi secara lebih umum maka parameter atau variabel yang terlibat dinyatakan dalam notasi vektor atau matriks yang merepresentasikan variabel dengan banyak komponen atau elemen. Vektor atau matriks dituliskan sebagai variabel dengan huruf tebal (*bold*). Jika data (**d**) dan model (**m**) masing-masing dinyatakan oleh vektor berikut:

$$\mathbf{d} = [d_1, d_2, d_3, \dots, d_N]^T \quad (2.6a)$$

$$\mathbf{m} = [m_1, m_2, m_3, \dots, m_M]^T \quad (2.6b)$$

maka secara umum hubungan antara data dan parameter model dapat dinyatakan oleh:

$$\mathbf{d} = \mathbf{g}(\mathbf{m}) \quad (2.7)$$

dimana **g** merupakan fungsi umum pemodelan kedepan (*forward modeling*) yang memetakan model menjadi besaran dalam "domain" data. Dengan kata lain, fungsi **g** memungkinkan kita memprediksi data untuk suatu model **m** tertentu.

Pada persamaan (2.7) fungsi pemodelan kedepan **g** dinyatakan dalam notasi vektor untuk mengeksplisitkan bahwa hasil pemetaan model adalah besaran dalam "domain" data yang memiliki banyak elemen sesuai dengan jumlah data N . Secara lebih eksplisit setiap komponen pada persamaan (2.7) dapat dituliskan sebagai berikut:

$$\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_N \end{bmatrix} = \begin{bmatrix} g_1(m_1, m_2, \dots, m_M) \\ g_2(m_1, m_2, \dots, m_M) \\ \vdots \\ g_N(m_1, m_2, \dots, m_M) \end{bmatrix} \quad (2.8)$$

dimana g_i menyatakan "fungsi" prediksi data elemen ke- i hasil perhitungan fungsi pemodelan kedepan **g** sebagai fungsi model **m**. Fungsi g_i pada dasarnya adalah fungsi yang sama untuk semua $i = 1, 2, \dots, N$. Perbedaannya, fungsi tersebut dihitung untuk variabel bebas tertentu sehingga berasosiasi dengan komponen data tertentu.

Komponen atau elemen data **d** dapat merepresentasikan data yang bervariasi terhadap suatu variabel bebas berupa waktu, posisi, atau variabel lain. Sebagai contoh adalah fungsi pemodelan kedepan efek gravitasi bola homogen yang merupakan fungsi dari posisi (x) pada lintasan. Demikian pula dengan model **m** yang terdiri dari M parameter model. Namun untuk regresi linier yang telah dibahas, komponen parameter model a , b dan seterusnya (untuk polinom) bukan menyatakan

variasi terhadap sesuatu yang bersifat fisis melainkan hanya sekumpulan parameter berupa koefisien polinom.

Besaran vektor dituliskan dalam notasi matriks yang berisi atau menyatakan komponen-komponennya. Notasi matriks pada persamaan (2.6) diberi tanda superskrip T untuk menyatakan operasi transpos karena besaran dengan beberapa komponen tersebut umumnya dinyatakan dalam bentuk matriks kolom. Notasi lain untuk menyatakan vektor atau matriks adalah dengan menuliskan indeks elemennya, seperti $\mathbf{d} = [d_i]$, $i = 1, 2, \dots, N$ dan $\mathbf{m} = [m_j]$, $j = 1, 2, \dots, M$.

Untuk kasus khusus dimana fungsi yang menghubungkan data dengan parameter model adalah suatu fungsi linier maka persamaan (2.7) dan (2.8) dapat dinyatakan oleh persamaan yang lebih sederhana berupa perkalian matriks:

$$\mathbf{d} = \mathbf{G} \mathbf{m} \quad (2.9a)$$

atau

$$\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_N \end{bmatrix} = \begin{bmatrix} G_{11} & G_{12} & \cdots & G_{1M} \\ G_{21} & G_{22} & \cdots & G_{2M} \\ \vdots & \vdots & & \vdots \\ G_{N1} & G_{N2} & \cdots & G_{NM} \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_M \end{bmatrix} \quad (2.9b)$$

dimana $\mathbf{G}$ adalah matriks ($N \times M$) yang sering disebut sebagai matriks kernel. Matriks tersebut pada dasarnya adalah fungsi *forward modeling* yang tidak mengandung elemen parameter model. Dalam hal ini istilah linier dimaksudkan untuk menunjukkan bahwa operasi terhadap parameter model $\mathbf{m}$ bersifat linier atau hanya merupakan perkalian $\mathbf{m}$ dengan suatu "faktor" tertentu.

Pada persamaan (2.9) parameter model $\mathbf{m}$ tidak dapat peroleh secara langsung hanya dengan melakukan inversi matriks $\mathbf{G}$ mengingat matriks kernel tersebut belum tentu berupa matriks bujur-sangkar ($N \neq M$). Operasi perkalian matriks $\mathbf{G}$ dengan vektor $\mathbf{m}$ tersebut akan menghasilkan:

$$\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_N \end{bmatrix} = \begin{bmatrix} G_{11} m_1 + G_{12} m_2 + \cdots + G_{1M} m_M \\ G_{21} m_1 + G_{22} m_2 + \cdots + G_{2M} m_M \\ \vdots \\ G_{N1} m_1 + G_{N2} m_2 + \cdots + G_{NM} m_M \end{bmatrix} \quad (2.10)$$

Selanjutnya perkalian matriks dapat pula dinyatakan dalam bentuk komponen-komponennya menggunakan notasi somasi atau penjumlahan berikut:

$$d_i = \sum_{j=1}^M G_{ij} m_j ; i = 1, 2, \dots, N \quad (2.11)$$

Persamaan (2.7) sampai (2.11) adalah persamaan yang menyatakan hubungan antara data dengan parameter model. Penyelesaian persamaan tersebut pada dasarnya adalah proses *forward modeling*. Untuk lebih memberikan gambaran nyata mengenai formulasi hubungan antara data dengan parameter model menggunakan persamaan (2.7) sampai (2.11) maka kita tinjau kembali contoh permasalahan atau fenomena variasi temperatur terhadap kedalaman. Dalam hal ini data $\mathbf{d}$ adalah temperatur dan model $\mathbf{m}$ dibentuk oleh parameter model a dan b sehingga dengan mengacu persamaan (2.9) dan (2.10) diperoleh:

$$\begin{bmatrix} T_1 \\ T_2 \\ \vdots \\ T_N \end{bmatrix} = \begin{bmatrix} 1 & z_1 \\ 1 & z_2 \\ \vdots & \vdots \\ 1 & z_N \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} \text{ atau } \begin{bmatrix} T_1 \\ T_2 \\ \vdots \\ T_N \end{bmatrix} = \begin{bmatrix} a + b z_1 \\ a + b z_2 \\ \vdots \\ a + b z_N \end{bmatrix} \quad (2.12)$$

Jumlah parameter model atau M adalah 2 sehingga matriks kernel $\mathbf{G}$ adalah matriks ($N \times 2$). Dengan menggunakan persamaan (2.12) kita dapat memperkirakan temperatur pada beberapa kedalaman misalnya pada $z_1, z_2, \dots, z_N$. Tentu saja harga tertentu untuk a dan b harus terlebih dahulu diketahui atau diasumsikan. Dengan kata lain persamaan (2.12) adalah persamaan pemodelan kedepan untuk regresi garis lurus. Bentuk persamaan yang identik dapat dituliskan untuk kasus regresi polinom.

Untuk permasalahan yang lebih umum, penyelesaian inversi adalah memperkirakan parameter $\mathbf{m}$ yang memiliki respons (data perhitungan) yang cocok dengan data lapangan. Untuk itu kriteria jumlah kuadrat kesalahan minimum (*least-square*) kembali diterapkan untuk memperoleh solusi atau model $\mathbf{m}$. Dengan menggunakan notasi d_i sebagai data hasil pengamatan dan data perhitungan dinyatakan oleh ruas kanan persamaan (2.11) maka jumlah kuadrat kesalahan adalah sebagai berikut:

$$E = \sum_{i=1}^N \left(\sum_{j=1}^M G_{ij} m_j - d_i \right)^2 \quad (2.13)$$

Persamaan (2.13) tersebut di atas pada dasarnya identik dengan persamaan (2.1) dan (2.2) yang telah dibahas untuk kasus yang sangat khusus, yaitu regresi garis lurus. Agar lebih bersifat umum dan untuk memperjelas hubungan antara notasi penjumlahan dengan notasi matriks maka persamaan (2.13) dapat dituliskan secara lebih eksplisit dalam bentuk:

$$E = \sum_{i=1}^N \left(\sum_{j=1}^M G_{ij} m_j - d_i \right) \left(\sum_{k=1}^M G_{ik} m_k - d_i \right) \quad (2.14a)$$

atau

$$E = \mathbf{e}^T \mathbf{e} = [\mathbf{d} - \mathbf{G} \mathbf{m}]^T [\mathbf{d} - \mathbf{G} \mathbf{m}] \quad (2.14b)$$

Untuk memperjelas penurunan fungsi obyektif E terhadap setiap elemen parameter model m_q maka pada persamaan (2.14a) penjumlahan 1 sampai dengan M dalam kedua tanda kurung digunakan variabel penjumlahan (*dummy variable*) yang berbeda yaitu j dan k . Perkalian kedua suku dalam tanda kurung tersebut dan penyusunan kembali urutan penjumlahan menghasilkan:

$$E = \sum_{i=1}^N d_i d_i - 2 \sum_{j=1}^M m_j \sum_{i=1}^N G_{ij} d_i + \sum_{j=1}^M \sum_{k=1}^M m_j m_k \sum_{i=1}^N G_{ij} G_{ik} \quad (2.15)$$

Suku pertama persamaan (2.15) tidak mengandung elemen parameter model m_q sehingga turunannya terhadap m_q sama dengan nol:

$$\frac{\partial}{\partial m_q} \left(\sum_{i=1}^M d_i d_i \right) = 0 \quad (2.16)$$

Turunan suku ke dua dan ke tiga persamaan (2.15) terhadap elemen parameter model m_q menghasilkan:

$$\begin{aligned} \frac{\partial}{\partial m_q} \left(-2 \sum_{j=1}^M m_j \sum_{i=1}^N G_{ij} d_i \right) &= -2 \sum_{j=1}^M \delta_{jq} \sum_{i=1}^N G_{ij} d_i \\ &= -2 \sum_{i=1}^N G_{iq} d_i \end{aligned} \quad (2.17)$$

$$\begin{aligned} \frac{\partial}{\partial m_q} \left(\sum_{j=1}^M \sum_{k=1}^M m_j m_k \sum_{i=1}^N G_{ij} G_{ik} \right) &= \\ \sum_{j=1}^M \sum_{k=1}^M (\delta_{jq} m_k + m_j \delta_{kq}) \sum_{i=1}^N G_{ij} G_{ik} &= 2 \sum_{k=1}^M m_k \sum_{i=1}^N G_{iq} G_{ik} \end{aligned} \quad (2.18)$$

dimana pada kedua persamaan tersebut di atas $\partial m_i / \partial m_j$ dinyatakan oleh delta Kronecker δ_{ij} yang hanya akan berharga sama dengan 1 jika $i = j$. Turunan E terhadap setiap elemen parameter model m_q atau $\partial E / \partial m_q = 0$ diperoleh dengan menggabungkan persamaan (2.17) dan (2.18) sehingga diperoleh:

$$\frac{\partial E}{\partial m_q} = -2 \sum_{i=1}^N G_{iq} d_i + 2 \sum_{k=1}^M m_k \sum_{i=1}^N G_{iq} G_{ik} = 0 \quad (2.19)$$

Dengan memperhatikan hubungan antara notasi matriks dengan notasi penjumlahan, selanjutnya dapat dibuktikan bahwa penulisan persamaan (2.19) menggunakan notasi matriks akan menghasilkan persamaan matriks berikut:

$$2(-\mathbf{G}^T \mathbf{d} + \mathbf{G}^T \mathbf{G} \mathbf{m}) = 0 \quad (2.20)$$

Cara lain untuk mendapatkan persamaan (2.20) adalah dengan menurunkan fungsi obyektif E terhadap parameter model $\mathbf{m}$ langsung dalam bentuk notasi matriks. Cara tersebut tidak mengikuti kaidah kalkulus yang ketat, namun dapat memberikan gambaran bagaimana solusi inversi linier diperoleh. Dalam hal ini pengoperasian perkalian pada persamaan (2.14b) menghasilkan:

$$\begin{aligned} E &= [\mathbf{d} - \mathbf{G}\mathbf{m}]^T [\mathbf{d} - \mathbf{G}\mathbf{m}] \\ &= \mathbf{d}^T \mathbf{d} - \mathbf{d}^T \mathbf{G}\mathbf{m} - [\mathbf{G}\mathbf{m}]^T \mathbf{d} + [\mathbf{G}\mathbf{m}]^T \mathbf{G}\mathbf{m} \end{aligned} \quad (2.21)$$

Berdasarkan persamaan (2.21) turunan fungsi obyektif E terhadap parameter model $\mathbf{m}$ adalah sebagai berikut:

$$\begin{aligned} \frac{\partial E}{\partial \mathbf{m}} &= -\mathbf{d}^T \mathbf{G} - \mathbf{G}^T \mathbf{d} + \mathbf{G}^T \mathbf{G}\mathbf{m} + [\mathbf{G}\mathbf{m}]^T \mathbf{G} \\ 0 &= 2(-\mathbf{G}^T \mathbf{d} + \mathbf{G}^T \mathbf{G}\mathbf{m}) \end{aligned} \quad (2.22)$$

Persamaan (2.20) atau (2.22) adalah persamaan matriks dengan vektor parameter model $\mathbf{m}$ sebagai variabel yang tidak diketahui. Penyusunan kembali persamaan tersebut untuk memperoleh estimasi model $\mathbf{m}$ sebagai solusi inversi linier menghasilkan persamaan berikut:

$$\mathbf{m} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T \mathbf{d} \quad (2.23)$$

Matriks $\mathbf{G}^T \mathbf{G}$ adalah matriks bujur-sangkar berukuran $(M \times M)$ sesuai dengan jumlah parameter model yang dicari. Jika matriks $\mathbf{G}^T \mathbf{G}$ bukan merupakan matriks singular maka invers matriks tersebut dapat dihitung menggunakan teknik inversi matriks yang umum, misalnya metode eliminasi Gauss-Jordan, dekomposisi LU dan sebagainya (Press dkk., 1987). Teknik inversi matriks yang lebih stabil untuk matriks yang mendekati singular adalah teknik dekomposisi nilai singular (*Singular Value Decomposition* atau SVD).

Persamaan (2.23) adalah solusi inversi linier untuk suatu sistem atau permasalahan dimana hubungan antara data dan parameter model (*forward modeling*) dapat dinyatakan oleh persamaan linier $\mathbf{d} = \mathbf{G}\mathbf{m}$.

Eksistensi solusi ditentukan oleh sejauhmana data dapat mendefinisikan atau mengkarakterisasi parameter model (melalui matriks kernel-nya) serta perbandingan jumlah data terhadap jumlah parameter model. Umumnya diasumsikan bahwa jumlah data selalu jauh lebih besar dari pada jumlah parameter model ($N > M$) sehingga permasalahannya bersifat *over-determined* atau *over-constrained*. Jika jumlah data lebih kecil dari pada jumlah parameter model ($N < M$) maka permasalahannya bersifat *under-determined* yang akan dibahas secara khusus kemudian.

2.3 Contoh Inversi Linier

Regresi Garis Lurus

Pada regresi garis lurus $T = a + b z$ hubungan antara data dengan parameter model dinyatakan oleh persamaan (2.12) yang bentuk umumnya adalah $\mathbf{d} = \mathbf{G}\mathbf{m}$. Bentuk umum solusi inversi linier ditanyakan oleh persamaan (2.23). Berdasarkan hal tersebut elemen-elemen dalam persamaan solusi dapat dituliskan sebagai berikut:

$$[\mathbf{G}^T \mathbf{G}] = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ z_1 & z_2 & \cdots & z_N \end{bmatrix} \begin{bmatrix} 1 & z_1 \\ 1 & z_2 \\ \vdots & \vdots \\ 1 & z_N \end{bmatrix} = \begin{bmatrix} N & \Sigma z_i \\ \Sigma z_i & \Sigma z_i^2 \end{bmatrix} \quad (2.24a)$$

$$\begin{aligned} [\mathbf{G}^T \mathbf{G}]^{-1} &= \begin{bmatrix} N & \Sigma z_i \\ \Sigma z_i & \Sigma z_i^2 \end{bmatrix}^{-1} \\ &= \frac{1}{N \Sigma z_i^2 - (\Sigma z_i)^2} \begin{bmatrix} \Sigma z_i^2 & -\Sigma z_i \\ -\Sigma z_i & N \end{bmatrix} \end{aligned} \quad (2.24b)$$

$$\mathbf{G}^T \mathbf{d} = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ z_1 & z_2 & \cdots & z_N \end{bmatrix} \begin{bmatrix} T_1 \\ T_2 \\ \vdots \\ T_N \end{bmatrix} = \begin{bmatrix} \Sigma T_i \\ \Sigma T_i z_i \end{bmatrix} \quad (2.24c)$$

Selanjutnya diperoleh persamaan yang menyatakan solusi regresi garis lurus berikut:

$$\mathbf{m} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T \mathbf{d}$$

$$= \frac{1}{N \sum z_i^2 - (\sum z_i)^2} \begin{bmatrix} \sum z_i^2 & -\sum z_i \\ -\sum z_i & N \end{bmatrix} \begin{bmatrix} \sum T_i \\ \sum T_i z_i \end{bmatrix} \quad (2.25)$$

Penulisan persamaan (2.25) secara lebih eksplisit untuk masing-masing parameter model menghasilkan solusi regresi garis lurus $\mathbf{m}=[a \ b]$ sebagaimana pada persamaan (2.4). Setelah solusi diperoleh maka parameter model tersebut dapat digunakan untuk menghitung data pada variabel bebas (z) tertentu (*forward modeling*) sehingga dihasilkan kurva regresi yang merepresentasikan variasi data terhadap kedalaman.

Regresi Polinom

Contoh yang dibahas sebelumnya dapat diperluas untuk kasus yang lebih kompleks, misalkan suatu permasalahan atau sistem tidak dapat dianggap sebagai fungsi linier melainkan fungsi kuadratik (polinom orde-2) maupun fungsi kubik (polinom orde-3) dari suatu variabel bebas tertentu. Untuk itu akan ditinjau penerapan konsep inversi linier menggunakan metode kuadrat terkecil yang telah diformulasikan untuk kasus yang lebih umum.

Jika suatu parameter observasi y merupakan fungsi polinom dalam variabel bebas x ber-orde n , maka hubungan antara data dengan parameter model dapat dinyatakan sebagai berikut:

$$y_i = a_1 x_i^0 + a_2 x_i^1 + a_3 x_i^2 + \dots + a_{n+1} x_i^n = \sum_{j=1}^M x_i^{j-1} a_j \quad (2.26)$$

dimana $i = 1, 2, \dots, N$ adalah indeks data dan jumlah parameter model yang dicari adalah $M = n + 1$. Jika persamaan (2.26) dituliskan untuk semua data maka diperoleh sistem persamaan yang dapat dinyatakan dalam bentuk matriks sebagaimana persamaan (2.9) yang pada dasarnya juga berbentuk $\mathbf{d} = \mathbf{G} \mathbf{m}$:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} x_1^0 & x_1^1 & \dots & x_1^n \\ x_2^0 & x_2^1 & \dots & x_2^n \\ \vdots & \vdots & & \vdots \\ x_N^0 & x_N^1 & \dots & x_N^n \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{bmatrix} \quad (2.27)$$


Hal yang sama dapat diterapkan pada permasalahan dengan variabel bebas lebih dari satu, misalnya fungsi permukaan atau bidang f sebagai fungsi dari koordinat (x, y) . Permasalahan tersebut dijumpai pada penentuan anomali gravitasi regional menggunakan polinom yang dikenal sebagai *surface fitting* atau *Trend Surface Analysis* (TSA). Dalam hal ini uraian $\mathbf{d} = \mathbf{G} \mathbf{m}$ menjadi:

$$\begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_N \end{bmatrix} = \begin{bmatrix} 1 & x_1^1 & x_1^2 & \dots & y_1^1 & y_1^2 & \dots & y_1^n \\ 1 & x_2^1 & x_2^2 & \dots & y_2^1 & y_2^2 & \dots & y_2^n \\ \vdots & \vdots & \vdots & \dots & \vdots & \vdots & & \vdots \\ 1 & x_N^1 & x_N^2 & \dots & y_N^1 & y_N^2 & \dots & y_N^n \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_M \end{bmatrix} \quad (2.28)$$

dimana jumlah parameter model M bergantung pada konfigurasi polinom dalam (x, y) yang digunakan dan juga orde polinom.

Gambar 2.2 memperlihatkan contoh hasil regresi polinom untuk garis $f(x)$ maupun permukaan $f(x, y)$ dengan beberapa orde (n) yang berbeda. Tampak bahwa semakin tinggi orde polinom maka kurva akan semakin mendekati data (Gambar 2.2a). Hal yang sama sebenarnya juga terjadi pada regresi permukaan.

Dari kedua contoh tersebut jelas bahwa hubungan antara data dan parameter model masih bersifat linier berapapun jumlah variabel bebas dan orde polinom. Dengan demikian penyelesaian inversi linier untuk memperoleh koefisien polinom dapat dilakukan dengan menyelesaikan persamaan dalam bentuk umum sebagaimana dinyatakan oleh persamaan (2.23). Perlu diingat bahwa pemangkatan hanya dilakukan terhadap variabel bebas, dalam hal ini x atau x dan y . Fungsi yang lebih kompleks seperti fungsi sinusoidal, logaritmik dan lain lain dapat pula diformulasikan dan diselesaikan dengan cara yang sama, selama parameter model yang dicari adalah koefisien liniernya.



Gambar 2.2

Regresi polinomial dengan satu variabel bebas $f(x)$ berupa kurva (a) dan dua variabel bebas $f(x, y)$ berupa permukaan yang digambarkan dalam bentuk kontur.

Tomografi akustik

Misalkan suatu medium terdiri dari beberapa blok segi empat dengan sifat bahan yang berbeda. Kecepatan rambat gelombang akustik dalam medium merupakan fungsi dari sifat bahan pada blok tersebut. Oleh karena itu, karakteristik bahan dapat diketahui dengan mengukur waktu tempuh gelombang akustik yang melintasi medium tersebut dengan konfigurasi sumber gelombang dan penerima dalam arah baris dan kolom seperti pada Gambar 2.3. Data dan parameter model masing-masing adalah waktu tempuh dan *slowness* atau (kecepatan)⁻¹

$$\mathbf{d} = [\Delta T_1, \Delta T_2, \dots, \Delta T_8]^T \quad (2.29a)$$

$$\mathbf{m} = [s_1, s_2, \dots, s_{16}]^T \quad (2.29b)$$


Jika h adalah lebar blok maka sistem persamaan yang berlaku adalah:

$$\begin{aligned} \text{baris 1 : } \Delta T_1 &= h s_1 + h s_2 + h s_3 + h s_4 \\ \text{baris 2 : } \Delta T_2 &= h s_5 + h s_6 + h s_7 + h s_8 \\ &\vdots \\ \text{kolom 4 : } \Delta T_8 &= h s_4 + h s_8 + h s_{12} + h s_{16} \end{aligned} \quad (2.30)$$

dimana baris dan kolom menyatakan konfigurasi pengukuran pada baris dan kolom pada medium. Dalam bentuk matriks diperoleh persamaan linier antara data dengan parameter model sebagai berikut:

$$\begin{bmatrix} \Delta T_1 \\ \Delta T_2 \\ \vdots \\ \Delta T_8 \end{bmatrix} = h \begin{bmatrix} 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} s_1 \\ s_2 \\ \vdots \\ s_{16} \end{bmatrix} \quad (2.31)$$

Tampak bahwa pada kasus sederhana ini, jumlah data lebih kecil dibandingkan dengan jumlah parameter model sehingga secara teoritis permasalahannya bersifat kurang kendala (*under-determined* atau *under-constrained*). Untuk memperoleh solusi yang lebih bermakna maka diperlukan informasi tambahan yang dapat memberikan batasan atau kendala terhadap model atau solusi, yang akan dibahas kemudian.



Gambar 2.3

Ilustrasi tomografi akustik sederhana untuk memperkirakan sifat medium berdasarkan kecepatan perambatan gelombang pada medium tersebut, **S** = sumber, **R** = penerima.

Tomografi kedokteran

Tomografi akustik didasarkan pada konsep tomografi kedokteran sehingga prinsip kedua teknik tersebut pada dasarnya sangat mirip. Dalam tomografi kedokteran sifat medium (dalam hal ini jaringan tubuh) dikarakterisasi oleh absorpsi sinar yang digunakan (biasanya sinar-x atau gelombang elektromagnetik yang lain). Perubahan intensitas sinar terhadap jarak berbanding lurus dengan intensitas sinar tersebut dan koefisien absorpsi yang bergantung pada jaringan yang dilalui sebagaimana dinyatakan oleh persamaan berikut (lihat Gambar 2.4):

$$dI/ds = -c(x, y) I \quad (2.32)$$

Jika intensitas sumber I_0 maka intensitas pada penerima ke- i adalah:

$$I_i = I_0 \exp \left(- \int_i c(x, y) ds \right) \quad (2.33)$$

Intensitas merupakan fungsi non-linier dari koefisien absorpsi $c(x, y)$ yang bervariasi secara kontinu sepanjang jarak tempuhnya. Permasalahan dapat diubah menjadi linier dengan menganggap bahwa absorpsi total cukup kecil sehingga fungsi eksponensial dapat didekati dengan 2 suku pertama ekspansi Taylor: $\exp(-x) \cong 1 - x$.


Selanjutnya diasumsikan pula bahwa variasi koefisien absorpsi kontinu dapat didekati sebagai variasi diskret pada M blok yang sebangun sehingga parameter model adalah $\mathbf{m} = [c_1, c_2, c_3, \dots, c_M]$ dan integrasi pada persamaan (2.33) dapat dituliskan sebagai penjumlahan:

$$\Delta I_i = \frac{I_0 - I_i}{I_0} = \sum_{j=1}^M \Delta s_{ij} c_j \quad (2.34)$$

dimana ΔI_i adalah perubahan intensitas relatif terhadap intensitas sumber, Δs_{ij} adalah jarak tempuh oleh sinar ke- i sepanjang blok ke- j . Persamaan matriks yang menghubungkan data dan parameter model adalah:

$$\begin{bmatrix} \Delta I_1 \\ \Delta I_2 \\ \vdots \\ \Delta I_N \end{bmatrix} = \begin{bmatrix} \Delta s_{11} & \Delta s_{12} & \cdots & \Delta s_{1M} \\ \Delta s_{21} & \Delta s_{22} & \cdots & \Delta s_{2M} \\ \vdots & \vdots & & \vdots \\ \Delta s_{N1} & \Delta s_{N2} & \cdots & \Delta s_{NM} \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_M \end{bmatrix} \quad (2.35)$$

Sebagaimana pada tomografi akustik, sinar hanya melalui sebagian kecil dari blok-blok sehingga banyak elemen matriks kernel (Δs_{ij}) pada persamaan (2.35) berharga nol. Matriks kernel tersebut bersifat "sparse" yang memerlukan penanganan tersendiri dalam perhitungan inversnya. Selain itu perlu dilakukan verifikasi atas asumsi yang telah digunakan, misalnya dalam hal pendekatan fungsi non-linier menjadi fungsi linier.



Gambar 2.4

Prinsip tomografi kedokteran untuk memperkirakan sifat medium berdasarkan absorpsi sinar yang melaluinya (jaringan tubuh manusia).

*Far better an approximate answer to the right question,
which is often vague,
than the exact answer to the wrong question,
which can always be made precise.*

– John Tukey

3.1 Konsep Jarak atau Norm

Pada dasarnya solusi inversi linier diperoleh dengan mencari minimum suatu fungsi obyektif yang menyatakan selisih kuadrat antara data pengamatan dengan data perhitungan yang berasosiasi dengan suatu model tertentu (konsep kuadrat-terkecil atau *least-squares*). Data perhitungan diperoleh melalui penyelesaian fungsi atau persamaan *forward modeling* untuk suatu model tertentu.

Jika elemen data dianggap sebagai elemen suatu vektor maka selisih kuadrat dari semua elemen vektor tersebut juga mengandung makna "jarak" sebagaimana dikenal dalam geometri *Euclide*. Dalam hal ini jarak antara data pengamatan dan data perhitungan didefinisikan dalam ruang berdimensi - N , dimana N adalah jumlah data. Konsep ruang berdimensi - N merupakan perluasan konsep ruang nyata 3-D sesuai dengan jumlah komponen vektor yang digunakan untuk mendefinisikan ruang tersebut.

Jarak atau panjang dalam geometri *Euclide* bukan merupakan satu-satunya cara untuk mengkuantifikasi ukuran atau panjang suatu vektor. Oleh karena itu digunakan istilah "norm" untuk menyatakan ukuran atau panjang suatu vektor dalam perumusan yang lebih umum. *Norm* suatu vektor $\mathbf{e}$ diberi notasi $\|\mathbf{e}\|$ dan disebut dengan *norm* L_n sesuai dengan bilangan n yang digunakan sebagai pemangkatan elemen vektor $\mathbf{e}$ sebagaimana dinyatakan oleh persamaan berikut:


$$\begin{aligned} L_1 \text{ norm : } \|\mathbf{e}\|_1 &= \left(\sum_{i=1}^N |e_i|^1 \right) \\ L_2 \text{ norm : } \|\mathbf{e}\|_2 &= \left(\sum_{i=1}^N |e_i|^2 \right)^{1/2} \\ &\vdots \\ L_n \text{ norm : } \|\mathbf{e}\|_n &= \left(\sum_{i=1}^N |e_i|^n \right)^{1/n} \end{aligned} \quad (3.1)$$

Tampak bahwa semakin besar pangkat n maka elemen terbesar dari vektor $\mathbf{e}$ akan diberi bobot yang makin besar pula. Pada kasus yang ekstrim dimana n mendekati atau menjadi tak-hingga ($n \rightarrow \infty$) maka panjang suatu vektor lebih ditentukan oleh elemen terbesarnya dan dinyatakan oleh:

$$L_\infty \text{ norm : } \|\mathbf{e}\|_\infty = \max_i |e_i| \quad (3.2)$$

Jarak dalam geometri *Euclide* berasosiasi dengan $n = 2$. Dalam hal ini metode kuadrat-terkecil menggunakan *norm* L_2 untuk menyatakan "jarak" antara data pengamatan dengan data perhitungan. Dapat dibuktikan bahwa pada metode kuadrat-terkecil, penggunaan *norm* L_2 berimplikasi pada asumsi mengenai sifat statistik atau distribusi data. Pada kasus ini data dianggap terdistribusi secara normal (*Gaussian*). Oleh karena itu jika terdapat data yang tidak mengikuti distribusi normal atau yang sering disebut sebagai *outliers* maka metode kuadrat-terkecil akan menghasilkan solusi yang kurang memadai.

Efek adanya *outliers* atau data dengan distribusi *non-Gaussian* terhadap hasil inversi linier menggunakan kriteria kesalahan minimum dengan *norm* yang berbeda diperlihatkan secara skematis pada Gambar 3.1. Tampak bahwa *norm* L_1 relatif lebih *robust* atau tidak terlalu sensitif terhadap adanya *outliers*. Pada umumnya penggunaan *norm* L_2 lebih didasarkan pada kemudahan perumusan matematis dan perhitungan solusinya (lihat buku teks standar untuk penjelasan mengenai hal ini).



Gambar 3.1

Regresi garis lurus pada pasangan data (x, y) menggunakan kriteria kesalahan minimum dengan *norm* yang berbeda.

3.2 Inversi Linier Berbobot

Dalam penyelesaian permasalahan inversi linier menggunakan persamaan (2.23) kesalahan atau ketelitian data belum diperhitungkan. Padahal kesalahan data sangat berpengaruh pada solusi yang diperoleh sebagaimana dapat dilihat pada pembahasan singkat mengenai konsep *norm* di atas. Misalnya, jika dalam satu set data terdapat satu atau beberapa data dengan tingkat kesalahan yang sangat besar atau "outliers" maka hasil inversi menggunakan metode kuadrat-terkecil adalah garis regresi L_2 yang sebenarnya bukan merupakan solusi yang diharapkan. Jika data tidak mengandung "outliers" maka hasil inversi akan mirip atau dekat dengan garis regresi L_1 (lihat Gambar 3.1).

Metode inversi yang baik hendaknya dapat memperhitungkan tingkat kesalahan data atau ketelitian data dalam proses penyelesaian inversi. Dengan demikian solusi yang diperoleh secara obyektif sesuai dengan kualitas data. Umumnya pengaruh data dengan kesalahan cukup besar (atau tingkat ketelitian rendah) harus diminimumkan agar hasil inversinya merupakan representasi data dengan tingkat ketelitian yang baik. Hal tersebut dapat dilakukan melalui pembobotan data dalam penyelesaian masalah inversi.

Pada dasarnya kita dapat memberikan bobot relatif pada data sedemikian hingga data dengan kesalahan besar tidak akan berpengaruh pada solusi inversi. Dengan kata lain, solusi inversi akan lebih ditentukan oleh data yang berkualitas baik. Faktor pembobot data ke- i atau w_i dimasukkan pada perhitungan kesalahan kuadrat sehingga diperoleh:

$$E = \sum_{i=1}^N w_i (d_i^{cal} - d_i^{obs})^2 \quad (3.3)$$

Jika data dianggap memiliki kesalahan cukup besar maka diberi bobot kecil agar kontribusi pada penjumlahan pada persamaan (3.3) tidak terlalu signifikan. Sebagai contoh pada Gambar 3.1 salah satu data dianggap memiliki kesalahan cukup besar ("outlier"). Jika informasi lain tidak tersedia maka kita dapat memberikan bobot konstan untuk semua data kecuali data yang dianggap meragukan (dalam hal ini data terakhir) sehingga $[w_i] = [\dots 1 1 1 1 0.1]$. Jika informasi mengenai tingkat ketelitian data tersedia lebih lengkap (misalnya dari statistik data) maka pembobotan dapat dilakukan dengan mengacu pada tingkat ketelitian data tersebut dan tidak bersifat subyektif dengan menggunakan harga ekstrim seperti pada contoh di atas.

Pemberian bobot secara lebih obyektif dapat dilakukan dengan menggunakan standar deviasi data sebagai bobot sehingga persamaan (3.3) menjadi:

$$E = \sum_{i=1}^N \left(\frac{d_i^{cal} - d_i^{obs}}{\sigma_i} \right)^2 \quad (3.4)$$

Dalam hal ini $w_i = \sigma_i^{-2}$ adalah kuadrat dari standar deviasi atau variansi. Data dengan ketelitian rendah memiliki standar deviasi yang besar sehingga bobotnya kecil dan sebaliknya data dengan ketelitian tinggi memiliki standar deviasi yang kecil sehingga bobotnya besar.

Penggunaan standar deviasi sebagai bobot juga dapat diartikan bahwa data yang tidak terlalu akurat (dengan standar deviasi cukup besar) akan memberikan toleransi yang juga cukup besar pada data prediksi (d_{cal}) untuk dianggap cocok dengan data hasil pengamatan. Demikian

pula sebaliknya, perbedaan kecil antara data perhitungan dengan data pengamatan yang cukup teliti (dengan standar deviasi kecil) akan memberikan kontribusi cukup besar pada perhitungan kesalahan kuadratik total yang harus diminimumkan pada persamaan (3.4). Oleh karena itu harus dicari model yang responsnya sangat dekat dengan data yang cukup teliti tersebut agar menghasilkan kesalahan total minimum.

Secara lebih umum pembobotan data dapat dinyatakan dalam bentuk matriks sehingga persamaan (3.3) atau (3.4) dalam notasi matriks dapat dituliskan sebagai berikut:

$$E = \mathbf{e}^T \mathbf{W}_e \mathbf{e} = [\mathbf{d} - \mathbf{G} \mathbf{m}]^T \mathbf{W}_e [\mathbf{d} - \mathbf{G} \mathbf{m}] \quad (3.5)$$

Pada kasus pembobotan subyektif sebagaimana dicontohkan di atas atau pembobotan menggunakan standar deviasi data maka matriks $\mathbf{W}_e$ adalah matriks diagonal dengan elemen diagonal berisi $[w_i] = [\sigma_i^{-2}]$ sehingga secara lengkap matriks $\mathbf{W}_e$ adalah:

$$\mathbf{W}_e = \begin{bmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & w_N \end{bmatrix} = \begin{bmatrix} \sigma_1^{-2} & 0 & \cdots & 0 \\ 0 & \sigma_2^{-2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_N^{-2} \end{bmatrix} \quad (3.6)$$

Untuk kasus yang lebih umum maka $\mathbf{W}_e$ bukan berbentuk matriks diagonal, namun $\mathbf{W}_e = \mathbf{C}_d^{-1}$ dimana matriks $\mathbf{C}_d$ disebut sebagai matriks ko-variansi (*covariance*) dengan elemen-elemen sebagai berikut:

$$c_{ij} = r_{ij} \sigma_i \sigma_j \quad (3.7)$$

Ko-variansi c_{ij} adalah fungsi dari variansi masing-masing data dan koefisien korelasi $-1 \leq r_{ij} \leq 1$ yang menyatakan keterkaitan antara satu data dengan lainnya. Jika $i = j$ maka elemen diagonal matriks $\mathbf{C}_d$ adalah variansi data ke- i atau $c_{ii} = \sigma_i^2$.

Solusi permasalahan inversi linier dengan pembobotan data dapat diperoleh dengan cara yang sama seperti pada penurunan persamaan (2.23) dan dapat dibuktikan bahwa hasilnya adalah sebagai berikut:

$$\mathbf{m} = [\mathbf{G}^T \mathbf{W}_e \mathbf{G}]^{-1} \mathbf{G}^T \mathbf{W}_e \mathbf{d} \quad (3.8)$$

Pada umumnya untuk menyederhanakan masalah maka data dianggap tidak terkorelasi satu dengan yang lainnya atau independen sehingga matriks pembobot $\mathbf{W}_e$ adalah matriks diagonal dengan elemen diagonal adalah variansi data. Inversi linier dengan pembobotan data sangat umum digunakan untuk memperoleh solusi yang optimal. Metode inversi linier berbobot sering disebut sebagai *weighted linear inversion*.

3.3 Estimasi Kesalahan Solusi Inversi Linier

Melalui pembobotan data maka pengaruh kesalahan data pada model atau hasil inversi telah diperhitungkan dan tercermin pada persamaan (3.8). Secara statistik kesalahan suatu variabel (*input*) akan berpropagasi atau "terpetakan" pada kesalahan variabel lain (*output*) yang merupakan fungsi dari variabel *input* tersebut. Pada penyelesaian masalah inversi linier, kesalahan data akan "terpetakan" menjadi kesalahan parameter model.

Dari persamaan (2.23) dan (3.8) tampak bahwa estimasi parameter model atau solusi inversi merupakan fungsi linier dari data. Secara umum untuk kasus inversi linier yang paling sederhana model sebagai fungsi atau kombinasi linier dari data tersebut dinyatakan oleh $\mathbf{m} = \mathbf{A} \mathbf{d}$ dimana $\mathbf{A} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T$. Berdasarkan prinsip propagasi kesalahan (*error propagation*) variansi parameter model ke- j dinyatakan oleh:

$$\Delta m_j^2 = \sum_{k=1}^N \left(\frac{\partial m_j}{\partial d_k} \Delta d_k \right)^2 = \sum_{k=1}^N A_{jk}^2 \Delta d_k^2 \quad (3.9)$$

dimana Δd_k^2 adalah variansi data ke- k dengan $j = 1, 2, \dots, M$ dan $k = 1, 2, \dots, N$. Jelas bahwa A_{jk} adalah komponen matriks $\mathbf{A} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T$.

Untuk kasus yang lebih umum jika kesalahan data dinyatakan oleh matriks ko-variansi data $\mathbf{C}_d$ maka berdasarkan persamaan (3.9) dapat dibuktikan bahwa matriks ko-variansi model adalah:

$$\mathbf{C}_m = \mathbf{A} \mathbf{C}_d \mathbf{A}^T \quad (3.10)$$

Pada dasarnya matriks ko-variansi model $\underline{C}_m$ dapat dihitung dengan relatif mudah menggunakan persamaan (3.10). Matriks ko-variansi model tersebut menyatakan ketidak-pastian atau kesalahan estimasi parameter model yang merupakan hasil "pemetaan" atau propagasi kesalahan data. Untuk memberikan ilustrasi mengenai sifat-sifat matriks $\underline{C}_m$ dan hubungannya dengan parameter lain terutama distribusi dan kesalahan data, maka selanjutnya ditinjau suatu kasus yang sangat khusus. Jika data tidak saling berkorelasi dan memiliki standar deviasi yang sama atau seragam, yaitu σ_d maka $\underline{C}_d = \sigma_d^2 \underline{I}$ dan substitusinya ke persamaan (3.10) menghasilkan:


$$\begin{aligned}\underline{C}_m &= \left[\left[\underline{G}^T \underline{G} \right]^{-1} \underline{G}^T \right] \sigma_d^2 \underline{I} \left[\left[\underline{G}^T \underline{G} \right]^{-1} \underline{G}^T \right]^T \\ &= \sigma_d^2 \left[\underline{G}^T \underline{G} \right]^{-1}\end{aligned}\quad (3.11)$$

Jika fungsi *misfit* $E(\mathbf{m})$ bervariasi secara tajam di sekitar nilai minimumnya yaitu pada $\mathbf{m} = \mathbf{m}^{\text{est}}$ maka model akan terdefinisi dengan baik atau memiliki variansi ($\Delta \mathbf{m}$) cukup kecil. Sebaliknya, jika fungsi *misfit* tersebut bervariasi secara landai di sekitar nilai minimumnya, maka model akan memiliki variansi yang relatif besar (untuk variasi kesalahan ΔE yang sama). Hal tersebut secara grafis diperlihatkan pada Gambar 3.2.

Variasi atau kecendrungan fungsi *misfit* $E(\mathbf{m})$ di sekitar nilai minimumnya dapat dikuantifikasi sebagai kecekungan atau *curvature*. Kecekungan fungsi $E(\mathbf{m})$ ditentukan oleh turunan ke-dua fungsi E terhadap $\mathbf{m}$. Selanjutnya hubungan antara turunan ke-dua dari fungsi $E(\mathbf{m})$ dengan parameter yang menyatakan kesalahan (ko-variansi) model akan diperlihatkan secara matematis. Dengan melakukan ekspansi Taylor fungsi $E(\mathbf{m})$ di sekitar nilai minimum $\mathbf{m} = \mathbf{m}^{\text{est}}$ sampai orde ke-dua diperoleh hubungan sebagai berikut:

$$\begin{aligned}\Delta E &= E(\mathbf{m}) - E(\mathbf{m}^{\text{est}}) \\ &= [\mathbf{m} - \mathbf{m}^{\text{est}}]^T \left[\frac{1}{2} \frac{\partial^2 E}{\partial \mathbf{m}^2} \right]_{\mathbf{m}=\mathbf{m}^{\text{est}}} [\mathbf{m} - \mathbf{m}^{\text{est}}]\end{aligned}\quad (3.12)$$

Persamaan (3.12) menunjukkan secara matematis hal-hal yang telah dibahas secara deskriptif dan ilustratif di atas. Fungsi $E(\mathbf{m})$ dengan daerah minimum yang tajam memiliki kecekungan (turunan ke-dua E terhadap $\mathbf{m}$) yang besar dan berkorelasi dengan $\Delta \mathbf{m} = \mathbf{m}^{\text{est}} - \mathbf{m}$ yang kecil. Sebaliknya, untuk ΔE yang sama maka fungsi $E(\mathbf{m})$ dengan daerah minimum yang landai akan memiliki kecekungan yang kecil dan berkorelasi dengan $\Delta \mathbf{m} = \mathbf{m}^{\text{est}} - \mathbf{m}$ yang besar.



Gambar 3.2

Ilustrasi grafis pengaruh kecekungan atau *curvature* fungsi $E(\mathbf{m})$ terhadap kesalahan estimasi parameter model $\Delta \mathbf{m}$.

Turunan ke-dua fungsi *misfit* E terhadap parameter model $\mathbf{m}$ dapat dihitung dari persamaan (2.21) atau (2.22) dan hasilnya adalah:

$$\left[\frac{1}{2} \frac{\partial^2 E}{\partial \mathbf{m}^2} \right]_{\mathbf{m}=\mathbf{m}^{\text{est}}} = \underline{G}^T \underline{G} \quad (3.13)$$

Dengan demikian persamaan (3.11) menjadi:

$$\underline{C}_m = \sigma_d^2 \left[\underline{G}^T \underline{G} \right]^{-1} = \sigma_d^2 \left[\frac{1}{2} \frac{\partial^2 E}{\partial \mathbf{m}^2} \right]_{\mathbf{m}=\mathbf{m}^{\text{est}}}^{-1} \quad (3.14)$$

Persamaan (3.14) menunjukkan hubungan antara kecekungan fungsi $E(\mathbf{m})$ di sekitar nilai minimumnya dengan ko-variansi model, terutama untuk kasus khusus yang ditinjau, yaitu data independen dengan variansi konstan.

Jika data terdistribusi normal dengan standar deviasi seragam σ_d maka kesalahan prediksi data E merupakan variabel acak (*random*) dengan distribusi χ^2 (*chi-squared*) yang memiliki $(N-M)$ derajat kebebasan. Besaran tersebut memiliki harga rata-rata $\bar{E} = (N-M) \sigma_d^2$ dan variansi $\sigma_E^2 = 2(N-M) \sigma_d^4$ (penjelasan mengenai distribusi χ^2 dapat dilihat pada buku statistika standar). Standar deviasi dari harga E dapat digunakan untuk menyatakan variansi data dan substitusinya pada persamaan (3.14) menghasilkan:

$$\begin{aligned} \underline{C}_m &= \sigma_d^2 [\underline{G}^T \underline{G}]^{-1} \\ &= \frac{\sigma_E}{[2(N-M)]^{1/2}} \left[\frac{1}{2} \frac{\partial^2 E}{\partial \mathbf{m}^2} \right]_{\mathbf{m}=\mathbf{m}^{\text{est}}}^{-1} \end{aligned} \quad (3.15)$$

Persamaan (3.15) menunjukkan bahwa matriks ko-variansi model ditentukan oleh variansi data dikalikan dengan suatu ukuran bagaimana kesalahan data "dipetakan" menjadi kesalahan parameter model. Selain itu, matriks ko-variansi model juga dapat dinyatakan sebagai perkalian antara standar deviasi kesalahan prediksi data E dengan kecekungan fungsi $E(\mathbf{m})$ pada nilai minimumnya.

Pada kasus standar deviasi data yang seragam, untuk satu satuan variansi data maka dapat ditunjukkan bahwa matriks satuan ko-variansi model adalah:

$$\underline{C}_m^u = [\underline{G}^T \underline{G}]^{-1} \quad (3.16)$$

Meskipun data saling berkorelasi sehingga bentuk matriks ko-variansi data lebih kompleks, matriks ko-variansi data tetap dapat dinormalisasi sehingga diperoleh matriks satuan ko-variansi data $\underline{C}_d^u$ yang berhubungan dengan matriks satuan ko-variansi model melalui persamaan yang identik dengan persamaan (3.11) berikut:

$$\begin{aligned} \underline{C}_m^u &= [\underline{G}^T \underline{G}]^{-1} \underline{G}^T \underline{C}_d^u [\underline{G}^T \underline{G}]^{-1} \underline{G}^T \\ &= \underline{G}^{-g} \underline{C}_d^u \underline{G}^{-gT} \end{aligned} \quad (3.17)$$

$\underline{G}^{-g}$ adalah matriks yang disebut sebagai *generalized inverse matrix*.


Berdasarkan persamaan (3.16) dan (3.17) jelas bahwa "pemetaan" kesalahan data menjadi kesalahan model hanya dikontrol oleh hubungan antara data dengan parameter model yang dinyatakan oleh matriks kernel. Dengan demikian, "pemetaan" tersebut tidak bergantung pada besaran numerik (harga) data maupun variansi data. Hal ini berlaku pada kasus data tidak saling berkorelasi dan standar deviasi yang seragam maupun pada kasus yang lebih umum.

Fakta bahwa matriks satuan ko-variansi model hanya merupakan fungsi dari matriks kernel dapat digunakan untuk melakukan analisis sebelum pengambilan data dan pemodelan berlangsung (*experimental design*). Sebagai contoh, matriks satuan ko-variansi model pada regresi garis lurus dengan parameter model $\mathbf{m} = [a \ b]$ adalah:

$$\underline{C}_m^u = \frac{1}{N \sum z_i^2 - (\sum z_i)^2} \begin{bmatrix} \sum z_i^2 & -\sum z_i \\ -\sum z_i & N \end{bmatrix} \quad (3.18)$$

Jelas bahwa matriks ko-variansi model berbanding lurus dengan determinan matriks $[\underline{G}^T \underline{G}]$. Pada kasus dimana titik-titik data terkonsentrasi dengan nilai z yang berdekatan maka harga denominator dari determinan menjadi kecil dan variansi parameter model menjadi besar. Sebaliknya, jika titik-titik data tersebar dengan nilai z yang berjauhan maka harga denominator menjadi besar dan variansi parameter model menjadi kecil. Hal tersebut diilustrasikan pada Gambar 3.3.

Pada contoh tersebut di atas, tingkat kesalahan data yang sama dapat menghasilkan tingkat kesalahan model yang berbeda bergantung pada geometri atau distribusi data yang tercermin pada matriks kernel. Informasi semacam ini dapat digunakan untuk mendisain eksperimen atau pengukuran sehingga diperoleh data yang menghasilkan parameter model dengan tingkat kesalahan yang kecil.



Gambar 3.3

Regresi garis lurus dari satu set data dengan tingkat kesalahan sama. Distribusi data pada sumbu- z yang berbeda menghasilkan tingkat kesalahan model yang berbeda.

3.4 Matriks Resolusi Data

Solusi permasalahan inversi linier $\mathbf{d} = \mathbf{G}\mathbf{m}$ sebagaimana telah dibahas secara umum dapat dinyatakan dalam bentuk $\mathbf{m} = \mathbf{A}\mathbf{d}$ dimana $\mathbf{A} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T$ adalah matriks yang bukan merupakan fungsi dari data $\mathbf{d}$. Hal tersebut menunjukkan bahwa estimasi parameter model dikontrol oleh matriks $\mathbf{A}$ yang beroperasi pada data $\mathbf{d}$. Dengan demikian matriks $\mathbf{A}$ sangat penting, selain vektor model $\mathbf{m}$ sebagai solusi inversi. Dengan mempelajari karakteristik matriks $\mathbf{A}$ diharapkan kita dapat memperoleh informasi mengenai sifat atau karakteristik permasalahan inversi dan solusinya.

Matriks $\mathbf{A}$ sering disebut sebagai *generalized inverse matrix* dan diberi simbol $\mathbf{G}^{-g}$ karena dapat meng-"inversi" persamaan linier $\mathbf{d} = \mathbf{G}\mathbf{m}$. Bentuk sebenarnya dari matriks $\mathbf{G}^{-g}$ bergantung pada permasalahan yang ditinjau. Pada kasus yang sejauh ini telah dibahas bentuk matriks tersebut adalah $\mathbf{G}^{-g} = [\mathbf{G}^T \mathbf{G}]^{-1} \mathbf{G}^T$. Matriks *generalized inverse* tidak sama dengan invers matriks biasa karena $\mathbf{G}^{-g}$ bukan matriks bujur-sangkar dan perkalian $\mathbf{G}^{-g} \mathbf{G}$ tidak selalu menghasilkan matriks identitas atau matriks satuan.

Operasi matriks *generalized inverse* pada data pengamatan menghasilkan estimasi parameter model yang merupakan solusi inversi linier, atau $\mathbf{m}^{\text{est}} = \mathbf{G}^{-g} \mathbf{d}$. Selanjutnya dapat diperkirakan sejauhmana model yang dihasilkan dapat menghasilkan respons model yang cocok dengan data. Dengan melakukan substitusi estimasi parameter model tersebut ke persamaan $\mathbf{d} = \mathbf{G}\mathbf{m}$ sehingga menghasilkan data prediksi $\mathbf{d}^{\text{pre}}$ maka diperoleh persamaan

$$\begin{aligned} \mathbf{d}^{\text{pre}} &= \mathbf{G} \mathbf{m}^{\text{est}} \\ &= \mathbf{G} [\mathbf{G}^{-g} \mathbf{d}] = [\mathbf{G} \mathbf{G}^{-g}] \mathbf{d} = \mathbf{N} \mathbf{d} \end{aligned} \quad (3.19)$$

$\mathbf{N}$ adalah matriks ($N \times N$) yang disebut sebagai matriks resolusi data (*data resolution matrix*), dimana N adalah jumlah data. Matriks tersebut menyatakan sejauhmana data prediksi cocok dengan data pengamatan.

Pada dasarnya data $\mathbf{d}$ pada persamaan (3.19) adalah data pengamatan atau $\mathbf{d}^{\text{obs}}$. Data prediksi merupakan kombinasi linier dari data observasi dengan koefisien yang dinyatakan oleh elemen-elemen baris dari matriks $\mathbf{N}$ sesuai persamaan berikut:

$$d_i^{\text{pre}} = \sum_{j=1}^N N_{ij} d_j^{\text{obs}} = \dots + N_{i-1} d_{i-1}^{\text{obs}} + N_{ii} d_i^{\text{obs}} + N_{i+1} d_{i+1}^{\text{obs}} + \dots \quad (3.20)$$

Jika elemen vektor data $\mathbf{d}$ berurutan secara natural (misalnya sesuai dengan urutan besarnya variabel bebas z pada kasus $T = a + bz$) maka interpretasi matriks resolusi data menjadi sederhana, yaitu:

- Jika $\mathbf{N} = \mathbf{I}$ (matriks identitas) maka $\mathbf{d}^{\text{pre}} = \mathbf{d}^{\text{obs}}$ dan kesalahan prediksi sama dengan nol atau resolusi sempurna.
- Jika $\mathbf{N} \neq \mathbf{I}$ namun elemen-elemen terbesar terkonsentrasi atau mendominasi di sekitar diagonal maka diperoleh resolusi yang baik.
- Jika $\mathbf{N} \neq \mathbf{I}$ dan harga-harga suatu baris dari matriks $\mathbf{N}$ hampir merata maka diperoleh resolusi yang buruk.

Elemen diagonal dari matriks $\mathbf{N}$ sering disebut sebagai *data importance* yang menyatakan "kesetaraan" antara data prediksi dan data observasi.

Sebagaimana halnya matriks ko-variansi model yang hanya bergantung pada matriks kernel, matriks resolusi data $\underline{\mathbf{N}}$ juga hanya merupakan fungsi dari matriks kernel $\underline{\mathbf{G}}$ yang mengandung informasi mengenai geometri data. Dengan demikian matriks resolusi data dapat digunakan untuk mendesain eksperimen sebelum melakukan pengukuran data yang sebenarnya.

3.5 Matriks Resolusi Model

Matriks resolusi data menggambarkan sejauhmana data dapat diprediksi secara independen dari data pengamatan. Hal yang sama dapat dilakukan dengan parameter model. Misalnya kita anggap terdapat suatu model sesungguhnya $\mathbf{m}^{\text{true}}$, yang pada kasus sebenarnya tidak kita ketahui. Sejauhmana kita dapat meresolusi model tersebut?

Model $\mathbf{m}^{\text{true}}$ berasosiasi dengan data pengamatan sesuai dengan persamaan linier $\mathbf{d} = \underline{\mathbf{G}} \mathbf{m}^{\text{true}}$. Substitusi hubungan linier tersebut ke dalam persamaan $\mathbf{m}^{\text{est}} = \underline{\mathbf{G}}^{-g} \mathbf{d}$ menghasilkan:

$$\begin{aligned} \mathbf{m}^{\text{est}} &= \underline{\mathbf{G}}^{-g} \mathbf{d} \\ &= \underline{\mathbf{G}}^{-g} [\underline{\mathbf{G}} \mathbf{m}^{\text{true}}] = [\underline{\mathbf{G}}^{-g} \underline{\mathbf{G}}] \mathbf{m}^{\text{true}} = \underline{\mathbf{R}} \mathbf{m}^{\text{true}} \end{aligned} \quad (3.21)$$

$\underline{\mathbf{R}}$ adalah matriks ($M \times M$) yang disebut sebagai matriks resolusi model (*model resolution matrix*), dimana M adalah jumlah parameter model. Jika $\underline{\mathbf{R}} = \underline{\mathbf{I}}$ dimana $\underline{\mathbf{I}}$ adalah matriks identitas atau matriks satuan, maka setiap elemen parameter model terdefinisi secara unik dan sesuai dengan model yang sebenarnya.

Jika matriks resolusi model bukan matriks identitas maka estimasi parameter model merupakan rata-rata berbobot dari parameter model yang sebenarnya. Analog dengan persamaan (3.20) maka diperoleh:

$$\begin{aligned} m_i^{\text{pre}} &= \sum_{j=1}^N R_{ij} m_j^{\text{true}} \\ &= \dots + R_{i,i-1} m_{i-1}^{\text{true}} + R_{ii} m_i^{\text{true}} + R_{i,i+1} m_{i+1}^{\text{true}} + \dots \end{aligned} \quad (3.22)$$

Model terresolusi dengan baik jika elemen diagonal dari matriks $\underline{\mathbf{R}}$ dominan. Setiap baris dari matriks $\underline{\mathbf{R}}$ menggambarkan sejauhmana model dapat terresolusi dan bagaimana korelasi antar parameter model. Sebagaimana matriks resolusi data, matriks resolusi model juga hanya merupakan fungsi dari matriks kernel $\underline{\mathbf{G}}$ sehingga perhitungan matriks $\underline{\mathbf{R}}$ dapat dilakukan sebelum eksperimen (pengambilan data atau pemodelan inversi) dilaksanakan. Hal ini juga merupakan instrumen penting untuk mendisain suatu eksperimen.

3.6 Resolusi dan Ko-variansi Inversi Linier

Berdasarkan bentuk matriks *generalized inverse* untuk inversi linier yang telah dibahas yaitu $\underline{\mathbf{G}}^{-g} = [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T$ maka dapat disintesis berbagai kuantitas penting. Dalam hal ini matriks resolusi data, matriks resolusi model serta matriks satuan ko-variansi model adalah sebagai berikut:

$$\underline{\mathbf{N}} = \underline{\mathbf{G}} \underline{\mathbf{G}}^{-g} = \underline{\mathbf{G}} [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T \quad (3.23)$$

$$\underline{\mathbf{R}} = \underline{\mathbf{G}}^{-g} \underline{\mathbf{G}} = [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T \underline{\mathbf{G}} = \underline{\mathbf{I}} \quad (3.24)$$

$$\begin{aligned} \underline{\mathbf{C}}_m^u &= \underline{\mathbf{G}}^{-g} \underline{\mathbf{G}}^{-gT} [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T \\ &= [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \end{aligned} \quad (3.25)$$

Metode inversi linier yang telah dibahas berlaku pada kasus dimana jumlah data lebih besar dari pada jumlah parameter model (*over-determined*). Dalam hal ini data dapat mendefinisikan parameter model dengan baik sehingga secara matematis model ter-resolusi sempurna karena $\underline{\mathbf{R}} = \underline{\mathbf{I}}$.

It is often said that experiments should be made without preconceived ideas. That is impossible.

– Jules Henri Poincaré

4.1 Eksistensi Solusi Inversi Linier

Pada umumnya tidak ada solusi eksak dalam penyelesaian masalah inversi linier, yaitu model yang menghasilkan kesalahan prediksi data sama dengan nol ($E = 0$). Oleh karena itu dilakukan optimasi untuk memperoleh solusi terbaik dengan kriteria tertentu. Melalui pendekatan kuadrat-terkecil (*least-squares*) dilakukan optimasi untuk mencari model yang merupakan representasi solusi terbaik. Dalam hal ini kriteria solusi terbaik didasarkan pada kesalahan prediksi data minimum sesuai dengan *norm* L_2 (lihat persamaan (3.1)). Solusi inversi linier sebagaimana dinyatakan oleh persamaan (2.23) maupun persamaan (3.8) untuk inversi linier berbobot secara implisit mengasumsikan bahwa terdapat hanya satu solusi terbaik.

Dalam penyelesaian inversi linier pada umumnya jumlah data lebih besar dari pada jumlah parameter model yang dicari ($N > M$). Dalam hal ini data dapat menjadi kendala (*constrain*) yang memadai bagi model yang memenuhi kriteria kesalahan prediksi data minimum. Pada kasus seperti ini permasalahan inversi dikatakan sebagai *over-determined* atau *over-constrained*. Pada contoh regresi garis lurus yang telah dibahas, parameter model yang dicari adalah titik potong garis pada sumbu vertikal (*intercept*) dan kemiringan garis (*gradien*) sehingga jumlah parameter model M adalah 2. Jumlah data yang digunakan untuk memperkirakan parameter model tersebut umumnya jauh lebih besar dari M atau $N > 2$. Secara statistik estimasi solusi dapat dianggap memadai jika jumlah data minimum adalah 8.

Jika jumlah data tepat sama dengan jumlah parameter model ($N = M$) maka permasalahan inversi disebut sebagai *even-determined*. Solusi inversi dapat diperoleh langsung dengan inversi matriks kernel yang merupakan matriks bujur-sangkar (*square*), yaitu:

$$\begin{aligned} \mathbf{m} &= \mathbf{G}^{-1} \mathbf{d} \\ &= \frac{1}{z_2 - z_1} \begin{bmatrix} z_2 & -z_1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} d_1 \\ d_2 \end{bmatrix} \end{aligned} \quad (4.1)$$

Pada contoh regresi garis lurus hal tersebut terjadi jika hanya terdapat dua data atau dua titik. Permasalahan inversi yang demikian ter-reduksi menjadi permasalahan kalkulus biasa, yaitu penentuan persamaan garis lurus melalui dua titik yang solusinya sudah sangat dikenal dan identik dengan persamaan (4.1). Dalam hal ini kesalahan prediksi data $E = 0$.


Jika jumlah data lebih kecil dari pada jumlah parameter model yang dicari ($N < M$) maka permasalahan inversi disebut sebagai *under-determined* atau *under-constrained*. Pada kasus ini terdapat lebih dari satu solusi atau model yang dapat menghasilkan kesalahan prediksi data minimum. Artinya solusi tidak unik. Pada contoh regresi garis lurus dengan hanya satu data atau satu titik maka terdapat tak-hingga garis yang melalui titik tersebut dengan kesalahan prediksi data minimum yaitu $E = 0$. Ditinjau dari sudut pandang inversi linier, matriks $[\mathbf{G}^T \mathbf{G}]$ adalah matriks singular dan invers-nya tidak dapat ditentukan karena:

$$[\mathbf{G}^T \mathbf{G}]^{-1} = \begin{bmatrix} N & \sum z_i \\ \sum z_i & \sum z_i^2 \end{bmatrix}^{-1} = \begin{bmatrix} 1 & z_1 \\ z_1 & z_1^2 \end{bmatrix}^{-1} \quad (4.2)$$

sehingga determinan matriks tersebut berharga nol:

$$[\mathbf{G}^T \mathbf{G}]^{-1} = \frac{1}{(z_1^2 - z_1^2)} \begin{bmatrix} z_1^2 & -z_1 \\ -z_1 & 1 \end{bmatrix} \quad (4.3)$$

Ilustrasi inversi linier *over-determined*, *even-determined* dan *under-determined* pada contoh regresi garis lurus masing-masing diperlihatkan pada Gambar 4.1a, 4.1b dan 4.1c.



Gambar 4.1

Regresi garis lurus pada kasus *over-determined* (a), *even-determined* (b) dan *under-determined* (c). Informasi tambahan berupa *intercept* ataupun gradien untuk memperoleh solusi inversi linier *under-determined* (d).

Pada kasus *under-determined* data tidak cukup memberikan kendala untuk menentukan solusi atau model secara unik (tunggal). Untuk mengatasi masalah tersebut maka diperlukan informasi tambahan yang diharapkan dapat memberikan kendala atau batasan terhadap model yang dicari. Pada contoh regresi garis lurus informasi tersebut misalnya:

- Informasi mengenai titik lain (yang diperoleh secara independen) yang harus dilalui garis yang dimaksud sehingga permasalahan inversi menjadi *even-determined* karena $N = M = 2$.

- Asumsi atau perkiraan berdasarkan sumber informasi lainnya mengenai harga salah satu parameter model, misalnya titik potong dengan sumbu vertikal (*intercept*) atau kemiringan garis lurus (gradien) yang dicari. Dengan demikian permasalahan inversi menjadi *even-determined* dengan $N = M = 1$, karena harga salah satu parameter model sudah diketahui.

Sebagai contoh, pada kasus regresi linier yang merepresentasikan variasi temperatur terhadap kedalaman ($T = a + bz$), selain data yang sudah diketahui (temperatur pada satu kedalaman tertentu), kita dapat memperkirakan temperatur di permukaan bumi (T pada $z = 0$). Dengan demikian parameter model yang dicari hanyalah b karena a sudah diketahui. Demikian pula jika informasi mengenai gradien temperatur terhadap kedalaman (gradien geotermal) di tempat pengukuran sudah diketahui, maka parameter model yang dicari menjadi hanya a saja karena b sudah diketahui (lihat Gambar 4.1d).

4.2 Inversi Linier *Under-Determined*

Misalkan kita tinjau permasalahan inversi linier $\mathbf{d} = \mathbf{Gm}$ dimana jumlah data lebih kecil dari pada jumlah parameter model ($N < M$) yang disebut sebagai *purely under-determined*. Terdapat banyak (bahkan tak-hingga) solusi dengan kesalahan prediksi data $E = 0$. Selama hubungan antara data dengan parameter model $\mathbf{d} = \mathbf{Gm}$ bersifat konsisten maka sebenarnya data memberikan informasi mengenai parameter model, namun informasi tersebut tidak cukup untuk menentukan model secara unik. Untuk memperoleh solusi maka kita perlu suatu cara yang dapat menentukan atau memilih secara obyektif salah satu dari tak-hingga solusi dengan $E = 0$. Untuk itu kita perlu menambahkan informasi lain yang tidak terkandung dalam hubungan $\mathbf{d} = \mathbf{Gm}$.

Informasi tambahan yang sering disebut sebagai informasi "a priori" merupakan kuantifikasi ekspektasi atau harapan mengenai karakteristik solusi yang tidak didasarkan pada data pengukuran. Contoh informasi "a priori" pada regresi garis lurus dengan hanya satu data telah

dibahas pada sub-Bab terdahulu. Contoh informasi "a priori" lainnya adalah dalam bentuk interval harga parameter model, seperti pada pemodelan data gravitasi. Harga rapat massa batuan sudah dapat dipastikan selalu positif ($\sigma > 0$) atau rapat massa batuan terdapat pada selang atau interval tertentu ($\sigma_{\min} < \sigma < \sigma_{\max}$). Dalam penyelesaian masalah inversi, informasi "a priori" tersebut dapat mempersempit "daerah" pencarian solusi yang mungkin.

Hal-hal yang sering menjadi pertanyaan dalam penggunaan informasi "a priori" pada penyelesaian masalah inversi adalah mengenai asal, ketelitian dan cara kuantifikasi informasi tersebut. Keberatan atau kritik terhadap penggunaan informasi "a priori" disebabkan oleh sifatnya yang cenderung subyektif. Hal tersebut dikhawatirkan akan mempengaruhi hasil inversi secara tidak proporsional atau yang disebut sebagai *bias*. Oleh karena itu pemilihan informasi "a priori" harus dilakukan dengan cermat sehingga solusi yang diperoleh memang dapat menjelaskan data pengamatan dan bukan sebagai akibat pengaruh informasi "a priori" yang dominan.

Salah satu informasi "a priori" yang dapat digunakan dalam penyelesaian masalah inversi *purely under-determined* adalah asumsi bahwa solusi yang dicari bersifat "sederhana". Konsep kesederhanaan atau kompleksitas model dikuantifikasikan sebagai panjang vektor atau *norm* (L_2) dari model sebagai berikut:

$$L = \mathbf{m}^T \mathbf{m} = \sum_{i=1}^M m_i^2 \quad (4.4)$$

Berdasarkan perumusan pada persamaan (4.4), suatu model disebut "sederhana" jika L minimum.

Meskipun kriteria *norm* model minimum tersebut kurang memiliki landasan fisis namun dapat dijadikan kriteria untuk memperoleh solusi inversi linier pada kasus dimana $N < M$ (*purely under-determined*). Untuk sementara kriteria *norm* model minimum dianggap dapat diterima. Pada pembahasan selanjutnya kriteria yang berhubungan dengan sifat yang harus dipenuhi oleh solusi atau model akan dikembangkan lebih umum

untuk merepresentasikan kriteria yang lebih realistis. Selain itu arti kriteria tersebut secara fisis diharapkan lebih jelas.

Berdasarkan asumsi bahwa *norm* model harus minimum maka permasalahan inversi menjadi pencarian model $\mathbf{m}$ yang memenuhi kriteria L minimum dengan kendala atau syarat $\mathbf{e} = \mathbf{d} - \mathbf{G}\mathbf{m} = 0$. Secara analitik matematis permasalahan tersebut dapat diselesaikan dengan menggunakan metode pengali Lagrange (*Lagrange multipliers*). Berikut akan dibahas terlebih dahulu konsep metode pengali Lagrange untuk suatu fungsi yang umum. Selanjutnya metode pengali Lagrange tersebut digunakan untuk memformulasikan solusi inversi linier *purely under-determined*.

Misalkan permasalahannya adalah meminimumkan suatu fungsi $F(x, y)$ terhadap x dan y dengan kendala $\phi(x, y) = 0$. Pada nilai minimum fungsi $F(x, y)$ perubahan kecil pada x dan y tidak berpengaruh terhadap nilai F sehingga berlaku:

$$dF = \frac{\partial F}{\partial x} dx + \frac{\partial F}{\partial y} dy = 0 \quad (4.5)$$

Fungsi kendala $\phi(x, y)$ berharga nol untuk setiap x dan y sehingga turunannya terhadap x dan y juga berharga nol:

$$d\phi = \frac{\partial \phi}{\partial x} dx + \frac{\partial \phi}{\partial y} dy = 0 \quad (4.6)$$

Penjumlahan persamaan (4.5) dan (4.6) dengan pengali Lagrange λ sebagai pembobot persamaan (4.6) menghasilkan:

$$dF + \lambda d\phi = \left(\frac{\partial F}{\partial x} + \lambda \frac{\partial \phi}{\partial x} \right) dx + \left(\frac{\partial F}{\partial y} + \lambda \frac{\partial \phi}{\partial y} \right) dy = 0 \quad (4.7)$$

Jika persamaan (4.7) berlaku untuk setiap λ maka problematika menjadi pencarian minimum fungsi $F + \lambda \phi$ tanpa fungsi kendala. Salah satu syarat agar persamaan (4.7) berlaku adalah masing-masing suku berharga nol sehingga terdapat 3 persamaan dengan 3 variabel tak diketahui yaitu x , y dan λ . Persamaan tersebut adalah sebagai berikut:

$$\left(\frac{\partial F}{\partial x} + \lambda \frac{\partial \phi}{\partial x} \right) = 0, \quad \left(\frac{\partial F}{\partial y} + \lambda \frac{\partial \phi}{\partial y} \right) = 0, \quad \phi(x, y) = 0 \quad (4.8)$$

Persamaan (4.5) sampai (4.8) dapat diperluas untuk fungsi F dan ϕ yang merupakan fungsi dari suatu vektor $\mathbf{x}$ (x_i ; $i = 1, 2, \dots, p$) dengan sejumlah q fungsi kendala sehingga ϕ juga merupakan besaran vektor $\phi(\mathbf{x}) = 0$ (ϕ_k ; $k = 1, 2, \dots, q$). Dengan demikian persamaan simultan yang harus diselesaikan berjumlah $(p + q)$ dan dinyatakan sebagai berikut:

$$\left(\frac{\partial F}{\partial x_i} + \sum_{k=1}^p \lambda_k \frac{\partial \phi_k}{\partial x_i} \right) = 0 \quad \text{dan} \quad \phi_k(\mathbf{x}) = 0 \quad (4.9)$$

dimana $i = 1, 2, \dots, p$ dan $k = 1, 2, \dots, q$.

Berdasarkan analogi dengan permasalahan minimisasi menggunakan konsep pengali Lagrange di atas maka minimisasi panjang vektor atau *norm* model $L = \mathbf{m}^T \mathbf{m}$ dengan kendala $\mathbf{e} = \mathbf{d} - \mathbf{G} \mathbf{m} = 0$ pada dasarnya adalah minimisasi $\Phi(\mathbf{m}) = L + \mathbf{e}^T \boldsymbol{\lambda}$ yang dapat diuraikan menjadi:

$$\begin{aligned} \Phi(\mathbf{m}) &= L + \sum_{i=1}^N \lambda_i e_i \\ &= \sum_{j=1}^M m_j^2 + \sum_{i=1}^N \lambda_i \left(d_i - \sum_{j=1}^M G_{ij} m_j \right) \end{aligned} \quad (4.10)$$

Dalam hal ini jumlah pengali Lagrange adalah N yang sama dengan jumlah data. Jika $\Phi(\mathbf{m})$ minimum maka turunannya terhadap $\mathbf{m}$ atau setiap elemen parameter model m_q sama dengan nol ($\partial \Phi / \partial m_q = 0$) sehingga diperoleh suatu sistem persamaan berikut ($q = 1, 2, \dots, M$):

$$\begin{aligned} \frac{\partial \Phi}{\partial m_q} &= 2 \sum_{j=1}^M \frac{\partial m_j}{\partial m_q} m_j - \sum_{i=1}^N \lambda_i \sum_{j=1}^M G_{ij} \frac{\partial m_j}{\partial m_q} \\ 0 &= 2 m_q - \sum_{i=1}^N \lambda_i G_{iq} \end{aligned} \quad (4.11)$$

Dengan memperhatikan penurunan solusi inversi linier pada persamaan (2.22) maka persamaan (4.10) dapat ditulis kembali dalam bentuk matriks sebagai berikut:

$$\mathbf{m} = \frac{1}{2} \mathbf{G}^T \boldsymbol{\lambda} \quad (4.12)$$

Substitusi persamaan (4.12) ke dalam persamaan kendala $\mathbf{d} = \mathbf{G} \mathbf{m}$ menghasilkan $\mathbf{d} = \mathbf{G} \mathbf{m} = \mathbf{G} [0.5 \mathbf{G}^T \boldsymbol{\lambda}]$ sehingga diperoleh pengali Lagrange $\boldsymbol{\lambda} = 2 [\mathbf{G} \mathbf{G}^T]^{-1} \mathbf{d}$. Selanjutnya substitusi pengali Lagrange tersebut ke dalam persamaan (4.12) menghasilkan:

$$\mathbf{m} = \mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1} \mathbf{d} \quad (4.13)$$

Sebagaimana solusi inversi linier pada persamaan (2.23) yang secara umum berlaku untuk kondisi *over-determined* ($N > M$), persamaan (4.13) di atas adalah solusi untuk masalah inversi linier *purely under-determined* ($N < M$). Solusi tersebut sering pula disebut sebagai solusi inversi linier dengan *norm* model minimum karena diperoleh dengan meminimumkan "panjang" vektor model $\mathbf{m}$. Dalam hal ini matriks $\mathbf{G} \mathbf{G}^T$ adalah matriks bujur-sangkar ($N \times N$) yang diasumsikan bahwa inversnya dapat dihitung atau $\mathbf{G} \mathbf{G}^T$ bukan matriks singular. Contoh penerapan dari inversi linier *under-determined* ini akan dibahas pada Bab tentang aplikasi inversi linier pada data gravitasi dan magnetik.

Sebagaimana telah dilakukan pada metode inversi linier *over-determined*, matriks resolusi data, matriks resolusi model serta matriks satuan ko-variansi model dapat dirumuskan berdasarkan matriks *generalized inverse* untuk inversi linier *purely under-determined* $\mathbf{G}^{-g} = \mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1}$ sehingga diperoleh:

$$\mathbf{N} = \mathbf{G} \mathbf{G}^{-g} = \mathbf{G} \mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1} = \mathbf{I} \quad (4.14)$$

$$\mathbf{R} = \mathbf{G}^{-g} \mathbf{G} = \mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1} \mathbf{G} \quad (4.15)$$

$$\begin{aligned} \mathbf{C}_m^u &= \mathbf{G}^{-g} \mathbf{G}^{-gT} [\mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1}] [\mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-1}]^T \\ &= \mathbf{G}^T [\mathbf{G} \mathbf{G}^T]^{-2} \mathbf{G} \end{aligned} \quad (4.16)$$


Tampak bahwa pada inversi linier dengan kriteria *norm* model minimum matriks resolusi data adalah matriks identitas. Dengan demikian data dapat ter-resolusi dengan baik. Hal tersebut sesuai dengan perumusan solusi yang diperoleh dengan meminimumkan model dengan kendala kesalahan prediksi data $E = 0$.

4.3 Inversi Linier *Mixed-Determined*

Dalam banyak kasus, permasalahan inversi geofisika merupakan gabungan dari kondisi *under-determined* dan *over-determined* sehingga dapat disebut sebagai permasalahan inversi *mixed-determined*. Pada contoh tomografi akustik atau tomografi kedokteran misalnya, blok medium yang dilalui beberapa berkas sinar gelombang akan terdefinisi dengan baik sehingga merupakan sub-sistem permasalahan inversi *over-determined*. Sebaliknya, daerah yang sama sekali tidak dilalui berkas sinar gelombang (karena keterbatasan geometri eksperimen) tidak akan terdefinisi dengan baik sehingga merupakan sub-sistem permasalahan inversi *under-determined* (lihat Gambar 4.2).

Keterbatasan geometri eksperimen, misalnya posisi sumber dan penerima pada tomografi akustik, dapat menyebabkan harga parameter model secara individual tidak dapat ditentukan. Dalam hal ini, kombinasi dari harga parameter model saja (seperti hanya harga rata-rata sifat fisik medium) yang dapat diperoleh. Oleh karena itu diperlukan strategi penyelesaian inversi linier yang dapat menghasilkan informasi paling optimum mengenai parameter model yang dicari. Penggunaan asumsi tertentu mengenai karakter model dapat digunakan sebagai informasi "a priori" atau kriteria tambahan.

Salah satu strategi untuk menyelesaikan permasalahan inversi linier *mixed-determined* adalah dengan menggabungkan kriteria untuk mencari solusi optimum atau model terbaik. Pada kasus *over-determined* kriteria yang digunakan untuk menghasilkan solusi adalah kesalahan prediksi data (*misfit*) E minimum. Sementara itu pada kasus *under-determined* model atau solusi yang diharapkan adalah yang memiliki "panjang" vektor minimum (sesuai dengan *norm* L_2).



Gambar 4.2

Berbagai kondisi geometri eksperimen pada tomografi akustik yang menghasilkan resolusi parameter model berbeda sesuai dengan kondisi inversi *even-determined*, *under-determined*, *over-determined* atau *mixed-determined*.

Dengan menggabungkan kedua kriteria yaitu *misfit* dan *norm* model minimum maka permasalahan inversi menjadi proses pencarian model dengan meminimumkan kuantitas berikut:

$$\Phi(\mathbf{m}) = E + \varepsilon^2 L = \mathbf{e}^T \mathbf{e} + \varepsilon^2 \mathbf{m}^T \mathbf{m} \quad (4.17)$$

dimana ε^2 adalah bilangan positif sebagai bobot relatif antara kedua faktor yang diminimumkan. Jika ε^2 dipilih sangat besar maka minimisasi *norm* model (*solution length*) akan lebih dominan, sementara model tersebut belum tentu menghasilkan kesalahan prediksi data minimum. Sebaliknya jika $\varepsilon^2 = 0$ maka kesalahan prediksi data akan diminimumkan, namun tidak ada informasi "a priori" yang digunakan untuk memberikan kendala bagi parameter model yang dicari.

Harga minimum dari $\Phi(\mathbf{m})$ diperoleh dengan mencari turunan $\Phi(\mathbf{m})$ terhadap parameter model $\mathbf{m}$ yang kemudian dibuat sama dengan nol seperti dilakukan pada penurunan inversi linier (persamaan (2.23)). Dengan demikian diperoleh solusi inversi linier ter-redam (*damped linear inversion*) sebagai berikut:

$$\mathbf{m} = [\mathbf{G}^T \mathbf{G} + \varepsilon^2 \mathbf{I}]^{-1} \mathbf{G}^T \mathbf{d} \quad (4.18)$$


Penggunaan istilah redaman atau *damping* untuk estimasi parameter model sebagaimana dinyatakan oleh persamaan (4.18) berasosiasi dengan proses "meredam" ketidak-stabilan yang mungkin timbul akibat keterbatasan data pada inversi yang termasuk *under-determined*. Konsep minimisasi kesalahan pada inversi linier biasa diperluas menjadi minimisasi kesalahan prediksi data (*error length*) dan kesalahan solusi (*solution length*).

Secara matematis penambahan suatu bilangan relatif kecil ϵ^2 pada setiap elemen diagonal matriks $[\mathbf{G}^T \mathbf{G}]$ seperti terlihat pada persamaan (4.18) dapat menstabilkan proses inversi matriks tersebut. Perlu diingat bahwa dalam proses inversi suatu matriks (misalnya menggunakan algoritma eliminasi Gauss-Jordan) dilakukan prosedur *pivoting* yaitu membagi setiap baris matriks dengan elemen diagonalnya. Tujuan prosedur *pivoting* adalah untuk memperoleh elemen diagonal berharga satu yang kemudian digunakan untuk mengeliminasi elemen pada baris lainnya. Jika elemen diagonal sangat kecil atau mendekati nol maka proses *pivoting* akan menghasilkan bilangan yang sangat besar dan proses inversi menjadi tidak stabil. Dengan kata lain parameter ϵ^2 berfungsi meredam ketidakstabilan proses inversi matriks tersebut.

Faktor redaman ϵ^2 yang sering disebut pula sebagai *regularization parameter* harus dipilih sedemikian rupa sehingga menyatakan pertimbangan atau kompromi antara masing-masing faktor yang diminimumkan. Pada umumnya ϵ^2 ditentukan secara coba-coba (*trial and error*) kemudian melalui mekanisme tertentu dipilih diantara beberapa harga ϵ^2 dengan menerapkan salah satu dari kriteria berikut:

- Norm model minimum dengan kesalahan prediksi data yang masih berada di bawah harga tertentu, $E = \|\mathbf{e}\|^2 \leq \delta$.
- Kesalahan prediksi data minimum dengan norm model $L = \|\mathbf{m}\|^2 \leq \lambda$.

Harga L menurun sebagai fungsi ϵ^2 , sementara E meningkat sesuai peningkatan ϵ^2 . Plot harga L dan E untuk beberapa harga ϵ^2 (biasanya dalam skala log – log) menghasilkan kurva berbentuk "L" yang disebut sebagai *trade-off curve* yang dapat digunakan untuk menentukan harga ϵ^2 (Gambar 4.3).



Gambar 4.3

Dua tipe *trade-off curve* yang menggambarkan variasi *norm* model L dan kesalahan prediksi data E sebagai fungsi dari ϵ^2 yang dapat digunakan untuk memilih harga ϵ^2 dengan batasan $L \leq \lambda$ atau $E \leq \delta$ tertentu.

4.4 Beberapa Model "A Priori"

Model Referensi

Sebagaimana telah dibahas, kuantifikasi kompleksitas model dalam bentuk *norm* model $L = \mathbf{m}^T \mathbf{m}$ dan minimisasinya untuk memperoleh solusi inversi kurang memiliki arti fisis yang jelas. Kriteria *norm* model minimum dapat mengarah pada solusi inversi atau model yang dekat dengan nol yang jelas tidak realistis. Meskipun demikian, penggunaan informasi "a priori" tersebut terbukti dapat mengatasi permasalahan inversi linier *under-determined* maupun *mixed-determined*.

Dalam konteks inversi linier *mixed-determined*, akan lebih realistis jika model yang dicari adalah model yang mendekati atau mirip dengan model tertentu yang dinyatakan sebagai model referensi. Model referensi ditentukan berdasarkan informasi "a priori" yang tersedia. Salah satu contoh model referensi adalah model rata-rata, yaitu model yang disusun oleh parameter model dengan harga konstan tertentu. Pada kasus ini solusi inversi adalah fluktuasi atau variasi harga parameter model di sekitar harga rata-rata tersebut. Contoh lain adalah model bawah-

permukaan yang telah diketahui sebelumnya berdasarkan informasi yang diperoleh dari data lain. Pemodelan inversi dapat dibuat sedemikian hingga solusinya mendekati model referensi tersebut. Dapat dibuktikan bahwa, informasi yang diperoleh dari data pada dasarnya berfungsi memodifikasi atau meng-*update* model referensi tersebut.

Jarak (dalam *norm* L_2) antara solusi yang dicari dengan model referensi dapat dituliskan sebagai berikut:

$$L = [\mathbf{m} - \bar{\mathbf{m}}]^T [\mathbf{m} - \bar{\mathbf{m}}] \quad (4.19)$$

dimana $\bar{\mathbf{m}}$ adalah model referensi atau model "a priori". Kompleksitas suatu model dikuantifikasi sebagai jarak model tersebut terhadap model referensi. Dengan kata lain, suatu model disebut "sederhana" jika jaraknya terhadap model referensi minimum.

Sebagaimana pada pencarian solusi dengan kriteria *norm* model minimum, kuantitas dalam persamaan (4.19) bersama dengan kesalahan prediksi data E diminimumkan sehingga minimisasi dilakukan terhadap:

$$\begin{aligned} \Phi(\mathbf{m}) &= E + \varepsilon^2 L \\ &= \mathbf{e}^T \mathbf{e} + \varepsilon^2 [\mathbf{m} - \bar{\mathbf{m}}]^T [\mathbf{m} - \bar{\mathbf{m}}] \end{aligned} \quad (4.20)$$

Turunan $\Phi(\mathbf{m})$ terhadap model $\mathbf{m}$ dibuat sama dengan nol sehingga diperoleh solusi inversi linier ter-redam (*damped linear inversion*) yang pada kasus ini dinyatakan oleh persamaan berikut:

$$\mathbf{m} = \bar{\mathbf{m}} + [\underline{\mathbf{G}}^T \underline{\mathbf{G}} + \varepsilon^2 \underline{\mathbf{I}}]^{-1} \underline{\mathbf{G}}^T [\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}] \quad (4.21)$$

Tampak bahwa solusi atau model hasil inversi merupakan model referensi yang di-*update* dengan suatu faktor koreksi tertentu yang dinyatakan oleh suku ke dua ruas kanan dari persamaan (4.21). Bentuk persamaan yang menyatakan faktor koreksi tersebut mirip dengan persamaan untuk solusi inversi linier ter-redam pada persamaan (4.18). Dalam hal ini faktor pengali dari matriks *generalized inverse* bukan hanya vektor data $\mathbf{d}$ melainkan selisih antara respons model referensi terhadap data.


Model Flat dan Smooth

Penggunaan istilah "kompleks" atau "sederhana" untuk mengkarakterisasi model sebenarnya bersifat umum yang dapat dihubungkan dengan kuantitas tertentu. Kompleksitas model mungkin agak janggal jika dihubungkan dengan *norm* model $L = \mathbf{m}^T \mathbf{m}$ sebagaimana telah dibahas. Sementara itu kuantitas jarak model terhadap suatu model referensi $L = [\mathbf{m} - \bar{\mathbf{m}}]^T [\mathbf{m} - \bar{\mathbf{m}}]$ memungkinkan penggunaan informasi "a priori" maupun asumsi yang lebih realistis untuk menentukan karakteristik solusi inversi yang diharapkan. Dalam pembahasan berikut konsep minimisasi *norm* tersebut tetap akan digunakan, namun dihubungkan dengan kuantitas yang secara fisis dapat dikatakan menggambarkan sifat "kompleks" atau "sederhana" suatu model.

Dalam pemodelan geofisika, model umumnya merepresentasikan distribusi spasial sifat fisika bawah-permukaan. Jika parameter model adalah kuantitas sejenis (misal kecepatan gelombang seismik saja, rapat massa saja atau tahanan-jenis saja) maka parameterisasi model bersifat homogen. Dalam kasus tersebut parameter model berasosiasi dengan suatu geometri spasial yang tetap, misalnya lapisan-lapisan bumi pada model 1-D dimana sifat fisika hanya bervariasi terhadap kedalaman (z).

Pada model 2-D parameter model berasosiasi dengan grid seperti pada contoh tomografi akustik. Grid tersebut umumnya menggambarkan potongan vertikal (x, z) yang disebut penampang atau profil. Asosiasi parameter model dengan geometri model dapat diperluas untuk menggambarkan kondisi yang lebih realistis menggunakan model 3-D (Gambar 4.4). Dengan demikian variasi spasial parameter model tersebut pada setiap lapisan, grid atau blok dari model digunakan untuk menggambarkan distribusi sifat fisika bawah-permukaan.

Pada kasus tertentu variasi spasial harga parameter model diharapkan tidak terlalu besar sehingga dalam inversi perbedaan harga parameter model yang saling berdekatan diminimumkan. Dalam hal ini dicari model yang memiliki karakteristik "flat" atau "smooth" yang bergantung pada operator diferensial yang diterapkan untuk menghitung selisih atau variasi tersebut.



Gambar 4.4

Ilustrasi model atau medium 1-D, 2-D dan 3-D (dari kiri ke kanan) untuk merepresentasikan variasi spasial parameter model.

Jika model yang diharapkan adalah model yang bersifat "flat" maka besaran yang diminimumkan adalah:

$$L(\mathbf{m}) = \sum_{j=2}^M (m_j - m_{j-1})^2 \quad (4.22)$$

Besaran tersebut pada dasarnya adalah *norm* dari "flatness" model, sementara "flatness" model $\mathbf{l}$ dinyatakan dalam notasi matriks sebagai hasil operasi suatu matriks $\underline{\mathbf{D}}$ terhadap vektor model $\mathbf{m}$ berikut:

$$\mathbf{l} = \begin{bmatrix} -1 & 1 & 0 & \cdots & 0 \\ 0 & -1 & 1 & 0 & \cdots & 0 \\ \vdots & & & & \vdots & \\ 0 & & \cdots & -1 & 1 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_M \end{bmatrix} = \underline{\mathbf{D}} \mathbf{m} \quad (4.23)$$

Matriks $\underline{\mathbf{D}}$ adalah representasi diskret dari operator diferensial atau turunan pertama yang menyatakan beda-hingga (*finite-difference*) antara dua harga yang saling berdekatan secara spasial. Matriks $\underline{\mathbf{D}}$ sering disebut pula sebagai *flatness matrix* dan dinyatakan dengan notasi $\underline{\mathbf{D}}^f$.

Sebagai alternatif, jika model yang diharapkan adalah model yang "smooth" maka besaran yang diminimumkan adalah:

$$L(\mathbf{m}) = \sum_{j=3}^M (m_j - 2m_{j-1} + m_{j-2})^2 \quad (4.24)$$

Analog dengan sebelumnya, besaran tersebut adalah *norm* dari "smoothness" model. Dalam hal ini matriks $\underline{\mathbf{D}}$ yang digunakan adalah representasi diskret dari operator diferensial atau turunan orde-2 yang dituliskan sebagai berikut:

$$\underline{\mathbf{D}}^s = \begin{bmatrix} 1 & -2 & 1 & 0 & \cdots & 0 \\ 0 & 1 & -2 & 1 & \cdots & 0 \\ \vdots & & & & \vdots & \\ 0 & & \cdots & 1 & -2 & 1 \end{bmatrix} \quad (4.25)$$

Matriks $\underline{\mathbf{D}}^s$ sering disebut pula sebagai *smoothness matrix*.

Norm dari "flatness" maupun "smoothness" model dalam notasi matriks dinyatakan oleh persamaan berikut:

$$\begin{aligned} L = \mathbf{l}^T \mathbf{l} &= [\underline{\mathbf{D}} \mathbf{m}]^T [\underline{\mathbf{D}} \mathbf{m}] = \mathbf{m}^T \underline{\mathbf{D}}^T \underline{\mathbf{D}} \mathbf{m} \\ &= \mathbf{m}^T \underline{\mathbf{W}}_m \mathbf{m} \end{aligned} \quad (4.26)$$

Besaran L tersebut merepresentasikan kompleksitas atau variabilitas model yang diminimumkan untuk memperoleh solusi berupa model yang "flat" jika $\underline{\mathbf{D}} = \underline{\mathbf{D}}^f$ ataupun "smooth" jika $\underline{\mathbf{D}} = \underline{\mathbf{D}}^s$. Ditinjau dari bentuknya L pada persamaan (4.26) tersebut adalah *norm* model yang diberi bobot matriks $\underline{\mathbf{W}}_m = \underline{\mathbf{D}}^T \underline{\mathbf{D}}$. Dalam hal ini $\underline{\mathbf{W}}_m$ adalah matriks ($M \times M$) dimana M adalah jumlah parameter model.

Secara lebih umum ukuran kompleksitas model dapat diperluas untuk sebarang matriks $\underline{\mathbf{D}}$ yang beroperasi pada model $\mathbf{m}$ dan menghasilkan matriks pembobot $\underline{\mathbf{W}}_m$ yang berbeda. Namun pemilihan bentuk matriks $\underline{\mathbf{D}}$ hendaknya dilandasi realitas fisis yang diharapkan tercermin pada model inversi yang dicari.

Sebagaimana telah dilakukan sebelumnya, model atau solusi inversi dicari dengan meminimumkan jumlah berbobot antara kesalahan prediksi data dan *norm* dari variabilitas model. Dengan demikian kuantitas yang diminimumkan adalah:


$$\Phi(\mathbf{m}) = E + \varepsilon^2 L = \mathbf{e}^T \mathbf{e} + \varepsilon^2 \mathbf{m}^T \underline{\mathbf{W}}_m \mathbf{m} \quad (4.27)$$

Solusi inversi linier terkecil ter-redam pada kasus ini dinyatakan oleh:

$$\mathbf{m} = [\mathbf{G}^T \mathbf{G} + \varepsilon^2 \mathbf{W}_m]^{-1} \mathbf{G}^T \mathbf{d} \quad (4.28)$$

Jika dilihat kuantitas yang diminimumkan (persamaan (4.27)) dan solusi inversi linier dengan variabilitas minimum (persamaan (4.28)) keduanya sangat mirip dengan persamaan (4.17) dan (4.18) untuk inversi linier ter-redam dengan *norm* model minimum. Perbedaan keduanya hanya terletak pada suku yang mengandung faktor redaman ε^2 yang disebabkan oleh perbedaan pembobotan pada perhitungan *norm* model $L = \mathbf{m}^T \mathbf{m}$. Perhitungan $L = \mathbf{m}^T \mathbf{m}$ tanpa bobot identik dengan perhitungan $L = \mathbf{m}^T \mathbf{W}_m \mathbf{m}$ namun dengan matriks identitas sebagai matriks bobot.

Contoh aplikasi inversi geofisika dengan kriteria variabilitas model minimum diperlihatkan pada Gambar 4.5 untuk kasus inversi data magnetotellurik 1-D. Dalam hal ini inversinya adalah inversi non-linier sesuai dengan hubungan antara data dan parameter model pada masalah MT 1-D. Pada dasarnya inversi dengan kriteria variabilitas model minimum dapat diterapkan pada kasus dimana model adalah diskretisasi medium dengan dimensi yang lebih tinggi (2-D maupun 3-D).



Gambar 4.5

Ilustrasi pemodelan magnetotellurik 1-D yang menggunakan kriteria kehalusan model (*smoothness constrained*).

Bentuk Umum Model "A Priori"

Sampai sejauh ini telah dibahas dua macam informasi atau asumsi "a priori" yang masing-masing memiliki landasan fisis yang lebih realistis. Keduanya termasuk dalam kategori inversi linier ter-redam dimana model yang dicari adalah model yang dekat dengan suatu model referensi atau model dengan variabilitas minimum (model "flat" atau "smooth"). Secara teoritis kedua kriteria mengenai karakteristik model yang diharapkan tersebut dapat digabungkan untuk keperluan generalisasi, meskipun kriteria tersebut belum tentu berhubungan dengan realitas fisis yang tepat.

Pada dasarnya pembobotan *norm* model dengan $\mathbf{W}_m$ yang tidak diturunkan dari kriteria variabilitas spasial model sebagaimana pada persamaan (4.23) dan (4.25) dapat saja digunakan. Dengan demikian ukuran kompleksitas model dalam bentuknya yang lebih umum dinyatakan oleh gabungan antara: (1) kedekatan solusi dengan suatu model referensi tertentu dan (2) *norm* model yang diberi bobot. Kuantitas tersebut dinyatakan oleh:

$$L = [\mathbf{m} - \bar{\mathbf{m}}]^T \mathbf{W}_m [\mathbf{m} - \bar{\mathbf{m}}] \quad (4.29)$$

Dengan memilih model referensi atau model "a priori" $\bar{\mathbf{m}}$ dan bentuk matriks pembobot $\mathbf{W}_m$ maka L dapat merepresentasikan ukuran kompleksitas model yang cukup bervariasi. Pemilihan $\bar{\mathbf{m}}$ dan $\mathbf{W}_m$ yang tepat harus disesuaikan dengan permasalahan yang ditinjau.

Terdapat kemiripan bentuk persamaan yang menyatakan kuantitas yang diminimumkan dan solusi atau model inversi sebagaimana telah dibahas sebelumnya, seperti persamaan (4.17) dan (4.18), persamaan (4.20) dan (4.21) serta persamaan (4.27) dan (4.28). Berdasarkan hal tersebut maka kuantitas yang diminimumkan dan solusi inversi linier ter-redam untuk kasus yang lebih umum masing-masing adalah sebagai berikut:

$$\begin{aligned} \Phi(\mathbf{m}) &= E + \varepsilon^2 L \\ &= \mathbf{e}^T \mathbf{e} + \varepsilon^2 [\mathbf{m} - \bar{\mathbf{m}}]^T \mathbf{W}_m [\mathbf{m} - \bar{\mathbf{m}}] \end{aligned} \quad (4.30)$$

$$\mathbf{m} = \bar{\mathbf{m}} + [\underline{\mathbf{G}}^T \underline{\mathbf{G}} + \varepsilon^2 \underline{\mathbf{W}}_m]^{-1} \underline{\mathbf{G}}^T [\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}] \quad (4.31)$$

Jika perluasan atau generalisasi tersebut diterapkan pada inversi linier berbobot (yang memperhitungkan kesalahan data, dibahas pada Bab 3) maka dengan memasukkan faktor pembobotan data sebagaimana pada persamaan (3.5) dan solusinya seperti pada persamaan (3.8), persamaan (4.30) dan (4.31) menjadi:

$$\Phi(\mathbf{m}) = E + \varepsilon^2 L \quad (4.32)$$

$$= \mathbf{e}^T \underline{\mathbf{W}}_e \mathbf{e} + \varepsilon^2 [\mathbf{m} - \bar{\mathbf{m}}]^T \underline{\mathbf{W}}_m [\mathbf{m} - \bar{\mathbf{m}}]$$

$$\mathbf{m} = \bar{\mathbf{m}} + [\underline{\mathbf{G}}^T \underline{\mathbf{W}}_e \underline{\mathbf{G}} + \varepsilon^2 \underline{\mathbf{W}}_m]^{-1} \underline{\mathbf{G}}^T \underline{\mathbf{W}}_e [\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}] \quad (4.33)$$

Tampak bahwa persamaan (4.32) dan (4.33) merupakan bentuk yang paling umum dari permasalahan inversi linier berbobot dan ter-redam. Selanjutnya dapat dibuktikan bahwa persamaan (4.33) dapat dituliskan kembali sebagai berikut:

$$\mathbf{m} = \bar{\mathbf{m}} + \underline{\mathbf{W}}_m^{-1} \underline{\mathbf{G}}^T [\underline{\mathbf{G}} \underline{\mathbf{W}}_m \underline{\mathbf{G}}^T + \varepsilon^2 \underline{\mathbf{W}}_e^{-1}]^{-1} [\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}] \quad (4.34)$$

Pada pembahasan mengenai inversi linier *purely under-determined* telah dijelaskan penggunaan kriteria *norm* model minimum untuk memperoleh solusi yang dinyatakan oleh persamaan (4.13). *Norm* model pada persamaan (4.4) tersebut dapat diperluas menjadi *norm* model dalam bentuk yang lebih umum dengan pembobotan seperti pada persamaan (4.29). Berdasarkan analogi bentuk persamaan (4.13) dan persamaan (4.31) maka solusi inversi linier *purely under-determined* pada kasus yang diperluas ini adalah:

$$\mathbf{m} = \bar{\mathbf{m}} + \underline{\mathbf{W}}_m \underline{\mathbf{G}}^T [\underline{\mathbf{G}} \underline{\mathbf{W}}_m \underline{\mathbf{G}}^T]^{-1} [\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}] \quad (4.35)$$

Sebagaimana persamaan (4.21), persamaan (4.31), (4.33), (4.34) dan (4.35) menyatakan bahwa solusi inversi linier adalah model referensi yang dikoreksi dengan suatu faktor tertentu. Faktor koreksi tersebut diperoleh dari penerapan suatu matriks operator $\underline{\mathbf{A}}$ terhadap selisih antara data pengamatan dan respons model referensi $[\mathbf{d} - \underline{\mathbf{G}} \bar{\mathbf{m}}]$. Bentuk

matriks operator $\underline{\mathbf{A}}$ bergantung pada permasalahan yang ditinjau yang tercermin pada kuantitas yang diminimumkan. Jika dihubungkan dengan pembahasan mengenai matriks resolusi data dan matriks resolusi model pada Bab 3 maka operator $\underline{\mathbf{A}}$ pada persamaan-persamaan tersebut di atas pada dasarnya adalah juga suatu bentuk dari matriks *generalized inverse*. Konsekuensi dari bentuk matriks *generalized inverse* tersebut tidak dibahas pada bab ini.

4.5 Informasi "A Priori" dalam Bentuk Lain

Pada banyak kasus, informasi "a priori" yang tersedia dapat pula dinyatakan dalam bentuk umum $\underline{\mathbf{F}} \mathbf{m} = \mathbf{h}$, yang berarti bahwa suatu fungsi dari parameter model memiliki harga tertentu atau konstan. Persamaan tersebut berfungsi sebagai kendala (*constrain*) dalam estimasi parameter model. Sebagai contoh, misalkan harga rata-rata parameter model diketahui atau dikehendaki sama dengan suatu harga h_1 tertentu. Permasalahan inversi linier tersebut harus diselesaikan bersama dengan persamaan kendala berikut:

$$\underline{\mathbf{F}} \mathbf{m} = \mathbf{h} \equiv \frac{1}{M} \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_M \end{bmatrix} = [h_1] \quad (4.36)$$

Persamaan tersebut hanyalah merupakan perhitungan rata-rata harga parameter model dalam bentuk operasi terhadap vektor model $\mathbf{m}$, yaitu $\underline{\mathbf{F}} \mathbf{m} = \mathbf{h}$. Vektor $\mathbf{h}$ berharga tunggal atau skalar, yaitu harga rata-rata dari parameter model yang dikehendaki.

Informasi "a priori" dapat pula berupa harga salah satu parameter model yang dianggap sudah diketahui sehingga persamaan kendalanya menjadi:

$$\underline{\mathbf{F}} \mathbf{m} = \mathbf{h} \equiv \begin{bmatrix} 0 & \dots & 0 & 1 & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \vdots \\ m_M \end{bmatrix} = [h_1] \quad (4.37)$$

Contoh dari kasus ini adalah inversi geolistrik atau magnetotellurik 1-D dimana harga resistivitas salah satu atau beberapa lapisan telah diketahui, misalnya dari data lubang bor. Secara lebih umum pada pemodelan 2-D dan 3-D, persamaan kendala (4.37) tersebut dapat digunakan untuk menyatakan bahwa beberapa grid atau blok telah diketahui harga parameter modelnya.

Salah satu cara penyelesaian permasalahan inversi linier $\mathbf{d} = \mathbf{G}\mathbf{m}$ dengan kendala $\mathbf{F}\mathbf{m} = \mathbf{h}$ atau $\mathbf{F}\mathbf{m} - \mathbf{h} = 0$ seperti pada persamaan (4.36) atau (4.37) di atas adalah dengan menggunakan metode pengali Lagrange. Dalam hal ini fungsi yang diminimumkan adalah $\Phi(\mathbf{m}) = E + [\mathbf{F}\mathbf{m} - \mathbf{h}]^T \boldsymbol{\lambda}$ yang dapat diuraikan menjadi:

$$\Phi(\mathbf{m}) = \sum_{i=1}^N \left(d_i - \sum_{j=1}^M G_{ij} m_j \right)^2 + 2 \sum_{i=1}^p \lambda_i \left(\sum_{j=1}^M F_{ij} m_j - h_i \right) \quad (4.38)$$

dimana jumlah kendala adalah p dan $2 \lambda_i$ adalah pengali Lagrange (penggunaan faktor 2 pada pengali Lagrange hanya untuk memudahkan penurunan persamaan akhir).

Jika fungsi $\Phi(\mathbf{m})$ minimum maka turunannya terhadap setiap elemen parameter model m_q sama dengan nol ($\partial\Phi/\partial m_q = 0$). Penurunan $\Phi(\mathbf{m})$ terhadap setiap elemen parameter model m_q adalah sebagai berikut:

$$\frac{\partial\Phi(\mathbf{m})}{\partial m_q} = -2 \sum_{i=1}^N G_{iq} d_i + 2 \sum_{j=1}^M m_j \sum_{i=1}^N G_{ij} G_{iq} + 2 \sum_{k=1}^p \lambda_k F_{kq} \quad (4.39)$$

Dapat dibuktikan bahwa persamaan tersebut di atas dapat dituliskan dalam bentuk matriks sehingga menjadi:

$$\mathbf{G}^T \mathbf{G} \mathbf{m} + \mathbf{F}^T \boldsymbol{\lambda} = \mathbf{G}^T \mathbf{d} \quad (4.40)$$

Persamaan (4.36) di atas harus diselesaikan secara simultan dengan persamaan kendala $\mathbf{F}\mathbf{m} = \mathbf{h}$. Kedua persamaan dapat disusun menjadi:

$$\begin{bmatrix} \mathbf{G}^T \mathbf{G} & \mathbf{F}^T \\ \mathbf{F} & \mathbf{O} \end{bmatrix} \begin{bmatrix} \mathbf{m} \\ \boldsymbol{\lambda} \end{bmatrix} = \begin{bmatrix} \mathbf{G}^T \mathbf{d} \\ \mathbf{h} \end{bmatrix} \quad (4.41)$$

Solusi dari persamaan (4.41) yang menghasilkan bentuk eksplisit dari estimasi parameter model $\mathbf{m}$ dapat dilakukan dengan cara yang sama seperti dilakukan untuk memperoleh persamaan (4.13) yaitu solusi inversi linier *purely under-determined*. Namun demikian akan lebih mudah jika $(M + p)$ sistem persamaan pada persamaan (4.41) tersebut di atas diselesaikan untuk menghitung secara langsung sejumlah M parameter model dan p pengali Lagrange yang dicari. Hal ini dapat dilakukan dengan perkalian persamaan (4.41) dengan invers matriks bujur-sangkar di ruas kiri persamaan tersebut sehingga diperoleh persamaan solusi berikut:

$$\begin{bmatrix} \mathbf{m} \\ \boldsymbol{\lambda} \end{bmatrix} = \begin{bmatrix} \mathbf{G}^T \mathbf{G} & \mathbf{F}^T \\ \mathbf{F} & \mathbf{O} \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{G}^T \mathbf{d} \\ \mathbf{h} \end{bmatrix} \quad (4.42)$$


Sebagai contoh, pada regresi garis lurus $T_i = a + b z_i$ diasumsikan terdapat informasi "a priori" yang menyatakan bahwa garis tersebut (solusi inversi) dikehendaki melalui suatu titik (z^*, T^*) sebagaimana diilustrasikan pada Gambar 4.6. Pada kasus ini persamaan kendalanya adalah $T^* = a + b z^*$ yang dapat dinyatakan oleh:

$$\mathbf{F}\mathbf{m} = \mathbf{h} \equiv \begin{bmatrix} 1 & z^* \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} T^* \end{bmatrix} \quad (4.43)$$

Dalam hal ini $M = 2$ dan $p = 1$. Dengan menggunakan elemen-elemen yang sudah diketahui untuk matriks $\mathbf{G}^T \mathbf{G}$ dan $\mathbf{G}^T \mathbf{d}$ maka solusi permasalahan tersebut di atas adalah:

$$\begin{bmatrix} a \\ b \\ \lambda_1 \end{bmatrix} = \begin{bmatrix} N & \sum z_i & 1 \\ \sum z_i & \sum z_i^2 & z^* \\ 1 & z^* & 0 \end{bmatrix}^{-1} \begin{bmatrix} \sum T_i \\ \sum T_i z_i \\ T^* \end{bmatrix} \quad (4.44)$$

Pada Gambar 4.6 diperlihatkan model hasil inversi menggunakan informasi "a priori" berupa titik yang harus dilalui oleh solusi atau model. Solusi tersebut dapat saja berbeda dari solusi yang diperoleh jika tidak digunakan informasi tambahan.



Gambar 4.6

Regresi garis lurus jika diketahui informasi "a priori" bahwa garis tersebut harus melalui titik (z^*, T^*) .

Bentuk lain persamaan kendala adalah $\mathbf{Fm} \geq \mathbf{h}$ dimana kesamaan ($\mathbf{Fm} = \mathbf{h}$) dan ketidaksamaan ($\mathbf{Fm} > \mathbf{h}$) harus dievaluasi secara terpisah. Hal yang sama dapat dilakukan jika persamaan kendalanya adalah $\mathbf{Fm} \leq \mathbf{h}$ dengan terlebih dahulu mengalikan kedua ruas dengan bilangan -1. Kedua bentuk persamaan kendala tersebut dapat diterapkan pada permasalahan inversi linier dimana parameter model harus memiliki karakteristik tertentu, misalnya berharga positif $m_i > 0$ atau berada dalam batas atau interval tertentu $m_i^{\min} < m < m_i^{\max}$. Untuk sementara penyelesaian inversi linier menggunakan kendala tersebut tidak dibahas pada buku ini. Pembahasan lengkap dapat dipelajari dari Menke (1984).

*Divide each difficulty into as many parts as is feasible
and necessary to resolve it.*

– René Descartes

5.1 Parameterisasi Pemodelan


Dalam formulasi permasalahan inversi perlu ditentukan parameterisasi yang digunakan dengan memilih variabel yang merepresentasikan data dan parameter model. Hal tersebut penting mengingat hasil atau solusi inversi sangat bergantung pada pemilihan parameterisasi. Dengan kata lain, solusi tidak invarian (tidak independen) terhadap perubahan atau transformasi variabel.

Pada kasus inversi linier dengan kesalahan data yang terdistribusi normal (*Gaussian*) solusinya invarian terhadap transformasi variabel yang bersifat linier. Dengan kata lain perubahan parameterisasi data dan parameter model secara linier dapat menghasilkan solusi yang sama dengan solusi sebelum transformasi. Namun, pada banyak kasus tidak ada ketentuan yang spesifik mengenai pemilihan parameterisasi sehingga hal tersebut dapat menimbulkan masalah.

Sebagai contoh kita tinjau regresi linier terhadap pasangan data (1, 1), (2, 2), (3, 3), (4, 5) yang dianggap membentuk satu garis lurus. Jika pasangan data tersebut dianggap sebagai (x, y) dimana x adalah variabel bebas maka persamaan garis yang diperoleh adalah $y = -0.5 + 1.3x$ (Gambar 5.1a, garis penuh). Sebaliknya jika pasangan (x, y) dipertukarkan, yaitu $y' = x$ dan $x' = y$ sehingga data tersebut dianggap sebagai (x', y') dimana x' adalah variabel bebas, maka persamaan garis yang diperoleh adalah $y' = 0.309 + 0.743 x'$ (Gambar 5.1b). Penyusunan kembali hasil regresi tersebut menghasilkan $x' = -0.416 + 1.345 y'$

(Gambar 5.1a, garis putus-putus). Parameter model (kemiringan garis dan titik potong garis dengan sumbu vertikal) yang mendefinisikan kedua garis tersebut memiliki perbedaan sekitar 20%.

Salah satu penyebab perbedaan kedua solusi tersebut adalah penerapan asumsi statistik atau probabilitas yang tidak konsisten. Pada kasus pertama, x sebagai variabel bebas dianggap diketahui secara eksak, sedangkan y dianggap sebagai variabel acak (*random*) yang terdistribusi normal. Pada kasus kedua, $x' = y$ dianggap diketahui secara eksak sedangkan $y' = x$ merupakan variabel acak dengan distribusi normal. Perbedaan hasil inversi tersebut disebabkan oleh perbedaan pemilihan variabel yang mengandung kesalahan (*error*) dengan distribusi *Gaussian*.




Gambar 5.1

(a) Regresi linier pasangan data (x, y) . (b) Regresi linier pasangan data yang dipertukarkan menjadi $(x' = y, y' = x)$. Pada kedua gambar sumbu x adalah sumbu mendatar dan sumbu y adalah sumbu vertikal.

Salah satu tujuan pemilihan parameterisasi yang berbeda adalah untuk menyelesaikan permasalahan menggunakan cara-cara yang telah diketahui. Sebagai contoh adalah regresi fungsi eksponensial atau fungsi pangkat pada pasangan data (x, y) yang dianggap merepresentasikan suatu fungsi $y_i = m_1 \exp(m_2 x_i)$. Melalui transformasi variabel $m_1' =$

$\log(m_1)$, $m_2' = m_2$ dan $y_i' = \log(y_i)$, maka hubungan antara parameter model dengan data dapat dinyatakan sebagai suatu fungsi linier $y_i' = m_1' + m_2' x_i$ yang dapat diselesaikan dengan menggunakan metode regresi linier sebagaimana telah dibahas sebelumnya. Gambar 5.2 menunjukkan perbedaan solusi jika regresi dilakukan secara non-linier dan dengan linierisasi melalui transformasi variabel. Hal ini disebabkan setelah transformasi y_i' dianggap terdistribusi normal sehingga data sebelum transformasi y_i dianggap memiliki distribusi *non-Gaussian*.

Sebagaimana dibahas pada contoh sebelumnya, perbedaan asumsi mengenai distribusi statistik data (atau kesalahan data) pada kedua jenis parameterisasi dapat menyebabkan perbedaan hasil pemodelan inversi. Pemilihan parameter atau transformasi parameter untuk membuat fungsi menjadi linier harus dilakukan secara hati-hati. Penggunaan transformasi variabel pada penyelesaian masalah inversi non-linier memiliki keterbatasan. Pada sub-bab selanjutnya akan dibahas pemodelan inversi non-linier tanpa melalui transformasi variabel. Dalam hal ini penyelesaian inversi non-linier dilakukan dengan pendekatan linier.



Gambar 5.2

(a) Regresi kurva eksponensial tanpa transformasi variabel. (b) Konversi kurva regresi eksponensial pada (a) (garis utuh) yang tidak sama dengan hasil regresi garis lurus terhadap data $(x_i, \log(y_i))$ (garis putus-putus).

5.2 Inversi Non-Linier dengan Pendekatan Linier

Pada contoh yang dibahas sebelumnya, permasalahan inversi non-linier berupa regresi fungsi eksponensial dapat diselesaikan menggunakan metode inversi linier setelah melalui transformasi variabel. Hal tersebut hanya dapat dilakukan untuk pemodelan inversi non-linier sederhana dan hasilnya perlu dimaknai secara hati-hati karena menunjukkan perbedaan jika dibandingkan dengan penyelesaian inversi non-linier. Secara umum, transformasi variabel tidak selalu dapat dilakukan untuk memformulasikan kembali suatu permasalahan inversi sehingga dapat diselesaikan secara lebih mudah. Oleh karena itu diperlukan metode yang secara khusus dikembangkan untuk menyelesaikan suatu permasalahan inversi non-linier.

Elaborasi pemodelan inversi linier pada Bab-Bab sebelumnya dimaksudkan sebagai dasar bagi pembahasan pemodelan inversi non-linier. Pada prinsipnya semua formulasi yang telah digunakan untuk menyelesaikan permasalahan inversi linier dapat diperluas untuk memperoleh solusi inversi non-linier. Secara umum sebagian besar permasalahan inversi dalam geofisika adalah inversi non-linier. Meskipun demikian pada beberapa kasus, permasalahan inversi dapat dipilih atau dibuat menjadi linier ataupun non-linier bergantung pada parameterisasi model yang dipilih (lihat Bab 7 dan Bab 8 mengenai aplikasi inversi linier pada data gravitasi dan magnetik).

Sebagaimana telah dibahas sebelumnya pada Bab 2, hubungan antara data dengan parameter model secara umum dapat dinyatakan oleh persamaan berikut:

$$\mathbf{d} = \mathbf{g}(\mathbf{m}) \quad (5.1)$$

Persamaan tersebut dapat pula digunakan untuk menyatakan hubungan antara data dengan parameter model yang direpresentasikan oleh suatu fungsi non-linier. Dalam hal ini $\mathbf{g}$ adalah suatu fungsi pemodelan kedepan (*forward modeling*) yang merupakan fungsi non-linier dari parameter model. Fungsi $\mathbf{g}$ dinyatakan dalam notasi vektor untuk menyatakan adanya komponen yang berasosiasi dengan komponen data.

Misalkan solusi inversi dari persamaan (5.1) adalah model $\mathbf{m}$ yang merupakan suatu model awal $\mathbf{m}_0$ yang diperturbasi dengan $\Delta\mathbf{m}$ agar diperoleh kecocokan yang lebih baik antara respons model tersebut dengan data:

$$\mathbf{m} = \mathbf{m}_0 + \Delta\mathbf{m} \quad (5.2)$$

$$\mathbf{d} = \mathbf{g}(\mathbf{m}_0 + \Delta\mathbf{m}) \quad (5.3)$$

Jika persamaan (5.3) dituliskan kembali dalam bentuk komponennya maka diperoleh:

$$d_i = g_i(m_0^{(j)} + \delta m_j) \quad (5.4)$$

dimana $i = 1, 2, \dots, N$ dan $j = 1, 2, \dots, M$ dengan N dan M masing-masing adalah jumlah data dan jumlah parameter model.

Ekspansi Taylor orde pertama fungsi $\mathbf{g}(\mathbf{m})$ disekitar suatu model awal $\mathbf{m}_0$ dengan menggunakan notasi komponen seperti persamaan (5.3) menghasilkan:

$$g_i(m_0^{(j)} + \delta m_j) \approx g_i(m_0^{(j)}) + \left. \frac{\partial g_i}{\partial m_j} \right|_{m_0} \delta m_j + O(\delta m_j) \quad (5.5)$$

dimana $O(\delta m_j)$ adalah suku sisa yang melibatkan turunan orde ke-dua dan orde-orde lebih tinggi. Hasil substitusi persamaan (5.5) ke dalam persamaan (5.4) dengan mengabaikan suku sisa tersebut adalah sebagai berikut:

$$d_i = g_i(m_0^{(j)}) + \left. \frac{\partial g_i}{\partial m_j} \right|_{m_0} \delta m_j \quad (5.6)$$

Suku ke-dua pada ruas kanan persamaan (5.6) adalah komponen turunan parsial fungsi $\mathbf{g}(\mathbf{m})$ terhadap suatu elemen parameter model $\mathbf{m}$ yang membentuk matriks Jacobi atau *Jacobian matrix* berikut:

$$J_{ij} = \frac{\partial g_i}{\partial m_j} \quad (5.7)$$

Selanjutnya, substitusi dan pengaturan kembali persamaan (5.6) menghasilkan:

$$d_i - g_i(m_0^{(j)}) = J_{ij} \delta m_j \quad (5.8)$$

Bentuk lengkap dalam notasi matriks persamaan (5.8) adalah:

$$\mathbf{d} - \mathbf{g}(\mathbf{m}_0) = \mathbf{J}_0 \Delta\mathbf{m}_0 \quad \text{atau} \quad \Delta\mathbf{d}_0 = \mathbf{J}_0 \Delta\mathbf{m}_0 \quad (5.9)$$

dimana $\mathbf{J}_0$ adalah matriks Jacobi yang dievaluasi pada $\mathbf{m}=\mathbf{m}_0$. Dengan menganggap $\Delta\mathbf{d}_0 = \mathbf{d} - \mathbf{g}(\mathbf{m}_0)$ maka persamaan (5.9) mirip dengan persamaan yang berlaku pada hubungan linier antara data dengan parameter model, yaitu $\mathbf{d} = \mathbf{G}\mathbf{m}$. Dalam hal ini dapat dikatakan bahwa data digantikan oleh perturbasi data dan model menjadi perturbasi model. Sementara itu matriks kernel digantikan oleh matriks Jacobi yang menyatakan sejauhmana data prediksi berubah sebagai akibat dari perubahan atau perturbasi model. Oleh karena itu matriks Jacobi sering pula disebut sebagai matriks sensitivitas (*sensitivity matrix*).

Kemiripan bentuk persamaan (5.9) dengan persamaan yang menyatakan hubungan linier antara data dengan parameter model $\mathbf{d} = \mathbf{G}\mathbf{m}$ mengindikasikan hubungan linier antara $\Delta\mathbf{d}_0 = \mathbf{d} - \mathbf{g}(\mathbf{m}_0)$ dengan $\Delta\mathbf{m}_0$. Berdasarkan analogi, solusi inversi dalam bentuk $\Delta\mathbf{m}_0$ dari suatu permasalahan yang dapat dinyatakan oleh persamaan (5.9) adalah sebagai berikut:

$$\Delta\mathbf{m}_0 = [\mathbf{J}_0^T \mathbf{J}_0]^{-1} \mathbf{J}_0^T (\mathbf{d} - \mathbf{g}(\mathbf{m}_0)) \quad (5.10)$$


Persamaan (5.10) pada dasarnya menyatakan perturbasi yang diperlukan terhadap suatu model awal $\mathbf{m}_0$ agar diperoleh model yang lebih baik, yaitu $\mathbf{m} = \mathbf{m}_0 + \Delta\mathbf{m}_0$. Respons model $\mathbf{m}$ diharapkan lebih *fit* dengan data.

Mengingat sifat non-linier dari fungsi yang menghubungkan data dengan parameter model (pemodelan kedepan) maka pendekatan orde pertama tersebut tidak dapat langsung menghasilkan model optimum. Oleh karena itu proses perturbasi model dilakukan terhadap model awal $\mathbf{m}_0$ secara iteratif menggunakan persamaan (5.10) sampai diperoleh konvergensi menuju solusi optimum.

Untuk memperoleh solusi inversi atau model optimum diperlukan perturbasi secara iteratif suatu model awal $\mathbf{m}_0$. Dengan demikian pada iterasi ke-(n+1) perturbasi dilakukan terhadap model hasil iterasi sebelumnya dengan menggunakan persamaan berikut:

$$\mathbf{m}_{n+1} = \mathbf{m}_n + [\mathbf{J}_n^T \mathbf{J}_n]^{-1} \mathbf{J}_n^T (\mathbf{d} - \mathbf{g}(\mathbf{m}_n)) \quad (5.11)$$

Algoritma pemodelan inversi non-linier dengan pendekatan linier ditampilkan pada Gambar 5.3.



Gambar 5.3

Algoritma pemodelan inversi non-linier dengan pendekatan linier.

Dengan memperhatikan kemiripan bentuk persamaan (5.10) dengan solusi inversi linier pada persamaan (2.23) maka pada prinsipnya konsep yang telah di-elaborasi untuk pemodelan inversi linier dapat diterapkan pada inversi non-linier dengan pendekatan linier. Dengan demikian diperoleh varian atau bentuk-bentuk lain dari solusi inversi non-linier berdasarkan analogi dengan varian dari solusi inversi linier. Salah satu contohnya adalah pemodelan inversi non-linier berbobot yang dapat dirumuskan sebagai berikut:

$$\mathbf{m}_{n+1} = \mathbf{m}_n + [\mathbf{J}_n^T \mathbf{W}_e \mathbf{J}_n]^{-1} \mathbf{J}_n^T \mathbf{W}_e (\mathbf{d} - \mathbf{g}(\mathbf{m}_n)) \quad (5.12)$$

Berdasarkan analogi dengan inversi linier *purely under-determined* yang diselesaikan dengan meminimumkan *norm* model dan menerapkan metode pengali Lagrange (persamaan (4.13)), maka solusi inversi non-linier *purely under-determined* dinyatakan oleh persamaan berikut:

$$\mathbf{m}_{n+1} = \mathbf{m}_n + \mathbf{J}_n^T [\mathbf{J}_n \mathbf{J}_n^T]^{-1} (\mathbf{d} - \mathbf{g}(\mathbf{m}_n)) \quad (5.13)$$

Dengan cara yang sama dapat diperoleh solusi inversi non-linier teredam yang sekaligus meminimumkan kesalahan prediksi data dan *norm* model. Analog dengan persamaan (4.18) untuk inversi linier, solusi inversi non-linier *mixed-determined* adalah sebagai berikut:

$$\mathbf{m}_{n+1} = \mathbf{m}_n + [\mathbf{J}_n^T \mathbf{J}_n + \varepsilon^2 \mathbf{I}]^{-1} \mathbf{J}_n^T (\mathbf{d} - \mathbf{g}(\mathbf{m}_n)) \quad (5.14)$$

Pada prinsipnya penggunaan informasi "a priori" sebagaimana telah dibahas sebelumnya untuk penyelesaian inversi linier dapat pula dilakukan pada inversi non-linier. Solusi inversi non-linier yang memperhitungkan semua bentuk informasi "a priori" dapat diturunkan, misalnya untuk memperoleh solusi atau model dengan meminimumkan jarak terhadap model referensi dan variasi spasial parameter model.

Meskipun demikian, estimasi mengenai matriks ko-variansi model yang menyatakan ketidak-pastian atau ketelitian model inversi tidak dapat dilakukan melalui analogi dengan inversi linier. Hal ini disebabkan karena "pemetaan" kesalahan data menjadi kesalahan model pada inversi

non-linier relatif lebih rumit. Pada kasus inversi linier, jika data dan model "a priori" dianggap sebagai variabel acak dengan distribusi normal maka solusi atau model juga akan terdistribusi secara normal (*Gaussian*). Sementara itu pada inversi non-linier hal tersebut tidak berlaku.

Pada kasus inversi non-linier apapun distribusi data dan model "a priori" maka karakter statistik solusi tidak akan berupa distribusi normal. Semakin tidak linier hubungan antara data dengan parameter model maka karakter statistik solusi akan semakin jauh dari distribusi normal. Hal ini menyebabkan informasi mengenai ketidak-pastian solusi pada inversi non-linier lebih sulit diperoleh jika dibandingkan dengan inversi linier.

Selanjutnya akan dibahas beberapa variasi metode penyelesaian inversi non-linier menggunakan pendekatan linier. Pembahasan hanya mencakup beberapa metode standar, yaitu metode Newton dan Metode Gradien serta varian dari kedua metode tersebut.

5.3 Metode Newton

Metode Newton untuk penyelesaian inversi non-linier didasarkan pada prinsip yang sama dengan metode Newton untuk memperkirakan harga nol suatu fungsi $y = f(x)$. Harga nol atau akar suatu fungsi adalah harga x_0 dimana suatu fungsi non-linier berharga nol atau $y(x_0) = 0$. Dengan kata lain, solusi yang dicari adalah titik perpotongan fungsi tersebut dengan sumbu mendatar atau sumbu x .

Misalkan pada iterasi ke- n estimasi harga x_0 adalah x_n maka persamaan garis singgung kurva pada $y(x_n)$ dinyatakan oleh:

$$y(x) = a + \left(\frac{\partial y}{\partial x} \right)_{x=x_n} x \quad (5.15)$$


dimana $\partial y / \partial x$ adalah gradien atau kemiringan garis singgung di $x = x_n$ dan a adalah titik potong garis singgung tersebut terhadap sumbu vertikal (Gambar 5.4). Dengan memasukkan harga fungsi pada $x = x_n$ maka a

dapat dieliminasi sehingga diperoleh persamaan garis lurus sebagai berikut:

$$y(x) = y(x_n) + \left(\frac{\partial y}{\partial x} \right)_{x=x_n} (x - x_n) \quad (5.16)$$

Perpotongan garis lurus tersebut dengan sumbu mendatar atau sumbu x menghasilkan x_{n+1} yang merupakan estimasi baru nilai x_0 sehingga dapat dicari secara iteratif menggunakan persamaan berikut:

$$x_{n+1} = x_n - \left(\frac{\partial y}{\partial x} \right)_{x=x_n}^{-1} y(x_n) \quad (5.17)$$



Gambar 5.4

Ilustrasi metode Gauss-Newton untuk memperkirakan harga nol suatu fungsi non-linier atau perpotongan kurva dengan sumbu x yaitu pada $y(x_0) = 0$.

Pencarian harga nol suatu fungsi secara iteratif menggunakan metode Newton sebagaimana ditunjukkan oleh persamaan (5.17) dapat diterapkan pada penyelesaian permasalahan inversi non-linier. Hal ini didasarkan pada prinsip bahwa minimum fungsi obyektif E (kesalahan prediksi data) ditandai oleh turunannya terhadap parameter model $\mathbf{m}$ yang berharga nol. Dengan demikian dicari model $\mathbf{m}$ dimana $\partial E / \partial \mathbf{m} = 0$.

Pada penyelesaian inversi non-linier menggunakan metode Newton fungsi $y(x)$ pada persamaan (5.17) adalah $\partial E / \partial \mathbf{m}$ yang dicari harga nol-nya, sehingga solusi atau model inversi pada iterasi ke- $(n+1)$ dinyatakan oleh:

$$\mathbf{m}_{n+1} = \mathbf{m}_n - \left(\frac{\partial^2 E}{\partial \mathbf{m}^2} \right)_{\mathbf{m}=\mathbf{m}_n}^{-1} \left(\frac{\partial E}{\partial \mathbf{m}} \right)_{\mathbf{m}=\mathbf{m}_n} \quad (5.18)$$

Tampak bahwa dalam hal ini estimasi solusi inversi memerlukan perhitungan turunan ke-dua dari fungsi kesalahan prediksi data E yang menyatakan kecekungan (*curvature*) fungsi E .

Kesalahan prediksi data atau fungsi obyektif untuk kasus non-linier dapat ditulis sebagai berikut:

$$\begin{aligned} E &= [\mathbf{d} - \mathbf{g}(\mathbf{m})]^T [\mathbf{d} - \mathbf{g}(\mathbf{m})] \\ &= \mathbf{d}^T \mathbf{d} - 2[\mathbf{g}(\mathbf{m})]^T \mathbf{d} + [\mathbf{g}(\mathbf{m})]^T [\mathbf{g}(\mathbf{m})] \end{aligned} \quad (5.19)$$

Berdasarkan persamaan (19) tersebut, turunan pertama dan kedua fungsi E terhadap $\mathbf{m}$ masing-masing dinyatakan oleh persamaan berikut:

$$\begin{aligned} \frac{\partial E}{\partial \mathbf{m}} &= -2 \underline{\mathbf{J}}^T \mathbf{d} + 2 [\mathbf{g}(\mathbf{m})] \underline{\mathbf{J}}^T \\ &= 2 \underline{\mathbf{J}}^T (\mathbf{g}(\mathbf{m}) - \mathbf{d}) \end{aligned} \quad (5.20)$$

$$\frac{\partial^2 E}{\partial \mathbf{m}^2} = 2 \left(\underline{\mathbf{J}}^T \underline{\mathbf{J}} + \underline{\mathbf{H}}^T (\mathbf{g}(\mathbf{m}) - \mathbf{d}) \right) \quad (5.21)$$

Substitusi persamaan (5.20) dan (5.21) ke dalam persamaan (5.18) menghasilkan:

$$\mathbf{m}_{n+1} = \mathbf{m}_n - [\underline{\mathbf{J}}_n^T \underline{\mathbf{J}}_n + \underline{\mathbf{H}}_n^T (\mathbf{g}(\mathbf{m}_n) - \mathbf{d})]^{-1} \underline{\mathbf{J}}_n^T (\mathbf{g}(\mathbf{m}_n) - \mathbf{d}) \quad (5.22)$$

dimana $\underline{\mathbf{H}} = [\partial^2 g_i / \partial m_k^2]$ adalah turunan parsial orde ke-dua fungsi pemodelan kedepan terhadap setiap parameter model yang disebut sebagai matriks *Hessian*.

Pada penyelesaian inversi non-linier menggunakan pendekatan linier turunan ke-dua dari fungsi pemodelan kedepan $\mathbf{g}$ terhadap parameter model $\mathbf{m}$ diabaikan (ekspansi Taylor orde ke-dua dan orde lebih besar diabaikan). Pada metode Newton, turunan ke-dua tersebut digunakan untuk memperkirakan solusi inversi, yang tercermin pada penggunaan matriks $\underline{\mathbf{H}}$ pada persamaan (5.22). Perhitungan matriks $\underline{\mathbf{H}}$ cukup kompleks dan cenderung kurang stabil. Oleh karena itu, keberhasilan metode Newton ditentukan oleh sejauhmana kita dapat menghitung matriks $\underline{\mathbf{H}}$.

Untuk menghindari kesulitan perhitungan turunan ke-dua dari fungsi pemodelan kedepan maka suku ke-dua dari persamaan (5.21) yang mengandung matriks $\underline{\mathbf{H}}$ dianggap cukup kecil dan dapat diabaikan. Dengan kata lain, turunan kedua E terhadap parameter model $\mathbf{m}$ dapat didekati oleh suku yang hanya melibatkan turunan pertama $\mathbf{g}$ terhadap parameter model $\mathbf{m}$ (pendekatan orde pertama). Dengan demikian, persamaan (5.22) menjadi:

$$\mathbf{m}_{n+1} = \mathbf{m}_n - [\underline{\mathbf{J}}_n^T \underline{\mathbf{J}}_n]^{-1} \underline{\mathbf{J}}_n^T (\mathbf{g}(\mathbf{m}_n) - \mathbf{d}) \quad (5.23)$$

Persamaan (5.23) tersebut pada dasarnya identik dengan persamaan (5.11) yang menyatakan solusi inversi non-linier dengan pendekatan linier. Penyelesaian inversi non-linier menggunakan persamaan (5.11) atau (5.23) sering disebut pula sebagai **metode Gauss-Newton**. Kedua persamaan menyatakan bahwa model pada iterasi ke- $(n+1)$ adalah model pada iterasi sebelumnya (atau ke- n) yang di-update dengan suatu faktor koreksi. Faktor koreksi tersebut beroperasi pada selisih antara data pengamatan dengan respons model pada iterasi ke- n .

Turunan ke-dua fungsi E terhadap $\mathbf{m}$ pada persamaan (5.18) dapat pula disebut sebagai matriks *Hessian* $\underline{\mathbf{H}}^{-1}$. Pada **metode Quasi-Newton** perhitungan turunan ke-dua tersebut dilakukan melalui pendekatan. Pada iterasi pertama digunakan $\underline{\mathbf{H}}^{-1} = \underline{\mathbf{I}}$. Selanjutnya estimasi $\underline{\mathbf{H}}^{-1}$ di-update berdasarkan harga-harga gradien fungsi E yang telah diperoleh selama proses iterasi. Terdapat banyak alternatif skema pendekatan terhadap $\underline{\mathbf{H}}^{-1}$ dan detilnya tidak dibahas pada buku ini.

5.4 Metode Gradien

Gradien suatu fungsi menyatakan arah peningkatan terbesar fungsi tersebut (*steepest ascent*) sehingga arah yang berlawanan atau harga negatif dari gradien bersesuaian dengan penurunan harga fungsi (*steepest descent*). Pada metode gradien atau sering disebut pula sebagai **metode *steepest descent***, model pada setiap iterasi dikoreksi dalam arah negatif dari gradien fungsi obyektif E sehingga pada iterasi ke- n perturbasi model dinyatakan oleh:

$$\Delta \mathbf{m}_n = -k \left[\frac{\partial E}{\partial \mathbf{m}} \right]_{\mathbf{m}=\mathbf{m}_n} \quad (5.24)$$

Dengan substitusi persamaan (5.20) ke persamaan (5.24) dan menguraikan $\Delta \mathbf{m}_n = [\mathbf{m}_{n+1} - \mathbf{m}_n]$ maka diperoleh model pada iterasi ke- $(n+1)$ sebagai berikut:

$$\mathbf{m}_{n+1} = \mathbf{m}_n - 2k \left(\mathbf{J}_n^T (\mathbf{g}(\mathbf{m}_n) - \mathbf{d}) \right) \quad (5.25)$$

dimana k adalah konstanta yang menentukan sejauhmana koreksi dilakukan dalam arah *steepest descent*. Penentuan faktor k yang disebut sebagai *step size* umumnya dilakukan secara coba-coba seperti penentuan faktor redaman ϵ^2 pada inversi linier ter-redam. Jika faktor $2k$ diganti dengan $[\mathbf{J}_n^T \mathbf{J}_n]^{-1}$ maka metode gradien menjadi metode Gauss-Newton sebagaimana dinyatakan oleh persamaan (5.11) dan (5.23).

Metode gradien sangat lamban jika dibandingkan dengan metode Gauss-Newton, terutama jika sudah dekat dengan solusi atau nilai minimum fungsi obyektif. Hal ini disebabkan oleh harga gradien yang semakin kecil. Di lain pihak, metode gradien cukup efektif pada saat awal iterasi dimana metode Gauss-Newton dapat mengalami *overshoot*. Oleh karena itu kombinasi yang tepat antara kedua metode dapat memperbaiki kinerja tiap metode yang diterapkan secara terpisah. Kombinasi dilakukan dengan menerapkan metode gradien pada saat awal iterasi yaitu saat masih jauh dari solusi, kemudian semakin dekat dengan solusi digunakan metode quasi-Newton. Metode kombinasi tersebut dikenal sebagai **metode Levenberg-Marquardt**.

Metode Levenberg-Marquardt pada dasarnya identik dengan metode inversi non-linier ter-redam yang dinyatakan oleh:

$$\mathbf{m}_{n+1} = \mathbf{m}_n + [\mathbf{J}_n^T \mathbf{J}_n + \epsilon^2 \mathbf{I}]^{-1} \mathbf{J}_n^T (\mathbf{d} - \mathbf{g}(\mathbf{m}_n)) \quad (5.14)$$

Secara garis besar tahapannya adalah sebagai berikut. Pada saat iterasi awal digunakan faktor redaman ϵ^2 yang cukup besar sehingga elemen diagonal menjadi dominan. Hal tersebut pada dasarnya adalah metode gradien dengan $2k = \epsilon^2$. Jika perturbasi model menghasilkan fungsi obyektif yang lebih rendah berarti mendekati solusi dan ϵ^2 diperkecil sehingga langkah berikutnya adalah langkah metode Gauss-Newton. Sebaliknya, jika fungsi obyektif meningkat maka ϵ^2 diperbesar agar metode gradien kembali diterapkan. Dalam hal konvergensi, metode Levenberg-Marquardt relatif lebih baik, namun metode tersebut masih tetap memiliki kelemahan-kelemahan yang dimiliki pendekatan linier terhadap masalah inversi non-linier yang akan dibahas kemudian.


Sebenarnya masih banyak varian dari teknik atau metode yang dapat digunakan untuk menyelesaikan permasalahan inversi non-linier. Pembahasan pada buku ini hanya bersifat *overview* sehingga detil dari setiap metode diserahkan sebagai bagian dari studi literatur dan latihan. Metode-metode tersebut umumnya didasarkan pada teknik eksplorasi "ruang model" yang secara matematis merupakan ruang berdimensi M , dimana M adalah jumlah parameter model. Efektivitas pencarian nilai fungsi obyektif $E(\mathbf{m})$ di ruang multi-dimensi tersebut menentukan sejauhmana kita dapat memperoleh solusi optimum inversi non-linier.

5.5 Keterbatasan Pendekatan Linier

Salah satu keterbatasan pendekatan linier pada inversi non-linier menggunakan metode Gauss-Newton, metode Gradien maupun varian lainnya adalah sensitivitasnya terhadap pemilihan model awal. Model awal yang berbeda dapat menghasilkan solusi yang berbeda, yang belum tentu merupakan solusi optimum. Untuk memperoleh solusi optimum maka model awal harus cukup dekat dengan model yang dicari. Hal ini tentu saja seolah-olah merupakan paradoks.

Keterbatasan lain dari pendekatan linier pada inversi non-linier adalah kemungkinan terjebak pada nilai minimum lokal dari fungsi obyektif, sementara model optimum berasosiasi dengan minimum global. Fungsi obyektif dari permasalahan inversi non-linier umumnya sangat kompleks dan memiliki banyak nilai minimum. Semakin tidak linier fungsi pemodelan kedepan maka semakin kompleks pula bentuk "topografi" fungsi obyektifnya. Hal tersebut menyebabkan iterasi pada pendekatan linier (lokal) dapat terjebak pada minimum lokal dan bukan minimum global yang dicari (Gambar 5.5).

Kedua keterbatasan tersebut di atas pada dasarnya saling berkaitan. Pendekatan linier dari suatu fungsi non-linier sebenarnya hanya berlaku di sekitar suatu model tertentu (model awal). Salah satu cara untuk mengatasinya adalah dengan menggunakan semaksimal mungkin informasi "a priori" yang tersedia untuk menentukan model awal yang baik. Selain itu inversi dapat dilakukan menggunakan beberapa model awal yang berbeda untuk mencari konsistensi konvergensi ke model tertentu yang dapat dianggap sebagai solusi atau model optimum.



Gambar 5.5

Ilustrasi kurva fungsi obyektif dengan banyak minimum lokal namun hanya satu minimum global sehingga terdapat solusi yang unik (kiri). Kurva fungsi obyektif dengan banyak minimum yang hampir identik sehingga solusi tidak unik (kanan). Pendekatan linier dapat terjebak pada semua minimum yang terdapat pada kurva fungsi obyektif tersebut.

Sebagaimana pada inversi linier, permasalahan eksistensi invers matriks $[\underline{\mathbf{J}}^T \underline{\mathbf{J}}]$ juga dapat menimbulkan kesulitan pencarian solusi jika matriks tersebut adalah matriks singular atau mendekati singular. Jika $[\underline{\mathbf{J}}^T \underline{\mathbf{J}}]$ mendekati singular maka nilai *eigen*-nya menjadi sangat kecil atau mendekati nol sehingga menghasilkan solusi yang sangat besar. Dalam hal ini dikatakan bahwa solusi telah melampaui daerah liniernya (*overshoot*). Meskipun matriks $[\underline{\mathbf{J}}^T \underline{\mathbf{J}}]$ bukan matriks singular, iterasi tetap saja dapat divergen atau konvergen dengan sangat lamban. Inversi matriks yang lebih stabil dapat dilakukan dengan menerapkan metode *Singular Value Decomposition* atau SVD. Pembahasan lengkap mengenai metode SVD dapat dilihat pada buku teks standar, antara lain Press dkk. (1987).

*There is no comparison between that which is lost
by not succeeding and that which is lost by not trying.*

- Francis Bacon

6.1 Pencarian Sistematis

Metode inversi non-linier melalui linierisasi atau pendekatan linier termasuk dalam kelompok metode yang sering disebut sebagai pendekatan lokal (*local search approach*). Hal ini mengingat pencarian solusi dilakukan hanya berdasarkan informasi mengenai kecenderungan fungsi obyektif di sekitar model yang sedang ditinjau (model awal atau model hasil modifikasi pada suatu iterasi tertentu). Informasi tersebut umumnya hanya berupa gradien fungsi obyektif yang dapat memberikan petunjuk ke arah mana solusi atau model dengan nilai fungsi obyektif minimum kemungkinan besar berada.

Dalam pendekatan linier, perhitungan gradien fungsi obyektif hanya melibatkan turunan orde pertama dengan mengabaikan suku-suku orde lebih tinggi (orde-2 atau lebih). Hal tersebut dapat menimbulkan masalah konvergensi. Penyelesaian inversi non-linier dengan pendekatan linier memerlukan model awal yang sudah cukup dekat dengan solusi. Untuk itu informasi "a priori" dalam bentuk model awal yang baik sangat diperlukan. Solusi inversi dapat konvergen menuju ke minimum lokal yang bukan solusi optimum. Dengan kata lain, pendekatan linier suatu permasalahan inversi non-linier sering kurang memadai.

Fungsi obyektif non-linier dapat memiliki minimum lebih dari satu dimana hampir semua nilai minimum tersebut hanya bersifat minimum lokal, bukan minimum global yang diharapkan. Semakin tidak linier

suatu fungsi dan semakin banyak jumlah parameter model, maka semakin kompleks bentuk fungsi obyektifnya. Dalam konteks inversi, fungsi obyektif sering digambarkan secara matematis sebagai suatu "permukaan" pada ruang berdimensi M yang disebut ruang model, di mana M adalah jumlah parameter model. Oleh karena itu pencarian nilai minimum yang hanya didasarkan pada informasi lokal di sekitar suatu model tertentu dapat terjebak ke dalam nilai minimum lokal dan solusi atau model inversi yang dihasilkan bukan model optimum.

Untuk mengatasi kelemahan metode inversi non-linier yang menggunakan pendekatan linier tersebut maka diperlukan pengetahuan lebih menyeluruh atau global mengenai bentuk permukaan fungsi obyektif. Hal ini dapat dilakukan dengan menggunakan metode yang tidak memerlukan perhitungan gradien fungsi obyektif melainkan melalui evaluasi fungsi obyektif itu sendiri. Beberapa teknik penyelesaian inversi non-linier yang tidak menggunakan pendekatan linier termasuk dalam kategori pendekatan atau pencarian global (*global search approach*).

Salah satu cara untuk memperoleh solusi inversi non-linier menggunakan pendekatan global adalah dengan mengevaluasi secara sistematis (*systematic search*) harga fungsi obyektif untuk setiap model pada ruang model. Untuk itu ruang model didefinisikan terlebih dulu dengan menentukan secara "a priori" interval atau batas minimum dan maksimum harga setiap parameter model yang mungkin. Kemudian dilakukan diskretisasi pada interval tersebut sehingga diperoleh grid yang meliputi seluruh ruang model yang telah didefinisikan. Grid yang dibuat pada ruang model dapat saja tidak homogen, bergantung resolusi yang diinginkan untuk masing-masing parameter model.

Pada metode pencarian sistematis setiap grid merepresentasikan satu sampel model yang harus dihitung responsnya untuk memperoleh harga fungsi obyektif yang berasosiasi dengan model tersebut. Oleh karena itu teknik pencarian sistematis seperti ini sering disebut pula sebagai teknik *grid search*. Informasi mengenai harga fungsi obyektif untuk semua grid pada ruang model dapat digunakan untuk menentukan solusi, yaitu model dengan harga fungsi obyektif minimum.

Evaluasi secara sistematis fungsi obyektif untuk setiap sampel model pada ruang model merupakan cara yang paling mudah untuk memperoleh solusi inversi non-linier. Perhitungan fungsi obyektif pada dasarnya hanya merupakan perhitungan pemodelan kedepan (*forward modeling*). Cara tersebut juga tidak memerlukan perhitungan gradien atau turunan fungsi obyektif, sehingga inversi diselesaikan benar-benar secara non-linier tanpa pendekatan linier atau linierisasi. Namun pencarian solusi secara sistematis sangat tidak efisien mengingat banyaknya perhitungan pemodelan kedepan yang harus dilakukan untuk mengevaluasi fungsi obyektif.

Pemodelan data geofisika umumnya memerlukan representasi model dengan jumlah parameter model yang cukup besar. Selain itu, untuk memperoleh resolusi yang baik diperlukan diskretisasi ruang model yang cukup kecil sehingga jumlah model yang harus dievaluasi menjadi sangat besar. Oleh karena itu pencarian sistematis hampir tidak mungkin diterapkan pada permasalahan geofisika yang sebenarnya. Meskipun demikian, untuk masalah yang relatif sederhana dengan jumlah parameter yang tidak terlalu banyak dan diskretisasi yang tidak terlalu kecil, teknik pencarian sistematis dapat dilaksanakan dengan relatif mudah.

Berikut ini dibahas contoh inversi non-linier sederhana dengan menggunakan metode pencarian sistematis. Permasalahan inversinya adalah menentukan posisi pusat gempa di permukaan bumi atau episenter gempa (x_0, y_0) berdasarkan data waktu tiba gelombang gempa (t_i) di N stasiun pencatat gempa masing-masing dengan posisi (x_{si}, y_{si}), dimana $i = 1, \dots, N$. Kecepatan gelombang P (V_p) konstan dan waktu terjadinya gempa (*origin time*) t_0 diketahui.

Fungsi pemodelan kedepan untuk memperoleh data perhitungan waktu tiba t_i^{cal} untuk suatu model atau posisi episenter gempa (x_0, y_0) tertentu pada dasarnya adalah perhitungan waktu tempuh (*travel time*) yang ditambah dengan waktu terjadinya gempa dan dinyatakan sebagai:

$$t_i^{\text{cal}} = t_0 + \frac{\sqrt{(x_{si} - x_0)^2 + (y_{si} - y_0)^2}}{V_p}; i = 1, \dots, N \quad (6.1)$$

Fungsi obyektif didefinisikan sebagai jumlah kuadrat kesalahan prediksi data yang menyatakan selisih antara data pengamatan dengan data perhitungan untuk suatu model tertentu:

$$E = \sum_{i=1}^N (t_i^{\text{cal}} - t_i)^2 \quad (6.2)$$

Agar fungsi obyektif memiliki arti yang lebih jelas dalam satuan yang sama dengan data (detik) maka fungsi obyektif dapat didefinisikan sebagai besaran *root mean square error* (E_{RMS}) dengan persamaan berikut:

$$E_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (t_i^{\text{cal}} - t_i)^2} \quad (6.3)$$

Misalkan disimulasikan suatu kejadian gempa pada posisi (x_0, y_0) = (40, 30) dengan $V_p = 4$ km/detik dan $t_0 = 10:00:00$ WIB. Selanjutnya waktu tiba gelombang P di empat stasiun pengamat gempa dapat dihitung menggunakan persamaan (6.1). Hasilnya adalah data sintetik yang selanjutnya dianggap sebagai data pengamatan t_i^{obs} (Tabel 6.1).

Tabel 6.1

Koordinat posisi stasiun gempa dan waktu tiba gelombang P.

stasiun	posisi (xs, ys)	waktu tiba (t_i)	waktu tempuh (detik)
1	20, 10	10:00:07.1	7.1
2	50, 25	10:00:01.8	1.8
3	40, 50	10:00:05.0	5.0
4	10, 40	10:00:07.9	7.9

Untuk menghasilkan data sintetik yang lebih realistis biasanya ditambahkan *noise* secara acak dengan distribusi *uniform* atau normal (*Gaussian*). Misalkan diinginkan *noise* terdistribusi secara *uniform* dalam interval $\pm x$ dimana x dalam satuan yang sama dengan data, misalkan $x =$

0.1 detik pada kasus data sintetik waktu tempuh gelombang gempa. Untuk itu dibangkitkan bilangan acak yang terdistribusi secara *uniform* dalam interval 0 dan 1 menggunakan fungsi yang terdapat pada bahasa pemrograman, misalkan hasilnya adalah R . Data yang sudah terkontaminasi dengan *noise* adalah:

$$t_i^* = t_i^{\text{cal}} + (1 - 2R)x \quad (6.4)$$

Jika yang diinginkan adalah *Gaussian noise* maka dibangkitkan bilangan acak R_N yang terdistribusi secara normal dengan harga rata-rata 0.0 dan standar deviasi 1.0 (artinya R_N dapat berharga positif maupun negatif di sekitar nol). Data yang sudah terkontaminasi dengan *Gaussian noise* dapat dihitung dengan menggunakan persamaan:

$$t_i^* = t_i^{\text{cal}} + R_N x \quad (6.5)$$


Alternatif lain adalah *noise* yang ditambahkan berupa fraksi atau prosentase dari harga data, misalkan $y = 10\%$ namun tetap terdistribusi normal. Data sintetik yang telah ditambah *noise* dapat dihitung menggunakan persamaan berikut:

$$t_i^* = (1 + R_N y) t_i^{\text{cal}} \quad (6.6)$$

Data sintetik pada Tabel 6.1 dianggap telah mengandung *noise*. Selanjutnya dihitung fungsi obyektif atau E_{RMS} pada setiap grid berukuran 5 km dalam interval 0 – 60 km (yang ditentukan secara "a priori") pada sumbu x dan sumbu y . Dengan demikian diperlukan perhitungan *forward modeling* untuk $13 \times 13 = 169$ model. Hasil perhitungan E_{RMS} pada setiap grid diplot dan dibuat kontur (Gambar 6.1). Tampak bahwa harga minimum fungsi obyektif dapat diidentifikasi dari kontur 0.5 detik dimana solusi atau posisi pusat gempa dapat diperkirakan. Solusi tersebut hanya berjarak kurang dari 2 km dari posisi episenter gempa atau model sintetik, yaitu titik (40, 30).

Mengingat fungsi obyektif dihitung secara sistematis untuk setiap grid atau sampel dalam ruang model yang telah didefinisikan maka kesalahan solusi dapat diperkirakan secara langsung dari pola kontur

fungsi obyektif tersebut. Dengan asumsi kesalahan data sebesar 0.5 detik maka kesalahan model hasil inversi berkisar ± 2 km. Pada kasus ini hubungan antara data dengan parameter model hampir linier dan fungsi obyektif hanya memiliki satu harga minimum yang tampak dari pola kontur harga-harga E_{RMS} .



Gambar 6.1

Hasil perhitungan fungsi obyektif yang dinyatakan oleh kesalahan rata-rata (E_{RMS}) pada setiap grid 5 km $\times$ 5 km, interval kontur 0.5 detik. Posisi episenter gempa yang sebenarnya diplot beserta estimasi kesalahan posisi ± 2 km.

6.2 Pencarian Acak

Pencarian solusi secara sistematis pada ruang model sangat tidak efisien mengingat jumlah model yang harus di-evaluasi *misfit*-nya sangat besar, terutama jika jumlah parameter model juga cukup besar. Selain itu jika diinginkan resolusi yang tinggi maka harus dilakukan diskretisasi ruang model menjadi grid dengan ukuran cukup kecil. Hal tersebut akan meningkatkan jumlah sampel model yang harus di-evaluasi. Demikian

pula dengan fungsi pemodelan kedepan yang dapat berupa fungsi non-linier yang sangat kompleks sehingga perhitungannya membutuhkan waktu yang cukup lama.


Pada metode pencarian global, pola fungsi obyektif sebenarnya dapat diperkirakan berdasarkan harga fungsi obyektif pada beberapa sampel model yang dipilih secara acak (*random*) dari ruang model. Jumlah sampel model yang digunakan jauh lebih sedikit dibandingkan jumlah sampel model pada metode pencarian sistematis. Dengan demikian pendekatan tersebut dapat meningkatkan efisiensi metode pencarian sistematis. Selanjutnya dilakukan semacam interpolasi untuk memperoleh bentuk "permukaan" fungsi obyektif secara lebih menyeluruh. Perkiraan solusi inversi non-linier dapat dilakukan seperti pada metode pencarian sistematis, yaitu secara langsung dari nilai minimum fungsi obyektif.

Pemilihan model pada metode pencarian acak (*random search*) sesuai namanya dilakukan secara acak. Setiap model dalam ruang model memiliki peluang yang sama untuk dipilih sebagai sampel model. Bilangan acak dibangkitkan dengan probabilitas *uniform* antara 0 dan 1 yang kemudian dipetakan pada interval harga parameter model. Perhitungan pemodelan kedepan dilakukan untuk model yang terpilih yang jumlahnya tidak terlalu besar jika dibandingkan dengan jumlah keseluruhan model yang mungkin pada ruang model. Metode ini sering disebut sebagai **metode Monte-Carlo** karena mengambil analogi dengan perjudian yang umumnya bersifat acak.

Gambar 6.2 memperlihatkan kontur fungsi obyektif hasil interpolasi dari 50 titik atau sampel model yang tersebar secara acak pada grid 5×5 km. Pemilihan model hanya dilakukan pada grid tersebut dimaksudkan agar penyebarannya lebih merata (tidak terkonsentrasi di sekitar daerah tertentu saja). Model yang dipilih tersebar secara hampir merata di seluruh ruang model sehingga dapat menggambarkan pola permukaan fungsi obyektif dengan baik.

Pola kontur fungsi obyektif yang diperoleh dari sampel model pada grid acak (Gambar 6.2) dan grid sistematis (Gambar 6.1) tidak jauh

berbeda. Demikian pula dengan solusi yang diperoleh. Jika titik tengah kontur 1.0 detik dianggap sebagai model hasil inversi maka solusi tersebut hanya berbeda sekitar 4 km dari model sistetik. Hal tersebut memberikan gambaran peningkatan efisiensi pada metode pencarian acak dibandingkan terhadap metode pencarian sistematis.



Gambar 6.2

Kontur fungsi obyektif hasil interpolasi dari 50 titik yang tersebar secara acak pada grid 5×5 km, interval kontur 0.5 detik. Posisi episenter gempa yang sebenarnya diplot beserta estimasi kesalahan posisi ± 2 km.

Dalam hal penentuan episenter gempa, pencarian sistematis maupun acak dapat diperluas untuk jumlah parameter lebih besar, misalnya jika kedalaman gempa (z_0), kecepatan gelombang gempa (V_p) dan *origin time* (t_0) juga merupakan parameter model yang dicari. Namun pola permukaan fungsi obyektif akan lebih sulit digambarkan secara visual untuk jumlah parameter model lebih dari dua. Waktu perhitungan fungsi *misfit* juga tentu akan lebih lama. Untuk itu diperlukan penentuan solusi atau model optimal yang tidak didasarkan pada evaluasi visual.

Jika jumlah parameter model adalah M dan setiap parameter didiskretisasi secara homogen menjadi N harga maka jumlah model yg mungkin dalam ruang model menjadi N^M . Pada metode Monte-Carlo, jumlah sampel model acak yang harus digunakan berkorelasi dengan jumlah model yang mungkin tersebut (N^M) agar diperoleh ketelitian solusi yang memadai.

6.3 Metode *Guided Random Search*

Simulated Annealing

Tujuan utama metode inversi umumnya bukan untuk mengetahui secara keseluruhan bentuk permukaan fungsi obyektif pada ruang model, melainkan mencari nilai minimum. Nilai minimum yang dicari adalah minimum global dari fungsi obyektif yang berasosiasi dengan model optimum. Untuk menghindari konvergensi solusi ke minimum lokal maka digunakan metode pencarian global yang dapat memberikan gambaran lebih menyeluruh mengenai bentuk permukaan fungsi obyektif, diantaranya dengan metode pencarian sistematis maupun pencarian acak.

Pencarian solusi secara acak kurang efisien mengingat jumlah model yang harus di-evaluasi masih cukup besar. Pemilihan model secara acak murni (*purely random*) menyebabkan semua model dalam ruang model memiliki probabilitas yang sama untuk dipilih sebagai sampel dalam perhitungan fungsi obyektif. Model pada daerah yang jauh dari solusi juga harus dihitung responsnya. Untuk meningkatkan efisiensi pencarian acak, pemilihan model dimodifikasi sehingga model pada daerah tertentu yang mengarah atau dekat dengan solusi memiliki probabilitas lebih besar untuk dipilih. Metode semacam ini disebut sebagai metode *guided random search*.

Salah satu metode *guided random search* atau pencarian acak terarah adalah metode *Simulated Annealing* (SA). Metode *Simulated Annealing* dalam inversi didasarkan pada analogi dengan proses termodinamika pembentukan kristal suatu substansi. Pada temperatur tinggi suatu substansi berbentuk cair, kemudian proses pendinginan

secara perlahan-lahan menyebabkan terbentuknya kristal yang berasosiasi dengan energi sistem yang minimum. Probabilitas Boltzmann menyatakan hubungan antara probabilitas suatu sistem pada konfigurasi $\mathbf{m}$ dan temperatur T dengan energi E sebagai fungsi dari konfigurasi tersebut:

$$P(\mathbf{m}) \propto \exp(-E(\mathbf{m})/kT) \quad (6.7)$$

dimana k adalah konstanta Boltzmann dan konfigurasi sistem dinyatakan oleh M parameter yaitu $\mathbf{m} = (m_1, m_2, \dots, m_M)$.

Menurut persamaan (6.7) pada temperatur tinggi sistem dapat mengalami perubahan konfigurasi dan perturbasi yang menghasilkan konfigurasi dengan energi rendah memiliki probabilitas lebih besar. Meskipun demikian, perturbasi yang menghasilkan konfigurasi dengan energi tinggi masih dimungkinkan (probabilitas tidak nol). Pada saat temperatur menurun, perturbasi yang menghasilkan konfigurasi dengan energi lebih rendah memiliki probabilitas makin besar, sedangkan perturbasi yang menghasilkan konfigurasi dengan energi lebih tinggi probabilitasnya makin kecil. Pada T mendekati 0 terbentuk kristal yaitu konfigurasi dengan energi minimum. Jika proses pendinginan terlalu cepat maka kondisi kesetimbangan dengan energi minimum tidak dapat dicapai sehingga terbentuk poli-kristal atau gelas yang bersifat amorf.

Proses pembentukan kristal (*annealing*) dalam termodinamika diadopsi dalam penyelesaian masalah inversi, yaitu dengan menggunakan parameter model $\mathbf{m}$ untuk mendefinisikan konfigurasi sistem dan fungsi obyektif (*misfit*) E sebagai energi. Dalam hal inversi, T merupakan faktor pengontrol yang tetap disebut sebagai "temperatur" meskipun tidak memiliki arti fisis sebagaimana pada proses *annealing*. Dalam hal ini satuan T sama dengan satuan fungsi obyektif dan dipilih $k = 1$.

Perturbasi model dengan mekanisme *simulated annealing* dimaksudkan untuk mengeksplorasi ruang model secara acak namun lebih terarah. Beberapa algoritma yang dapat digunakan untuk mengimplementasikan metode *Simulated Annealing* pada inversi non-linier antara lain adalah algoritma Metropolis, algoritma *heat bath*, algoritma rantai Markov (*Markov Chains*) dan lain lain. Dalam buku ini

hanya akan dibahas algoritma Metropolis sederhana yang pada dasarnya terdiri dari dua langkah, yaitu perturbasi model dan penentuan diterima atau tidaknya perturbasi model tersebut.

Sebagaimana pada pencarian sistematis dan pencarian acak, ruang model harus didefinisikan terlebih dahulu dengan menentukan secara "a priori" interval harga minimum dan maksimum parameter model $[m_i^{\min}, m_i^{\max}]$, $i = 1, 2, \dots, M$ dimana M adalah jumlah parameter model. Interval tersebut tidak perlu sama untuk setiap elemen parameter model. Perturbasi atau pemilihan harga parameter model m_i ditentukan secara acak sebagai bilangan sebarang dalam interval $m_i^{\min} < m_i < m_i^{\max}$. Caranya adalah mengambil bilangan acak R dengan probabilitas *uniform* antara 0 dan 1 yang dipetakan menjadi harga parameter model menggunakan persamaan berikut:

$$m_i = m_i^{\min} + R(m_i^{\max} - m_i^{\min}) \quad (6.8)$$

Penggunaan persamaan (6.8) di atas untuk perturbasi model atau menentukan harga parameter model menghasilkan bilangan kontinu dalam interval $m_i^{\min} < m_i < m_i^{\max}$. Alternatif mekanisme perturbasi yang lain adalah memilih secara acak harga diskret dalam interval $[m_i^{\min}, m_i^{\max}]$. Contohnya seperti pada penentuan episenter gempa dengan pemilihan parameter model secara acak pada grid dengan spasi tertentu (lihat sub-Bab 6.2). Misalnya interval $[m_i^{\min}, m_i^{\max}]$ terbagi menjadi L sub-interval, yaitu $[m_i^1, m_i^2, \dots, m_i^L]$. Parameter model ditentukan dengan mengambil bilangan acak R dengan probabilitas *uniform* antara 0 dan 1 yang dipetakan menjadi bilangan bulat antara 1 dan L . Bilangan bulat tersebut menjadi indeks dari m_i yang terpilih sebagai harga parameter model.

Sebagaimana batas harga minimum dan maksimum dapat berbeda untuk setiap parameter model, maka jumlah sub-interval tersebut dapat pula berbeda untuk setiap parameter model. Hal tersebut dimaksudkan untuk menentukan resolusi masing-masing parameter model dalam penyelesaian inversi. Dengan demikian jumlah sub-interval L memiliki indeks sesuai elemen atau indeks parameter model, L_i .

Pada suatu iterasi ke- n perturbasi model menghasilkan perubahan fungsi obyektif atau perubahan *misfit* ΔE dimana $\Delta E = E_n - E_{n-1}$. Terdapat dua kemungkinan harga ΔE yang dihasilkan, yaitu $\Delta E \leq 0$ atau $\Delta E > 0$ yang akan menentukan penerimaan atau penolakan hasil perturbasi.

Jika $\Delta E \leq 0$ berarti perturbasi model menghasilkan *misfit* yang lebih kecil dari (atau sama dengan) sebelumnya. Artinya perturbasi menghasilkan model yang lebih baik dari (atau sama dengan) model sebelumnya. Pada kasus ini perturbasi model selalu diterima dan iterasi dilanjutkan dengan menggunakan model hasil perturbasi tersebut. Mekanisme ini memungkinkan pencarian model dengan *misfit* yang makin rendah.

Jika $\Delta E > 0$ berarti perturbasi model menghasilkan *misfit* yang lebih besar dari pada sebelumnya. Perturbasi model tersebut diterima dengan probabilitas yang dirumuskan oleh persamaan berikut:


$$P(\Delta E) = \exp(-\Delta E/kT) \quad (6.9)$$

Pada kasus ini $0 < P(\Delta E) < 1$ dan mekanisme penentuan hasil perturbasi diterima dengan probabilitas $P(\Delta E)$ diperlihatkan pada Gambar 6.3. Untuk suatu bilangan acak R dengan distribusi *uniform* pada interval $[0, 1]$ jika $R \leq P(\Delta E)$ maka perturbasi model diterima, jika $R > P(\Delta E)$ maka perturbasi model ditolak. Jika hasil perturbasi model ditolak maka model dikembalikan ke model sebelum dilakukan perturbasi. Iterasi dilanjutkan dengan model tersebut. Mekanisme probabilistik yang memungkinkan perturbasi model diterima meskipun *misfit*-nya lebih besar dimaksudkan untuk menghindari terjebaknya proses iterasi pada minimum lokal.

Secara umum untuk harga T tertentu dan $\Delta E > 0$, jika ΔE kecil maka probabilitas $P(\Delta E)$ besar sehingga hasil perturbasi model memiliki kemungkinan lebih besar untuk diterima. Sebaliknya jika ΔE besar maka probabilitas $P(\Delta E)$ kecil sehingga hasil perturbasi model memiliki kemungkinan kecil untuk diterima (atau hasil perturbasi model memiliki kemungkinan besar untuk ditolak). Artinya perturbasi model yang menghasilkan *misfit* sedikit lebih besar lebih mungkin diterima.

Proses iteratif dimulai dengan faktor temperatur T cukup tinggi sehingga hampir semua perturbasi model akan diterima karena berapapun harga ΔE jika $\Delta E > 0$ maka harga $P(\Delta E)$ akan cukup besar (Gambar 6.3a). Pada fase ini dapat dikatakan bahwa pencarian model dilakukan secara hampir acak murni. Pada saat temperatur turun secara perlahan, perturbasi yang menghasilkan fungsi obyektif yang lebih kecil ($\Delta E < 0$) akan lebih dominan dalam menentukan model.

Meskipun demikian, perubahan model yang menghasilkan fungsi obyektif yang lebih besar dibanding sebelumnya atau $\Delta E > 0$ tetap memiliki kemungkinan untuk diterima terutama jika harga ΔE tidak terlalu besar (atau $P(\Delta E)$ tidak terlalu kecil). Artinya perturbasi yang menjauhi suatu solusi yang sementara dianggap optimum tetap memiliki kemungkinan untuk diterima meskipun probabilitasnya kecil (Gambar 6.3b). Solusi optimum sementara tersebut kemungkinan berasosiasi dengan minimum lokal (*near optimum solution*) dan bukan minimum global. Mekanisme ini memungkinkan algoritma menghindari atau keluar dari minimum lokal.




Gambar 6.3

Ilustrasi mekanisme pemilihan dua alternatif berdasarkan bobot probabilitas untuk dua harga $P(\Delta E)$ yang berbeda.

- (a) Jika probabilitas $P(\Delta E)$ besar maka bilangan random R memiliki kemungkinan lebih besar berada pada posisi R_1 dan model diterima.
- (b) Jika probabilitas $P(\Delta E)$ kecil maka bilangan random R memiliki kemungkinan lebih besar berada pada posisi R_2 dan model ditolak.

Pada saat faktor temperatur T semakin kecil, perubahan model dengan $\Delta E \geq 0$ selalu menghasilkan $P(\Delta E)$ yang kecil sehingga perturbasi hampir selalu ditolak karena R hampir selalu lebih besar dari $P(\Delta E)$. Dengan asumsi bahwa faktor temperatur turun T secara sangat perlahan dan untuk setiap harga T dilakukan perturbasi model dengan jumlah yang cukup besar maka algoritma akan konvergen menuju minimum global.

Algoritma *Simulated Annealing* secara garis besar diperlihatkan pada Gambar 6.4. Sebagaimana telah dijelaskan, algoritma tersebut merupakan algoritma Metropolis sederhana. Perbedaan diantara varian lain dari metode *Simulated Annealing* terutama menyangkut mekanisme perturbasi model dan penentuan keputusan apakah suatu perturbasi model diterima atau ditolak.



Gambar 6.4

Algoritma *Simulated Annealing* sederhana untuk inversi non-linier.

Mekanisme penurunan temperatur merupakan salah satu faktor yang harus dicoba-coba (*tuning*) agar sesuai dengan permasalahan yang ditinjau. Penurunan temperatur tidak boleh terlalu cepat karena akan menyebabkan proses mudah terjebak pada minimum lokal. Sebaliknya, penurunan temperatur yang terlalu lamban akan membutuhkan waktu yang lama menuju konvergensi. Skema penurunan temperatur secara logaritmik dan geometrik dirumuskan sebagai berikut:

$$T_n = T_0 / \log(n) \quad (6.10a)$$


$$T_n = \alpha T_{n-1} \text{ atau } T_n = T_0 \alpha^n \quad (6.10b)$$

dimana T_0 adalah temperatur awal, n adalah iterasi dan α adalah faktor penurunan temperatur. Harga α harus dipilih kurang dari 1, biasanya antara 0.9 sampai 0.99.

Gambar 6.5 memperlihatkan beberapa kurva skema penurunan temperatur sebagai fungsi dari iterasi berdasarkan persamaan (6.10) dengan $T_0 = 5$. Tampak bahwa penurunan temperatur secara logaritmik relatif lebih cepat pada awal iterasi dan kemudian secara asimtotik menuju suatu harga yang hampir konstan. Penurunan temperatur secara geometrik lebih perlahan pada awal iterasi dan kemudian dengan relatif cepat mendekati harga sangat kecil atau menuju nol.

Faktor lain yang harus disesuaikan dengan permasalahan yang ditinjau adalah mekanisme perturbasi model. Parameter model yang di-update dipilih secara deterministik berurutan dari satu parameter model ke parameter model lainnya. Pemilihan parameter model yang akan diubah dapat pula ditentukan secara acak. Kedua hal tersebut kemungkinan lebih cocok untuk parameterisasi homogen. Cara lain adalah mengubah semua parameter model secara bersama-sama, kemudian ditentukan apakah perubahan tersebut diterima atau ditolak. Perubahan harga parameter model dapat dilakukan secara diskret atau kontinyu. Jika perubahan harga parameter model bersifat kontinyu maka setiap harga dalam batas interval (minimum dan maksimum) memiliki peluang yang sama menjadi harga parameter yang diubah.

Interval harga parameter model dapat dibuat tetap selama iterasi berlangsung atau berubah sesuai dengan perkembangan iterasi atau penurunan temperatur. Perubahan interval sesuai dengan perkembangan iterasi didasarkan pada asumsi bahwa pada iterasi yang sudah lanjut atau pada T kecil pola dominan parameter model sudah terbentuk sehingga tinggal penyesuaian dalam skala kecil. Dalam hal ini interval ditentukan berdasarkan harga parameter model pada iterasi tertentu, misalkan dengan menentukan $m_i^{\min} = m_i/2$ dan $m_i^{\max} = 2m_i$ setelah iterasi mencapai temperatur tertentu. Selain itu dapat pula digunakan probabilitas yang tidak *uniform* pada penentuan harga parameter model.



Gambar 6.5

Beberapa pola perubahan atau penurunan temperatur sebagai fungsi dari iterasi.

Algoritma Genetika

Evolusi biologis yang menghasilkan populasi yang lebih unggul atau lebih sesuai dengan kondisi alam dan lingkungan sebagaimana prinsip *survival for the fittest* telah mengilhami penyelesaian inversi non-linier dengan pendekatan global yang disebut algoritma genetika (*Genetic Algorithm*). Variasi dari algoritma yang dilandasi analogi dengan proses

evolusi sering disebut juga algoritma evolusi (*evolutionary algorithm*). Dalam konteks inversi non-linier dengan pendekatan global algoritma genetika dan algoritma evolusi termasuk dalam kategori *guided random search*.

Dalam algoritma genetika populasi atau kumpulan individu direpresentasikan oleh sejumlah model, sedangkan konsep *fitness* dinyatakan oleh kesesuaian antara respons model dengan data. Dengan demikian *fitness* yang tinggi berasosiasi dengan *misfit* yang rendah. Selanjutnya dalam konteks pemodelan inversi menggunakan algoritma genetika istilah individu dan model dapat saling dipertukarkan. Hal ini dimaksudkan untuk memberikan gambaran lebih jelas hubungan antara konsep genetika dengan konsep inversi.

Dalam algoritma genetika, anggota suatu populasi dipilih berdasarkan *fitness*-nya dan jumlah populasi dalam satu generasi dibuat tetap. Evolusi dari satu generasi ke generasi berikutnya dilakukan melalui beberapa mekanisme berikut:

▪ Seleksi

Pemilihan sekumpulan individu atau model untuk dijadikan anggota populasi didasarkan pada *fitness*-nya. Model dengan respons yang dekat dengan data pengamatan (*misfit* kecil) memiliki probabilitas lebih besar untuk terpilih. Mekanisme seleksi berdasarkan *misfit* juga digunakan untuk menentukan individu atau model yang akan menjalani proses reproduksi. Karakteristik individu dalam satu generasi dengan *fitness* cukup besar memiliki kemungkinan lebih besar untuk bertahan sampai generasi berikutnya melalui proses reproduksi. Individu terbaik dari satu generasi dapat secara otomatis terpilih menjadi anggota populasi pada generasi berikutnya (prinsip *elitism*).

▪ Reproduksi

Bobot yang menyatakan sejauhmana *fitness* menentukan tingkat reproduksi identik dengan faktor temperatur pada metode *simulated annealing*. Jika selektivitas rendah maka semua solusi (individu) akan diterima, sedangkan jika selektivitas tinggi akan menyebabkan satu solusi

dengan karakteristik tertentu menjadi dominan. Dalam proses reproduksi sepasang individu induk dipilih berdasarkan *fitness*-nya dan keturunannya (*offspring*) merupakan hasil pertukaran karakteristik atau parameter induk yang dipilih secara acak. Dalam hubungannya dengan pencarian solusi pada ruang model, proses pertukaran tersebut merepresentasikan kerjasama individu untuk sampai pada titik lain dalam ruang model secara langsung tanpa melalui proses perturbasi sedikit demi sedikit. Proses pertukaran karakteristik induk disebut juga sebagai *cross-over* atau penyilangan

▪ Mutasi

Dalam proses mutasi, karakteristik atau parameter pada suatu individu dapat berubah secara acak dengan harapan akan diperoleh individu yang lebih baik.

Gambar 6.6 memberikan ilustrasi bagaimana mekanisme atau algoritma genetika sederhana bekerja. Pada proses seleksi, satu populasi yang terdiri dari individu-individu dipilih berdasarkan *fitness*-nya. Hasil seleksi kemudian dipasangkan pada proses reproduksi atau persilangan (*cross-over*) dengan hasil *offspring* yang memiliki karakteristik yang disumbangkan oleh masing-masing induk. Proses diulang hingga beberapa generasi dan anggota populasi memiliki *fitness* tinggi yang merepresentasikan karakteristik optimum atau solusi inversi.

Dalam algoritma genetika, individu umumnya di-kode-kan sebagai bilangan biner (0 dan 1) pada sejumlah "bit" yang merepresentasikan harga parameter model. Pada Gambar 6.6b salah satu individu digambarkan sebagai x dan y untuk menggantikan 0 dan 1 untuk memperjelas proses reproduksi. Selain rekombinasi sederhana (*single-point cross-over*) seperti pada Gambar 6.6b dapat pula dilakukan *multi-point cross-over* atau *uniform cross-over* sebagai alternatif mekanisme reproduksi.

Pada kasus pengkodean biner, mutasi dilakukan dengan mengubah salah satu nilai "bit" menjadi kebalikannya. Parameter probabilitas mutasi digunakan untuk mengatur tingkat kejadian mutasi pada suatu populasi.

Pada algoritma genetika terdapat pula beberapa variabel atau parameter yang harus dipilih dan diatur (*tuning*) sedemikian hingga penyelesaian inversi dapat berjalan sesuai dengan yang diharapkan. Salah satu parameter yang harus dipilih adalah panjang "bit" atau *binary digit* pada peng-kode-an parameter model menjadi bilangan biner. Semakin besar jumlah "bit" maka resolusi parameter model akan semakin baik. Namun demikian hal tersebut akan memperbesar jumlah kombinasi parameter model yang harus di-eksplorasi dalam pencarian solusi optimum. Oleh karena itu perlu ditentukan panjang "bit" yang tepat sesuai dengan resolusi parameter model dan karakteristik data.


Alternatif lain dari pengkodean biner sebagai representasi individu adalah representasi *integer* dan representasi *real*. Pada ketiga jenis representasi individu tersebut diperlukan penyesuaian atau pengaturan terutama yang menyangkut "pemetaan" atau konversi dari kode atau representasi menjadi bilangan yang menyatakan harga parameter model. Demikian pula dengan pemilihan alternatif atau variasi mekanisme rekombinasi elemen-elemen dari suatu individu pada proses reproduksi yang berbeda sesuai dengan representasi yang digunakan.

Pemetaan atau konversi dari *misfit* menjadi *fitness* yang digunakan sebagai dasar pemilihan individu unggul juga merupakan masalah tersendiri. Hal yang perlu diperhatikan adalah adanya ambiguitas pada pemodelan geofisika yang mungkin menyebabkan nilai *fitness* hasil konversi dari *misfit* menjadi kurang representatif.

Parameter lain yang juga perlu diatur meskipun pengaruhnya tidak terlalu besar terhadap proses dan hasil inversi adalah probabilitas reproduksi dan probabilitas mutasi. Jika probabilitas reproduksi terlalu kecil, maka hampir tidak ada perbaikan individu dari satu generasi ke generasi berikutnya. Individu yang dihasilkan dari proses reproduksi akan mengalami mutasi sesuai dengan probabilitas mutasi. Pada evolusi biologis di alam, probabilitas terjadinya mutasi sangat kecil. Pada inversi menggunakan algoritma genetika, probabilitas mutasi yang terlalu besar dapat mengacaukan sistem yang sudah mulai konvergen menuju populasi dengan karakteristik yang optimum atau dekat dengan solusi inversi.

Parameter yang juga memerlukan pengkajian lebih lanjut adalah jumlah populasi. Jika jumlah populasi terlalu sedikit maka eksplorasi "ruang model" menjadi terbatas. Sementara itu jika jumlah populasi terlalu besar maka konvergensi akan sulit dicapai atau dapat dicapai dengan jumlah generasi yang sangat besar.

Sebenarnya masih banyak aspek algoritma genetika yang dapat dielaborasi lebih jauh. Pembahasan tentang algoritma genetika secara lebih lengkap terdapat pada banyak sumber literatur. Hal ini mengingat penerapan algoritma genetika sangat luas, tidak hanya untuk pemodelan inversi geofisika, namun pada hampir semua bidang yang memerlukan optimasi non-linier.



Gambar 6.6

(a) Konsep algoritma genetika, (b) reproduksi atau *cross-over*, (c) mutasi. Posisi bit untuk *cross-over* dan mutasi ditentukan secara acak.

*The road leading to a goal
does not separate you from the destination;
it is essentially a part of it.*

- Charles de Lint

7.1 Model Bola Homogen

Pada Bab ini dibahas beberapa contoh aplikasi inversi linier pada pemodelan data geofisika. Contoh yang dibahas diharapkan dapat memberikan gambaran lebih jelas bagaimana implementasi teori-teori yang telah dibahas pada Bab-Bab terdahulu. Meskipun demikian pembahasan tidak dimaksudkan untuk mencakup semua kemungkinan aplikasi pemodelan inversi linier secara lengkap.

Pada Bab 1 telah disinggung model bola homogen dan hubungannya dengan data anomali gravitasi sebagai ilustrasi pemodelan kedepan dan pemodelan inversi. Respons gravitasi komponen vertikal suatu model berbentuk bola homogen dinyatakan oleh persamaan berikut:

$$g_z(x) = G \frac{(4/3)\pi R^3 z_0 \rho}{((x-x_0)^2 + z_0^2)^{3/2}} \quad (7.1)$$

dimana G adalah konstanta universal gravitasi ($6.67 \cdot 10^{-11}$ dalam satuan SI), R adalah jari-jari bola, (x_0, z_0) adalah posisi titik pusat massa bola dalam arah sumbu x (horisontal) dan sumbu z (vertikal atau kedalaman) dan ρ adalah rapat massa bola. Respons model dihitung pada satu lintasan yang memotong titik pusat bola dan merupakan sumbu x (lihat Gambar 1.1). Dalam perhitungan persamaan (7.1) perlu diperhatikan masalah penyesuaian satuan karena umumnya anomali gravitasi dinyatakan dalam satuan miliGal, yaitu $1 \text{ miliGal} = 10^{-5} \text{ meter/detik}^2$.

Persamaan pemodelan kedepan tersebut di atas masih dinyatakan hanya sebagai fungsi variabel bebas (x) karena variabel yang dipilih sebagai parameter model akan menentukan masalah inversi yang ditinjau, linier atau non-linier. Pada kasus ini geometri bola (jari-jari dan posisi) dianggap konstan dan diketahui. Dengan demikian parameter model adalah rapat massa bola sehingga hubungan antara data dan parameter model bersifat linier. Jika geometri dianggap sebagai parameter model, maka inversinya menjadi non-linier.

Data sintetik dihitung dengan membuat model sintetik yang terdiri dari 4 bola masing-masing dengan rapat massa yang berbeda, yaitu ρ_k , $k = 1, \dots, 4$. Persamaan untuk perhitungan respons model adalah:

$$g_z(\rho_k)_i = G \frac{(4/3)\pi R^3 (z_0)_k \rho_k}{((x_i - (x_0)_k)^2 + (z_0)_k^2)^{3/2}} \quad (7.2)$$

Pada persamaan (7.2) respons model g_z sebagai fungsi dari posisi titik perhitungan dibuat implisit sebagai indeks i yang bervariasi sesuai jumlah data. Matriks kernel dibentuk oleh persamaan (7.2) tanpa variabel ρ_j dengan kolom sesuai posisi bola yang dinyatakan oleh $(x_0, z_0)_k$ sementara baris sesuai posisi titik perhitungan data x_i ; $i = 1, \dots, N$ dengan N adalah jumlah data.


Misalkan terdapat 4 bola masing-masing dengan parameter sebagaimana ditampilkan pada Tabel 7.1 dan respons model sintetik yang telah ditambah *random noise* yang terdistribusi homogen $\pm 0.25 \text{ mGal}$ ditampilkan (diplot sebagai bulatan penuh) pada Gambar 7.1. Data sintetik tersebut dihitung pada posisi antara 0 sampai 1000 meter dengan interval 20 meter.

Pemodelan inversi linier menghasilkan harga parameter model (rapat massa bola) yang hampir sama dengan parameter model sintetik (Tabel 7.1 kolom paling kanan). Perbandingan antara respons model hasil inversi (diplot sebagai garis penuh) dengan data diperlihatkan pada Gambar 7.1. *Misfit* antara respons model dan data yang dinyatakan sebagai *RMS error* adalah sebesar 0.1 mGal .

Tabel 7.1

Parameter model sintetik, bola pada penampang 2-D.

No. bola	Parameter model sintetik				Hasil inversi
	x_0 (m)	z_0 (m)	R (m)	ρ (kg/m ³)	ρ (kg/m ³)
1	100	150	100	2000	1996.5
2	300	200	100	9000	8978.5
3	650	100	100	2000	1987.3
4	950	200	100	5000	5082.7



Gambar 7.1

Perbandingan antar respons model inversi (garis penuh) dengan data sintetik (bulatan).

Mekanisme pemodelan seperti yang telah dicontohkan di sini, yaitu inversi data sintetik untuk menghasilkan model atau solusi merupakan cara yang umum untuk menguji metode pemodelan inversi. Mengingat

model sintetik sudah diketahui maka penilaian kelayakan metode inversi dapat dilihat dari kesesuaian antara model inversi dan model sintetik tersebut. Selain itu kesesuaian antara data perhitungan dan data pengamatan merupakan kriteria yang dapat digunakan, khususnya untuk inversi data lapangan atau data sesungguhnya.

Pemodelan data gravitasi menggunakan model bola sebagaimana diuraikan di atas dapat diperluas dengan titik pengamatan berupa grid di permukaan bumi. Dengan demikian data tidak hanya pada profil yang memotong pusat bola, namun pada bidang permukaan dan dapat ditampilkan dalam bentuk kontur anomali. Kompleksitas masalah dapat ditingkatkan dengan menganggap permukaan bumi tidak datar sehingga lebih realistis dan mendekati permasalahan sebenarnya. Hal ini mengingat model bola sudah merepresentasikan anomali 3-D meskipun dalam bentuk atau geometri yang paling sederhana.

Misalnya model 4 bola sebagaimana dibahas sebelumnya diposisikan dalam ruang secara 3-D yaitu dengan koordinat masing-masing (x_0, y_0, z_0) sehingga persamaan pemodelan kedepan menjadi:

$$g_z(\rho_k)_i = G \frac{(4/3)\pi R^3(z_0)_k \rho_k}{((x_i - (x_0)_k)^2 + (y_i - (y_0)_k)^2 + (z_i - (z_0)_k)^2)^{3/2}} \quad (7.3)$$

Parameter model berupa 4 bola ditampilkan pada Tabel 7.2 dan respons model dalam bentuk peta kontur anomali gravitasi (dalam miliGal) ditampilkan pada Gambar 7.2. Data sintetik tersebut juga telah ditambah dengan *random noise* yang terdistribusi homogen ± 0.25 mGal. Dalam hal ini permukaan topografi dianggap datar sehingga $z_i = 0$.


Pengembangan tingkat kesulitan atau kompleksitas model dapat dilakukan dengan menggunakan model sintetik yang terdiri dari bola dengan jumlah lebih banyak. Misalnya bola-bola tersebut tersebar dan mengisi grid 3-D. Dengan asumsi volume bola sama dengan volume kubus yang dibentuk oleh grid 3-D maka respons suatu distribusi rapat massa secara 3-D dapat dimodelkan menggunakan persamaan yang lebih sederhana. Pola penyelesaian masalah inversinya identik atau tidak jauh

berbeda dengan kasus-kasus yang telah dibahas di atas. Pemodelan inversi data sintetik yang dihasilkan dengan cara seperti yang dicontohkan di sini diharapkan dapat dilakukan sebagai latihan.

Tabel 7.2

Parameter model sintetik, bola pada ruang 3-D.

Parameter model sintetik					
No. Bola	x_0 (m)	y_0 (m)	z_0 (m)	R (m)	ρ (kg/m ³)
1	100	200	150	100	2000
2	300	600	200	100	9000
3	650	200	100	100	2000
4	950	800	200	100	5000



Gambar 7.2

Peta kontur anomali gravitasi (dalam miliGal) hasil pemodelan kedepan untuk model bola sebagaimana ditampilkan pada Tabel 7.2 .

7.2 Pemodelan Inversi Gravitasi 2-D

Model 2-D

Pada pemodelan gravitasi dengan pendekatan model 2-D, bentuk penampang benda anomali dalam arah sumbu x dan z dianggap tetap atau sama sepanjang arah struktur (*strike* searah sumbu y). Perhitungan respons model maupun pengukuran data dilakukan sepanjang penampang yang dianggap tegak-lurus arah struktur tersebut. Untuk menggambarkan distribusi rapat massa secara 2-D maka medium didiskretisasi menjadi grid atau blok berukuran seragam (homogen) dengan rapat massa (atau lebih tepat kontras rapat massa) bervariasi. Geometri grid dianggap tetap dan diketahui sehingga parameter model adalah rapat massa setiap blok yang dapat diperkirakan melalui pemodelan inversi linier (lihat Gambar 7.3). Hal ini mirip dengan permasalahan inversi gravitasi dengan model bola seperti dibahas sebelumnya.

Dengan menggunakan notasi matriks, data anomali gravitasi $\mathbf{d} = [d_i]$; $i = 1, 2, \dots, N$ merupakan fungsi dari distribusi rapat massa melalui hubungan linier berikut:

$$\mathbf{d} = \mathbf{G} \cdot \mathbf{m} \tag{7.4}$$


dimana $\mathbf{G} = [G_{ik}]$; $i = 1, 2, \dots, N$; $k = 1, 2, \dots, M$ adalah matriks kernel dan $\mathbf{m} = [m_k]$; $k = 1, 2, \dots, M$ adalah vektor model. Komponen matriks kernel G_{ik} menyatakan kontribusi blok ke- k dengan rapat massa satuan pada anomali gravitasi di titik ke- i . Sementara N dan M masing-masing adalah jumlah data dan jumlah parameter model (blok).

Persamaan (7.4) adalah fungsi pemodelan kedepan gravitasi 2-D dengan konfigurasi atau geometri seperti pada Gambar 7.3. Persamaan respons model yang membentuk matriks kernel diperoleh dari formulasi Talwani untuk model 2-D dengan penampang berbentuk poligon. Dalam hal ini poligon berbentuk bujur-sangkar dengan 4 sisi sesuai grid atau blok hasil diskretisasi model. Persamaan lengkap, algoritma perhitungan dan program komputer respons model 2-D tersebut terdapat pada buku teks tentang teori dan aplikasi medan potensial oleh Blakely (1995).

Mengingat data pengukuran hanya terletak di permukaan sepanjang lintasan atau penampang yang memotong anomali maka secara umum jumlah data jauh lebih kecil dari pada jumlah parameter model yang dicari (*under-determined*). Oleh karena itu solusi inversi diperoleh dengan meminimumkan *norm* model dan model inversi dinyatakan oleh:

$$\mathbf{m} = \mathbf{G}^T [\mathbf{G} \mathbf{G}^T + \lambda \mathbf{I}]^{-1} \mathbf{d} \quad (7.5)$$

dimana λ adalah faktor redaman yang dapat digunakan untuk mengurangi *over-fitting* yaitu respons model yang sama persis dengan data termasuk *noise* yang terkandung dalam data. Hal ini mengingat pada pemodelan inversi *purely under-determined* kesalahan prediksi data $E = 0$.



Gambar 7.3

Ilustrasi mengenai anomali gravitasi sepanjang profil yang berasosiasi dengan distribusi rapat bawah-permukaan 2-D yang didiskretisasi menjadi grid berukuran seragam.


Inversi tanpa Kendala Tambahan

Untuk memberikan ilustrasi mengenai aplikasi inversi linier pada data gravitasi 2-D maka dilakukan pemodelan inversi data sintetik tanpa kendala tambahan (*unconstrained*) selain *norm* model minimum. Model sintetik sederhana adalah benda anomali dengan penampang berbentuk balok segi empat dalam arah horisontal dan vertikal. Kontras rapat massa benda anomali tersebut terhadap sekitarnya adalah sebesar 1.0 gram/cm^3 . Respons model dihitung dengan menggunakan persamaan (7.4). Data sintetik adalah respons model yang telah ditambah *noise* dengan distribusi normal dengan rata-rata nol dan standar deviasi 1.0 mGal .

Pemodelan inversi dilakukan pada medium 2-D yang didiskretisasi menjadi 40×20 blok masing-masing berukuran 50×50 meter dalam arah sumbu x dan sumbu z. Hasil inversi ditampilkan pada Gambar 7.4 (bawah) yang menunjukkan bahwa model hasil inversi tidak dapat merekonstruksi dengan benar model sintetik (bentuk penampang model sintetik digambarkan oleh garis putih). Meskipun demikian terdapat kecocokan (*fit*) yang baik antara respons model dengan data (Gambar 7.4 atas) yang merupakan ciri utama inversi *purely under-determined*.

Pemodelan inversi menggunakan persamaan (7.5) menghasilkan solusi berupa distribusi kontras rapat masa yang cenderung terkonsentrasi hanya di dekat permukaan dengan kontras rapat massa lebih kecil dari yang seharusnya. Terlihat pula adanya blok-blok dengan kontras rapat massa negatif (blok berwarna putih) di dekat permukaan dan tepi penampang. Hal tersebut merupakan kompensasi adanya kontras rapat massa tidak nol pada blok-blok yang terlalu dekat ke permukaan.

Permasalahan utama dalam pemodelan inversi data medan potensial seperti data gravitasi adalah ketidak-unikan solusi atau model hasil inversi. Jika suatu model menghasilkan respons yang cocok (*fit*) dengan data maka terdapat banyak (bahkan tak-hingga) model dengan konfigurasi lain yang juga menghasilkan respons yang hampir sama. Hal tersebut terlihat pada model inversi data sintetik sebagaimana diuraikan di atas. Selanjutnya dengan data sintetik yang sama dilakukan inversi dengan kendala tambahan selain minimisasi *norm* model.



Gambar 7.4

Hasil inversi data sintetik tanpa kendala tambahan selain minimisasi *norm* model. Model digambarkan sebagai distribusi kontras rapat massa bawah-permukaan 2-D. Kotak putih pada penampang menunjukkan posisi model sintetik. Kurva respons model inversi (garis) cukup *fit* dengan data sintetik (titik).

Inversi dengan Kendala Tambahan

Untuk mengatasi masalah ketidak-unikan solusi maka digunakan informasi tambahan selain *norm* model minimum yang menjadi kendala (*constrain*) bagi solusi. Hal tersebut dilakukan dengan meminimumkan suatu fungsi obyektif yang secara fisis berasosiasi dengan kondisi geologis yang diinginkan. Dengan demikian model hasil inversi diharapkan dapat merefleksikan kondisi geologi yang lebih realistis.

Kendala yang digunakan pada kasus ini adalah momen inersia benda anomali terhadap suatu elemen geometri tertentu berharga minimum (Guillen dan Menichetti, 1984; Barbosa dan Silva, 1994; Silva dan Barbosa, 2006). Minimisasi momen inersia setiap elemen massa (benda anomali) pada proses inversi dilakukan melalui pembobotan yang diterapkan secara iteratif. Dalam hal ini dicari model yang membuat

benda anomali terkonsentrasi di sekitar satu atau beberapa elemen geometri berupa pusat massa dan/atau sumbu simetri tertentu. Untuk selanjutnya hanya digunakan elemen geometri berupa sumbu simetri.

Parameter model dimodifikasi secara iteratif melalui persamaan:

$$\mathbf{m}^{k+1} = \mathbf{m}^k + \Delta \mathbf{m}^k \quad (7.6)$$

$$\Delta \mathbf{m}^k = \mathbf{W}_k^{-1} \mathbf{G}^T [\mathbf{G} \mathbf{W}_k^{-1} \mathbf{G}^T + \lambda \mathbf{I}]^{-1} (\mathbf{d} - \mathbf{G} \mathbf{m}^k) \quad (7.7)$$

Bentuk persamaan (7.7) di atas mirip dengan bentuk persamaan (7.5) untuk solusi inversi dengan *norm* model minimum. Dalam hal ini solusi tidak secara langsung menghasilkan model melainkan perturbasi model. $\mathbf{W}_k$ adalah matriks diagonal pembobot dengan elemen diagonal dinyatakan oleh:

$$w_{jj} = \frac{d_j^2}{m_j^k + \varepsilon} \quad (7.8)$$

$$d_j = \min_{1 < i < L} (d_{ij}) \quad (7.9)$$

dimana d_{ij} adalah jarak antara pusat elemen massa satuan atau blok ke- j terhadap atau sumbu simetri ke- i dan ε adalah konstanta bilangan kecil (dalam orde 10^{-7}) dan indeks k menyatakan iterasi.

Pada tahap awal dilakukan inversi dengan *norm* model minimum menggunakan persamaan (7.5) yang menghasilkan respons model yang *fit* dengan data. Meskipun demikian, solusi atau model yang diperoleh tidak sesuai dengan kriteria bahwa benda anomali harus terkonsentrasi di sekitar sumbu simetri yang sudah ditentukan. Kemudian matriks $\mathbf{W}_k$ mengontrol perturbasi model $\Delta \mathbf{m}^k$ pada setiap iterasi. Blok dengan kontras rapat massa besar yang terletak dekat dengan suatu sumbu tertentu diberi bobot kecil sehingga koreksi atau perturbasinya menjadi besar, demikian pula sebaliknya. Elemen massa dengan kontras rapat massa tidak nol kemudian akan cenderung terkonsentrasi secara proporsional di sekitar sumbu yang telah ditentukan sehingga dapat mendelineasi benda anomali dengan lebih baik.

Untuk menghasilkan solusi yang layak secara fisis maka kendala ketidak-samaan (*inequality constrain*) diterapkan sehingga pada setiap iterasi kontras rapat massa memenuhi batasan berikut:


$$m_{\min} \leq m_j \leq m_{\max} \quad (7.10)$$

Kendala ketidak-samaan tersebut diterapkan pada setiap elemen massa. Jika pada satu iterasi elemen massa m_j melampaui (melebihi atau kurang dari) harga batas yang telah ditentukan maka m_j akan di-set sama dengan batas yang telah dilampaui. Kemudian bobot yang berasosiasi dengan elemen massa tersebut tidak dihitung menggunakan persamaan (7.8) dan (7.9) tetapi di-set ke suatu harga yang sangat besar. Bobot yang besar akan membuat elemen massa menjadi terpaku (*frozen*) pada harga batas, paling tidak pada beberapa iterasi awal. Dengan demikian respons model menjadi tidak cocok dengan data yang memicu perturbasi model sesuai derajat ketidak-cocokan tersebut. Demikian seterusnya.

Kendala ketidak-samaan dimaksudkan pula untuk mencegah konsentrasi massa yang sangat besar di sekitar suatu sumbu simetri sehingga benda anomali hanya membentuk "garis" atau "collapse" pada sumbu simetri tersebut. Hal yang demikian akan menghasilkan model yang tidak realistis secara geologi.

Penerapan metode yang dijelaskan di atas pada inversi data sintetik yang sama dengan sebelumnya (Gambar 7.4) menghasilkan solusi yang lebih mendekati model yang sebenarnya atau model sintetik (Gambar 7.5). Dalam hal ini informasi mengenai posisi sumbu simetri benda anomali yang dicari sangat menentukan hasil inversi. Pada dasarnya informasi "a priori" mengenai sumbu simetri benda anomali dapat diperoleh dari data geologi atau data lainnya.

Untuk menguji metode inversi dengan kendala minimisasi momen inersia terhadap sumbu simetri tertentu, maka pemodelan inversi juga dilakukan pada data sintetik lainnya. Data sintetik tersebut berasosiasi dengan model yang lebih kompleks. Mengingat karakter model yang dapat didelineasi menggunakan metode yang telah dikemukakan, maka teknik ini lebih cocok untuk permasalahan eksplorasi zona mineralisasi.




Gambar 7.5

Hasil inversi data sintetik (yang sama dengan Gambar 7.4) menggunakan kendala tambahan yang meminimumkan momen inersia di sekitar sumbu simetri tertentu. Tanda panah menunjukkan posisi sumbu simetri model yang ditentukan secara "a priori".

Model sintetik yang dibuat mengikuti pola *dike* atau *sill* dan gabungan antara keduanya. Kontras rapat masa model sintetik adalah 1.0 gr/cm^3 . Pada data sintetik juga ditambahkan *noise* yang terdistribusi normal dengan rata-rata nol dan standar deviasi 1.0 mGal . Hasil inversi ditampilkan pada Gambar 7.6. Tampak bahwa model hasil inversi dapat merekonstruksi model sintetik dengan cukup baik berkat informasi "a priori" berupa posisi sumbu simetri benda anomali yang memadai.

Inversi menggunakan posisi sumbu simetri yang tidak tepat juga telah dilakukan untuk menguji sensitivitas metode ini terhadap ketiadaan informasi "a priori" yang cukup akurat. Hasilnya adalah model yang tidak realistis secara geologi (blok-blok yang terpisah-pisah tidak membentuk benda anomali yang menerus), meskipun dicapai *misfit* minimum. Hasil semacam ini dapat digunakan sebagai indikator ketidaktepatan informasi "a priori" yang digunakan sehingga perlu penyesuaian lebih lanjut (misalkan dengan cara *trial and error*).



Gambar 7.6

Hasil inversi data sintetik yang berasosiasi dengan model yang lebih kompleks. Model inversi (bawah) cukup dekat dengan model sintetik (tengah). Keterangan gambar sama dengan gambar-gambar sebelumnya.

Pada kasus inversi data gravitasi yang telah dibahas, informasi "a priori" yang diperlukan sangat spesifik, yaitu sumbu simetri benda anomali dimana momen inersia-nya minimum. Aplikasi metode inversi dengan kendala seperti diuraikan di atas tentu saja memiliki keterbatasan. Meskipun demikian metode inversi ini mampu menghasilkan informasi mengenai distribusi kontras rapat massa bawah-permukaan yang cukup realistis secara geologi. Pengetahuan tentang geologi suatu daerah eksplorasi zona mineralisasi umumnya telah tersedia dan cukup memadai untuk digunakan pada inversi gravitasi 2-D dengan kendala minimisasi momen inersia ini.

Minimisasi momen inersia benda anomali terhadap elemen geometri (pusat massa atau sumbu simetri) hanya merupakan salah satu alternatif kendala untuk mengurangi ambiguitas solusi inversi data gravitasi. Alternatif lain adalah meminimumkan variabilitas spasial parameter model sehingga diperoleh model yang "flat" maupun yang "smooth" sebagaimana telah dibahas pada Bab 4. Selain itu dapat pula dilakukan pembobotan model sesuai dengan kedalaman elemen model (*depth weighting*) agar dapat merekonstruksi model inversi pada kedalaman yang tepat (Li dan Oldenburg, 1996, 1998).

Exercise is the best instrument in learning.

– Robert Recorde

9.1 Penentuan Episenter Gempa

Permasalahan inversi untuk menentukan atau memperkirakan posisi episenter gempa merupakan contoh klasik dan sederhana yang dapat memberikan ilustrasi bagaimana penyelesaian inversi dilakukan. Pada sub-Bab ini akan ditinjau kembali permasalahan penentuan episenter gempa menggunakan contoh (model dan data sintetik) sebagaimana telah dibahas pada Bab 6.

Misalkan diketahui data waktu tiba gelombang P di sejumlah titik pengamatan gempa adalah $\mathbf{d} = [t_1, t_2, \dots, t_N]$. Posisi titik pengamatan adalah $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$. Dengan asumsi kecepatan gelombang P atau V_P konstan dan diketahui maka penentuan episenter gempa $\mathbf{m} = [x_0, y_0]$ adalah inversi non-linier mengingat hubungan antara data dan parameter model dinyatakan persamaan berikut:

$$t_i = t_0 + \frac{\sqrt{(x_0 - x_i)^2 - (y_0 - y_i)^2}}{V_P} \quad (9.1)$$

dimana t_0 adalah waktu terjadinya gempa (*origin time*) yang dianggap nol (untuk memudahkan) sehingga waktu tiba sama dengan waktu tempuh gelombang gempa. Persamaan pemodelan kedepan yang dinyatakan oleh persamaan (9.1) sangat sederhana dan parameter model hanya terdiri dari dua komponen yaitu x_0 dan y_0 , yang merupakan parameter model homogen (dengan dimensi dan satuan yang sama).

Matriks Jacobi untuk kasus ini adalah matriks dua kolom yang masing-masing berasosiasi dengan turunan parsial fungsi waktu tempuh terhadap posisi episenter gempa yang dicari, yaitu x_0 dan y_0 . Baris matriks Jacobi berasosiasi dengan data atau jumlah data. Matriks Jacobi tersebut dirumuskan oleh persamaan berikut:

$$\underline{\mathbf{J}} = \begin{bmatrix} \frac{\partial t_1}{\partial x_0} & \frac{\partial t_1}{\partial y_0} \\ \frac{\partial t_2}{\partial x_0} & \frac{\partial t_2}{\partial y_0} \\ \vdots & \vdots \\ \frac{\partial t_N}{\partial x_0} & \frac{\partial t_N}{\partial y_0} \end{bmatrix} \quad (9.2)$$

dengan masing-masing komponen dapat dinyatakan secara eksplisit oleh:

$$\frac{\partial t_i}{\partial x_0} = \frac{(x_0 - x_i)}{V_P \sqrt{(x_0 - x_i)^2 - (y_0 - y_i)^2}} \quad (9.3a)$$

$$\frac{\partial t_i}{\partial y_0} = \frac{(y_0 - y_i)}{V_P \sqrt{(x_0 - x_i)^2 - (y_0 - y_i)^2}} \quad (9.3b)$$

Sebagaimana telah dibahas pada Bab 5, solusi inversi diperoleh dengan memodifikasi model awal secara iteratif sampai dicapai konvergensi menuju model optimum. Salah satu kriteria konvergensi adalah tercapainya *RMS error* yang dirumuskan sebagai kesalahan rata-rata:

$$E_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (t_i^{\text{cal}} - t_i)^2} \quad (9.4)$$

Untuk memberikan gambaran aplikasi metode pemodelan inversi non-linier dengan pendekatan linier dilakukan inversi data sintetik yang telah digunakan sebagai contoh inversi non-linier dengan pendekatan global pada Bab 6. Misalkan disimulasikan suatu kejadian gempa pada posisi $(x_0, y_0) = (40, 30)$ dengan $V_P = 4$ km/detik. Selanjutnya waktu tiba

gelombang P di empat stasiun pengamat gempa dapat dihitung menggunakan persamaan (9.1) dengan $t_0 = 0:0$ detik. Hasilnya adalah data sintetik yang selanjutnya dianggap sebagai data pengamatan t_i (Tabel 9.1). Semua koordinat posisi adalah dalam satuan kilometer dan waktu tempuh dihitung dan dibulatkan hanya sampai satu angka di belakang koma untuk mensimulasikan adanya *noise*.

Tabel 9.1

Posisi stasiun gempa dan data waktu tiba gelombang P.

Stasion	x_i (km)	y_i (km)	t_i (detik)
1	20	10	7.1
2	50	25	2.8
3	40	50	5.0
4	10	40	7.9

Tiga model awal (x_0, y_0) yang berbeda digunakan untuk menguji konvergensi solusi. Hasilnya ditampilkan pada Tabel 9.2 (model pada iterasi 0 adalah model awal). Pada semua percobaan iterasi dihentikan hanya sampai iterasi ke-empat. Berdasarkan Tabel 9.2 tampak bahwa iterasi sudah konvergen ke posisi episenter yang hampir sama antara iterasi ke-tiga dan ke-empat. Oleh karena itu selain *RMS error* kedekatan atau kesamaan model inversi pada dua iterasi yang saling berurutan dapat pula digunakan sebagai kriteria konvergensi dan penghentian iterasi. Hal tersebut dapat menghindarkan iterasi yang berjalan terus menerus karena *RMS error* tidak mencapai harga minimum yang diinginkan.

Hasil inversi dalam bentuk posisi episenter gempa sebagai fungsi iterasi untuk ketiga model awal yang berbeda ditampilkan pada Gambar 9.1. Tampak bahwa semua model awal konvergen ke solusi yang hampir sama dan hanya berjarak kurang dari 2 km dari posisi episenter yang sebenarnya (model sintetik). Kasalahan penentuan posisi episenter tersebut masih dalam batas ketelitian data sintetik sehingga pemodelan inversi sederhana menggunakan metoda Gauss-Newton cukup memadai.

Tabel 9.2

Koordinat posisi episenter gempa sebagai fungsi iterasi.

Iterasi	x_0 (km)	y_0 (km)	E_{RMS} (detik)
0	30.00	10.00	0.87816
1	44.17	24.54	0.29457
2	39.76	30.03	0.01106
3	40.02	30.06	0.00193
4	40.02	30.06	0.00194


Iterasi	x_0 (km)	y_0 (km)	E_{RMS} (detik)
0	10.00	10.00	1.62731
1	17.38	25.60	1.06487
2	38.46	29.90	0.06771
3	40.02	30.04	0.00190
4	40.02	30.06	0.00194

Iterasi	x_0 (km)	y_0 (km)	E_{RMS} (detik)
0	5.00	45.00	1.79209
1	24.53	55.80	1.33367
2	34.43	42.99	0.64984
3	40.37	29.68	0.02468
4	40.03	30.06	0.00197

Pada contoh yang dibahas hubungan antara data dengan parameter model adalah non-linier namun tidak terlalu kompleks (*weakly non-linear*). Dengan demikian, fungsi obyektif dapat didekati dengan cukup baik oleh fungsi linier di sekitar model yang sedang ditinjau pada setiap iterasi. Konvergensi pada solusi yang tepat diperoleh dengan jumlah iterasi yang sedikit dan $E_{RMS} = 0.16$ detik. Selain itu konfigurasi titik pengamatan yang mengelilingi episenter gempa menyebabkan fungsi obyektif memiliki minimum global dengan "bentuk" yang sederhana. Hal ini dapat dilihat pada bentuk kontur fungsi obyektif yang digambarkan sebagai hasil penyelesaian inversi non-linier dengan pendekatan global pada Bab 6 (lihat Gambar 6.1 dan 6.2).

Sebagai bahan latihan inversi non-linier dengan pendekatan linier, contoh sederhana pada sub-Bab ini dapat diperluas dengan memperhitungkan kondisi yang lebih realistis. Misalnya, parameter model tidak hanya terdiri dari dua parameter yaitu posisi episenter gempa di permukaan bumi (x_0, y_0) tetapi posisi fokus gempa yang melibatkan pula kedalaman (x_0, y_0, z_0). Dalam hal ini titik-titik pengamatan gempa dapat pula diposisikan dalam ruang 3-D (termasuk ketinggian atau topografi stasiun) dengan parameter (x_i, y_i, z_i) sebagai variabel bebas.

Waktu terjadinya gempa atau *origin time* (t_0) serta kecepatan gelombang P (V_p) pada medium dapat pula dijadikan sebagai parameter model yang dicari. Dengan demikian parameter model menjadi tidak homogen karena tidak merupakan besaran yang sama, yaitu gabungan dari posisi, waktu dan kecepatan. Hal tersebut dapat menjadikan permasalahan lebih mendekati kondisi yang sebenarnya.



Gambar 9.1

Plot trayektori model episenter gempa (x_0, y_0) sebagai fungsi iterasi untuk 3 model awal yang berbeda. Posisi model sintetik adalah lingkaran yang menandai daerah dengan jari-jari 2 km di sekitar titik (40, 30).

Pada permasalahan yang lebih kompleks, karena fungsi *misfit* yang sangat tidak linier maupun konfigurasi (atau geometri) eksperimen dan data yang kurang tepat, konvergensi menuju solusi inversi yang tepat umumnya cukup sulit. Selain bentuk fungsi *misfit* yang tidak sederhana juga terdapat kemungkinan adanya minimum lokal yang berasosiasi dengan model yang tidak optimum. Dalam hal ini pendekatan linier fungsi obyektif yang sangat tidak linier dan modifikasi model secara iteratif sering kurang memadai. Keterbatasan pendekatan linier antara lain adalah model awal harus cukup dekat dengan solusi dan kemungkinan konvergensi pada minimum lokal, bukan minimum global.

9.2 Inversi Data Geolistrik 1-D

Untuk memberikan gambaran mengenai aplikasi pemodelan inversi non-linier yang agak lebih kompleks maka pada sub-Bab ini dibahas inversi data geolistrik 1-D. Pada pemodelan geolistrik 1-D model bumi dianggap berlapis horisontal (Gambar 9.2) sehingga resistivitas (dalam Ohm.m) hanya bervariasi terhadap kedalaman. Pendekatan ini dianggap cukup memadai untuk kondisi geologi tertentu yaitu di lingkungan sedimen sampai kedalaman yang tidak terlalu besar. Data geolistrik diperoleh melalui pengukuran dengan konfigurasi elektroda tertentu dengan jarak antar elektroda yang makin besar untuk memperoleh informasi pada kedalaman yang makin besar pula (*sounding*).

Fungsi pemodelan kedepan pada metoda geolistrik dengan model 1-D diformulasikan sebagai persamaan integral Hankel yang menyatakan resistivitas-semu ρ_a sebagai fungsi dari resistivitas dan ketebalan (ρ_k, h_k) tiap lapisan, $k = 1, \dots, n$ dan n adalah jumlah lapisan:

$$\rho_a = s^2 \int_0^{\infty} T(\lambda) J_1(\lambda s) \lambda d\lambda \quad (9.5)$$

s adalah setengah jarak antar elektroda arus ($AB/2$ untuk konfigurasi Schlumberger), J_1 adalah fungsi Bessel orde-satu, dan $T(\lambda)$ adalah fungsi transformasi resistivitas yang dinyatakan oleh formulasi rekursif Pekeris (Koefoed, 1979):

$$T_k(\lambda) = \frac{T_{k+1}(\lambda) + \rho_k \tanh(\lambda h_k)}{1 + T_{k+1}(\lambda) \tanh(\lambda h_k) / \rho_k} ; k = n-1, \dots, 1 \quad (9.6)$$

Perhitungan persamaan (9.5) dapat dilakukan dengan metode filter linier yang secara umum dinyatakan oleh persamaan berikut:

$$\rho_a = \sum_k T_k(\lambda) f_k \quad (9.7)$$

dimana f_k adalah harga koefisien filter linier yang diturunkan oleh Ghosh (Koefoed, 1979). Dari persamaan-persamaan tersebut di atas tampak bahwa hubungan antara data resistivitas-semu (ρ_a) dengan parameter model resistivitas dan ketebalan lapisan (ρ_k, h_k) adalah sangat tidak linier.

Dalam konteks pemodelan inversi geolistrik 1-D, data dinyatakan sebagai $\mathbf{d} = [\rho_a^i]$ yaitu resistivitas-semu dengan $i = 1, 2, \dots, N$ dan N adalah jumlah data sesuai variabel bebas $AB/2$. Model resistivitas bawah-permukaan 1-D adalah $\mathbf{m} = [\rho_k, h_k]$, $k = 1, 2, \dots, n$. Dalam hal ini, jumlah parameter model adalah $M = 2n - 1$ karena pada model 1-D yang terdiri dari n lapisan terdapat n harga resistivitas dan $n - 1$ harga ketebalan lapisan (lapisan terakhir dianggap memiliki ketebalan tak-hingga, Gambar 9.2). Dengan demikian parameterisasi model bersifat tidak homogen.


Pemodelan inversi data geolistrik sounding 1-D dilakukan sesuai algoritma inversi non-linier dengan pendekatan linier yang telah diuraikan pada Bab 5 sehingga tidak diulang di sub-Bab ini. Dalam hal ini digunakan faktor redaman dan teknik *Singular Value Decomposition* (SVD) untuk menstabilkan proses inversi.

Persamaan pemodelan kedepan (*forward modeling*) geolistrik 1-D secara umum dinyatakan oleh $\mathbf{d} = \mathbf{g}(\mathbf{m})$. Mengingat persamaan yang menghubungkan data dengan parameter model cukup kompleks maka turunan parsial orde pertama terhadap setiap parameter model sangat sulit diperoleh secara analitik dan eksplisit. Oleh karena itu untuk memperoleh elemen matriks Jacobi dilakukan melalui pendekatan beda-hingga (*finite-difference*) sebagai berikut:

$$\left[\frac{\partial g_i(\mathbf{m})}{\partial m_k} \right] \approx \frac{g_i(\mathbf{m} | m_k + \Delta m_k) - g_i(\mathbf{m} | m_k)}{\Delta m_k} \quad (9.8)$$

Setiap elemen matriks Jacobi memerlukan dua kali pemodelan kedepan, pertama untuk model $\mathbf{m}$ dan kemudian untuk model yang sama namun dengan elemen ke- k dari $\mathbf{m}$ diperturbasi dengan Δm_k . Besarnya perturbasi umumnya berkisar antara 5% sampai 10% dari harga parameter model.

Berdasarkan persamaan (9.8) tampak bahwa kolom matriks Jacobi ke- k berasosiasi dengan perubahan respons model (pada semua elemen data perhitungan dengan indeks- i) sebagai akibat dari perturbasi suatu elemen parameter model m_k . Baris matriks Jacobi ke- i menyatakan perubahan respons model (pada satu elemen data perhitungan ke- i) akibat perturbasi semua elemen parameter model dengan indeks- k . Matriks Jacobi secara lengkap menggambarkan variasi respons model atau data perhitungan akibat perubahan parameter model.



Gambar 9.2

Model resistivitas 1-D yang terdiri dari n lapisan horisontal, masing-masing dengan resistivitas homogen ρ_k dan ketebalan h_k . Lapisan terakhir adalah *half-space* dengan ketebalan tak-hingga.

Pemodelan inversi non-linier data geolistrik 1-D dilakukan pada data sintetik. Model yang digunakan untuk menghasilkan data sintetik adalah model bumi 3 dan 4 lapis masing-masing sebagai model-1 dan model-2 (Tabel 9.3). Data sintetik mengandung *noise* terdistribusi normal dengan rata-rata nol dan standar deviasi sebesar 5% dari data teoritik.

Pada inversi non-linier data geolistrik 1-D secara "a priori" jumlah lapisan ditentukan sama dengan jumlah lapisan model sintetik, untuk menyederhanakan masalah. Informasi tersebut pada dasarnya dapat diperkirakan dari pola kurva *sounding* (resistivitas-semu fungsi dari spasi elektroda AB/2). Secara umum ketebalan dan resistivitas lapisan masing-masing dapat diperkirakan berdasarkan spasi elektroda dan resistivitas-semu (Zohdy, 1989; Muiuane dan Pedersen, 1999).


Tabel 9.3
Parameter model sintetik dan model hasil inversi data geolistrik 1-D.

Parameter model	Model-1		Model-2	
	Model sintetik	Model inversi	Model sintetik	Model inversi
ρ_1 (Ohm.m)	50.0	47.3	100.0	100.4
ρ_2 (Ohm.m)	100.0	98.6	50.0	52.7
ρ_3 (Ohm.m)	20.0	20.4	20.0	22.2
ρ_4 (Ohm.m)	—	—	10.0	10.1
h_1 (m)	5.0	4.6	5.0	4.7
h_2 (m)	10.0	9.3	10.0	8.5
h_3 (m)	—	—	20.0	19.6

Model awal yang dipilih secara sembarang tidak memberikan hasil yang konvergen ke model sebenarnya, terutama jika ketebalan lapisan cukup jauh dari harga ketebalan model sintetik. Sebagaimana telah dibahas sebelumnya, pemodelan inversi non-linier dengan pendekatan linier yang diselesaikan secara iteratif memerlukan model awal yang dekat dengan solusi. Oleh karena itu model awal dipilih sedemikian hingga tidak terlalu jauh dari model sebenarnya. Dalam hal ini model

awal yang digunakan adalah model yang terdiri dari 3 dan 4 lapisan (untuk model-1 dan model-2) dengan resistivitas homogen 80 Ohm.m dan ketebalan tiap lapisan 20 meter.

Hasil inversi ditampilkan pada Tabel 9.3 dan Gambar 9.3 yang menunjukkan kedekatan model inversi dengan model sintetik, demikian pula dengan data sintetik dan respons model inversi (Gambar 9.3 atas). *Misfit* model inversi adalah 4.2% dan 4.9% masing-masing untuk model-1 dan model-2 yang sesuai dengan tingkat *noise* pada data sintetik, yaitu 5%.




Gambar 9.3
Perbandingan antara data sintetik dengan respons model inversi (atas) serta perbandingan antara model sintetik dengan model inversi (bawah) masing-masing untuk model-1 (kiri) dan model-2 (kanan).

9.3 Inversi Data Magnetotellurik 2-D

Metode magnetotellurik (MT) digunakan untuk memperkirakan resistivitas bawah-permukaan berdasarkan data medan elektromagnetik (EM) alam. Data MT umumnya berupa kurva *sounding* resistivitas-sembu dan fasa terhadap periode atau frekuensi. Dalam hal ini periode yang semakin berasosiasi dengan kedalaman yang semakin besar pula. Data *sounding* MT pada beberapa titik di suatu lintasan dapat dimodelkan menggunakan model 1-D maupun 2-D. Parameterisasi model MT 1-D mirip dengan pemodelan geolistrik 1-D. Pada model 2-D resistivitas bervariasi dalam arah horisontal sesuai lintasan (sumbu x) dan dalam arah vertikal atau kedalaman (sumbu z) sehingga $\rho(y, z)$.

Medium didiskretisasi menjadi blok-blok dengan geometri tetap sehingga parameter model adalah resistivitas tiap blok. Ukuran blok dibuat tidak seragam untuk menggambarkan resolusi data MT yang berkurang terhadap jarak dan kedalaman serta untuk penerapan syarat batas pada penyelesaian persamaan diferensial menggunakan metode beda-hingga atau *finite difference* (Gambar 9.4).



Gambar 9.4

Ilustrasi model MT 2-D dan diskretisasi medium serta parameterisasinya.

Pemodelan kedepan untuk menghitung respons model MT 2-D pada dasarnya adalah penyelesaian persamaan diferensial yang diturunkan dari persamaan Maxwell dengan penyesuaian pada dimensi medium yang ditinjau. Persamaan Maxwell yang utama dituliskan sebagai berikut:

$$\nabla \times \mathbf{H} = \mathbf{J} + \frac{\partial \mathbf{D}}{\partial t} \quad (9.9)$$

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t} \quad (9.10)$$

dimana $\mathbf{H}$ adalah medan magnet (Ampere/m), $\mathbf{E}$ adalah medan listrik (Volt/m), $\mathbf{D}$ adalah perpindahan listrik (Coulomb/m²), $\mathbf{B}$ adalah induksi magnet (Tesla) dan $\mathbf{J}$ adalah rapat arus (A/m²).

Persamaan (9.9) dan (9.10) disubstitusikan ke persamaan hasil operasi *curl* ($\nabla \times$) terhadap kedua persamaan tersebut. Dekomposisi persamaan yang dihasilkan dengan memperhatikan geometri model 2-D sebagaimana ditunjukkan pada Gambar 9.5 menghasilkan persamaan medan EM yang diidentifikasi sebagai polarisasi TE (*transverse electric*) dan TM (*transverse magnetic*).

Pada polarisasi TE medan listrik E_x dan medan magnet H_y masing-masing sejajar dan tegak lurus dengan arah struktur. Persamaan yang berlaku adalah:

$$\frac{\partial^2 E_x}{\partial y^2} + \frac{\partial^2 E_x}{\partial z^2} = i\omega\mu_0\sigma E_x \quad (9.11a)$$

$$H_y = -\frac{1}{i\omega\mu_0} \frac{\partial E_x}{\partial z} \quad (9.11b)$$


Pada polarisasi TM medan magnet H_x dan medan listrik E_y masing-masing sejajar dan tegak lurus dengan arah struktur. Persamaan yang berlaku adalah:

$$\frac{\partial}{\partial y} \left(\rho \frac{\partial H_x}{\partial y} \right) + \frac{\partial}{\partial z} \left(\rho \frac{\partial H_x}{\partial z} \right) = i\omega\mu_0\sigma H_x \quad (9.12a)$$

$$E_y = \rho \frac{\partial H_x}{\partial z} \quad (9.12b)$$

Persamaan (9.11a) dan (9.12a) pada dasarnya adalah dekomposisi persamaan (9.9) dan (9.10) masing-masing untuk medan listrik E_x dan medan magnet H_x . Dalam hal ini, komponen perpindahan listrik jauh lebih kecil dari pada komponen konduksi listrik sehingga diabaikan.

Persamaan diferensial medan EM untuk masing-masing polarisasi didekati dengan persamaan beda-hingga dengan memperhatikan diskretisasi model 2-D seperti diperlihatkan pada Gambar 9.4. Pada polarisasi TE, terlebih dahulu dihitung medan listrik E_x pada grid menggunakan persamaan (9.11a) dan hasilnya kemudian digunakan untuk memperkirakan H_y melalui pendekatan diferensiasi secara numerik seperti diperlihatkan pada persamaan (9.11b). Hal yang sama dilakukan untuk polarisasi TM menggunakan persamaan (9.12a dan 9.12b).



Gambar 9.5

Komponen medan listrik dan medan magnet dalam polarisasi TE dan TM pada model 2-D sederhana berupa kontak vertikal antara medium 1 dan medium 2 dengan resistivitas berbeda. Arah struktur (*strike*) adalah sejajar dengan sumbu x .

Penyelesaian numerik persamaan (9.11) dan persamaan (9.12) cukup kompleks dan tidak dibahas di buku ini. Secara umum fungsi yang menghubungkan data dengan parameter model adalah fungsi non-linier. Oleh karena itu persamaan dan algoritma yang berlaku untuk penyelesaian inversi non-linier dengan pendekatan linier juga dapat digunakan untuk pemodelan inversi data MT menggunakan model 2-D.

Algoritma pemodelan kedepan MT 2-D (Uchida, 1993) yang digunakan untuk menghitung resistivitas-semu dan fasa sebagai respons model 2-D dapat direpresentasikan oleh persamaan umum $\mathbf{d} = \mathbf{g}(\mathbf{m})$. Mengingat fungsi pemodelan kedepan yang sangat kompleks, maka perhitungan matriks Jacobi untuk menentukan perturbasi model pada setiap iterasi hanya dapat dilakukan dengan pendekatan beda-hingga menggunakan persamaan yang sama dengan persamaan (9.8).

Jumlah parameter model 2-D umumnya jauh lebih besar dari pada jumlah data ($M > N$) sehingga pemodelan inversi menjadi *over-parameterized* atau *under-determined*. Untuk menjaga kestabilan proses inversi maka digunakan kendala bahwa model optimum adalah model dengan variasi spasial minimum atau model yang “flat”. Untuk model 2-D yang terdiri dari blok-blok dalam arah sumbu x dan sumbu z maka variabilitas spasial model $\mathbf{l}$ dituliskan sebagai berikut:


$$\mathbf{l} = \begin{bmatrix} -1 & 1 & 0 & \cdots & 0 & 0 & 0 & \cdots \\ 0 & -1 & 1 & \cdots & 0 & 0 & 0 & \cdots \\ & & & \vdots & & & & \\ -1 & 0 & 0 & \cdots & 1 & 0 & 0 & \cdots \\ 0 & -1 & 0 & \cdots & 0 & 1 & 0 & \cdots \\ & & & \vdots & & & & \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ m_3 \\ \vdots \\ m_M \end{bmatrix} = \mathbf{D} \mathbf{m} \quad (9.13)$$

dimana baris-baris pada bagian pertama matriks $\mathbf{D}$ berasosiasi dengan selisih parameter model yang berdekatan secara horisontal, sedangkan baris-baris pada bagian kedua matriks $\mathbf{D}$ berasosiasi dengan selisih parameter model yang berdekatan secara vertikal. Matriks $\mathbf{D}$ pada dasarnya adalah operator diferensial orde-1 dari parameter model.

Persamaan (9.13) adalah versi 2-D dari persamaan (4.23) yang berlaku untuk geometri parameter model 1-D. Sebagai alternatif matriks **D** dapat pula digunakan operator diferensial orde-2 yang dapat menghasilkan model yang "smooth". Selanjutnya penyelesaian inversi non-linier melalui perturbasi model secara iteratif mengikuti algoritma sebagaimana telah dibahas sebelumnya pada Bab 5.


Pemodelan inversi data MT 2-D dilakukan pada data sintetik yang berasosiasi dengan model blok sederhana. Hal ini dimaksudkan untuk mengetahui kemampuan resolusi dari metode MT dan berbagai jenis data MT (komponen TM dan TE secara terpisah serta gabungan antara komponen TM dan TE). Model sintetik terdiri atas dua blok masing-masing merepresentasikan anomali konduktif (10 Ohm.m) dan anomali resistif (1000 Ohm.m) yang terletak pada medium dengan resistivitas menengah 100 Ohm.m (Gambar 9.6).

Titik pengamatan sounding MT terletak di permukaan berjumlah 24 titik, masing-masing dengan 11 frekuensi pada rentang yang sesuai dengan geometri (ukuran dan kedalaman) model sintetik, yaitu antara 2 Hz sampai 2 kHz. Jumlah data sedikit lebih besar dari pada jumlah parameter model namun tetap diperlukan kendala untuk mengurangi ambiguitas solusi.




Gambar 9.6
Model sintetik untuk pengujian inversi non-linier data MT 2-D.

Hasil pemodelan inversi data MT komponen TM dan TE secara terpisah (Gambar 9.7) maupun data MT gabungan antara komponen TM dan TE (Gambar 9.8) memperlihatkan bahwa data MT komponen TM dan TE saling melengkapi sehingga model hasil inversi relatif lebih jelas. Penggunaan kendala variabilitas model telah membuat variasi spasial resistivitas menjadi minimum dengan amplitudo anomali yang juga sangat jauh berkurang. Meskipun demikian secara garis besar pemodelan inversi data MT 2-D telah dapat mendelineasi geometri anomali konduktif dan resistif.



Gambar 9.7
Hasil pemodelan inversi 2-D data sintetik MT komponen TM (*Transverse Magnetic*) (atas) dan komponen TE (*Transverse Electric*) (bawah).



Gambar 9.8

Hasil pemodelan inversi 2-D data sintetik MT yang merupakan gabungan antara komponen TM dan TE.

*We learn by example and by direct experience
because there are real limits
to the adequacy of verbal instruction.*

- Malcolm Gladwell

8.1 Teknik Sumber Ekuivalen 3-D

Pemodelan Inversi Magnetik 3-D

Dalam Bab ini dibahas aplikasi pemodelan inversi pada data magnetik dimana model bawah-permukaan didiskretisasi menjadi susunan prisma tegak atau kubus dalam ruang 3-D. Geometri model tetap sehingga parameter model adalah intensitas magnetisasi yang homogen untuk tiap kubus (Gambar 8.1). Hubungan linier antara data $\mathbf{d}$ (d_i , $i = 1, 2, \dots, N$) dengan parameter model atau intensitas magnetisasi $\mathbf{m}$ (m_k , $k = 1, 2, \dots, M$) dinyatakan oleh:

$$\mathbf{d} = \mathbf{G} \mathbf{m} \quad (8.1)$$


dimana $\mathbf{G}$ adalah matriks kernel ($N \times M$) yang memetakan sumber anomali menjadi data observasi, dengan N adalah jumlah data dan M adalah jumlah parameter model. Komponen matriks kernel $\mathbf{G} = [G_{ik}]$ menyatakan kontribusi kubus ke- k dengan intensitas magnetisasi satuan pada anomali magnetik di titik ke- i . Perhitungan komponen matriks kernel tersebut mengikuti perumusan, algoritma perhitungan dan program komputer sebagaimana dibahas oleh Blakely (1995).

Titik pengamatan terletak hanya di permukaan bumi pada bidang x - y dengan jumlah data N . Sementara jumlah parameter model adalah $M = n_x \times n_y \times n_z$, dimana n_x , n_y dan n_z masing-masing adalah jumlah kubus

hasil diskretisasi dalam arah x , y dan z . Pada kasus seperti ini jumlah partameter model M jauh lebih besar dari pada jumlah data N . Permasalahan inversi bersifat *purely under-determined* sehingga solusi inversi dinyatakan oleh persamaan yang identik dengan persamaan (7.5), yaitu model yang diperoleh dengan meminimumkan *norm* model:

$$\mathbf{m} = \mathbf{G}^T [\mathbf{G} \mathbf{G}^T + \lambda \mathbf{I}]^{-1} \mathbf{d} \quad (8.2)$$

Faktor redaman λ pada persamaan (8.2) digunakan untuk mengurangi pengaruh *noise* terhadap model inversi dalam bentuk *over-fitting*, yaitu model yang merefleksikan data secara berlebihan termasuk *noise*-nya. Hal ini mengingat kesalahan prediksi data $E = 0$ pada inversi *purely under-determined*.



Gambar 8.1

Geometri model satuan 3-D berbentuk prisma tegak atau kubus untuk perhitungan respons magnetik di titik P , posisi sisi-sisi kubus sesuai sumbu x , y dan z yaitu x_1 , x_2 , y_1 , y_2 , z_1 , z_2 (kiri) dan diskretisasi medium 3-D menjadi susunan kubus dengan geometri homogen (kanan).

Untuk memudahkan penentuan faktor redaman, Mendonca dan Silva (1994; 1995) menggunakan matriks normalisasi $\mathbf{D}$ sehingga λ dapat dipilih dalam interval $[0, 1]$ dan persamaan (8.2) menjadi:

$$\mathbf{m} = \mathbf{G}^T \mathbf{D} [\mathbf{D} \mathbf{G} \mathbf{G}^T \mathbf{D} + \lambda \mathbf{I}]^{-1} \mathbf{D} \mathbf{d} \quad (8.3)$$


$\underline{D}$ adalah matriks diagonal ($N \times N$) dengan elemen-elemen yang diturunkan dari elemen matriks kernel:

$$D_{ii} = \left(\sum_{k=1}^M G_{ik}^2 \right)^{-1/2} \quad (8.4)$$

Perhitungan inversi matriks pada persamaan (8.3) menggunakan teknik *Singular Value Decomposition* atau SVD (Press dkk., 1987) yang relatif lebih stabil. Dalam penerapan teknik SVD nilai singular lebih kecil dari harga tertentu dapat diabaikan atau dianggap sama dengan nol sehingga tidak diikutsertakan pada perhitungan solusi. Pada kasus yang dibahas ini, nilai singular yang berharga lebih kecil dari 10^{-6} kali nilai singular maksimum diabaikan. Penerapan teknik SVD pada pemodelan inversi (khususnya pada perhitungan inversi matriks) umumnya dapat menghasilkan solusi inversi yang cukup baik.

Pemodelan inversi data magnetik 3-D dilakukan terhadap data sintetik. Medium bawah-permukaan direpresentasikan oleh susunan prisma tegak atau kubus 3-D berukuran $50 \times 50 \times 50$ meter berjumlah $20 \times 20 \times 10$ masing-masing dalam arah x , y dan z . Data sintetik merupakan respons model yang terdiri dari blok-blok horisontal 250×250 meter dengan intensitas magnetisasi 1.0 Ampere/meter, inklinasi = -10° dan deklinasi = 0° (Gambar 8.2a). Pada data sintetik tersebut ditambahkan *noise* terdistribusi normal dengan rata-rata nol dan standar deviasi 2 nanoTesla.

Hasil inversi 3-D tanpa kendala tambahan selain minimisasi *norm* model (*unconstrained*) dengan $\lambda = 0.1$ diperlihatkan pada Gambar 8.2b. Sebagaimana pemodelan inversi data gravitasi 2-D yang telah dibahas sebelumnya, inversi data magnetik 3-D tanpa kendala tambahan tidak menghasilkan solusi atau model yang memiliki signifikansi fisis maupun geologis. Pada Gambar 8.2b tampak bahwa sumber anomali cenderung terkonsentrasi di dekat permukaan dengan intensitas magnetisasi kurang dari 1.0 Ampere/meter. Model inversi tersebut tidak merepresentasikan model yang sebenarnya (model sintetik). Meskipun demikian, respons model hasil inversi tersebut cukup *fit* dengan data sintetik (Gambar 8.3).




Gambar 8.2

Pemodelan inversi data magnetik 3-D (a) distribusi kemagnetan model sintetik, (b) hasil inversi tanpa kendala tambahan.

Transformasi Data Magnetik

Adanya inklinasi vektor medan magnet bumi yang menginduksi kemagnetan batuan menghasilkan pola dipol pada data magnetik. Reduksi ke kutub (*reduction to the pole*) dan reduksi ke ekuator (*reduction to the equator*) adalah proses transformasi vektor kemagnetan induksi sehingga mempunyai arah vertikal seperti kondisi di kutub atau di ekuator. Proses tersebut diharapkan menghasilkan pola anomali yang bersifat monopol sehingga lebih memudahkan interpretasi dan delineasi benda anomali.

Kontinuasi ke atas (*upward continuation*) dimaksudkan untuk memperoleh pola anomali magnetik regional yang lebih *smooth* dengan menghitung data yang seolah-olah diamati pada ketinggian tertentu. Transformasi data magnetik tersebut umumnya dilakukan dengan menerapkan teknik pemfilteran pada domain frekuensi melalui proses *Fast Fourier Transform* atau FFT (Blakely, 1995).



Gambar 8.3

(a) Data sintetik pada daerah seluas 1000×1000 meter yang merupakan respons model sintetik pada Gambar 8.2a. (b) Respons model hasil inversi tanpa kendala tambahan yang ditampilkan pada Gambar 8.2b. Skala abu-abu hanya menunjukkan besaran anomali secara relatif dari minimum (warna terang) ke maksimum (warna gelap).

Persamaan umum transformasi data magnetik (yang berlaku juga untuk data gravitasi) menggunakan teknik pemfilteran pada domain frekuensi dinyatakan sebagai berikut:

$$F[\Delta T_x] = F[\Psi_x] F[\Delta T] \quad (8.5)$$

dimana ΔT adalah data anomali, ΔT_x adalah anomali hasil transformasi, Ψ_x adalah fungsi filter transformasi dan $F[\cdot]$ menyatakan operasi FFT. Salah satu kelemahan metode pemfilteran tersebut adalah sensitivitasnya yang cukup tinggi terhadap *noise* pada proses FFT. Selain itu terdapat masalah ketidak-stabilan fungsi filter transformasi reduksi ke kutub akibat inklinasi mendekati nol untuk daerah dengan lintang magnetik rendah (daerah dekat ekuator).

Konsep sumber ekuivalen (*equivalent source*) banyak digunakan pada pengolahan dan pemodelan data medan potensial (gravitasi dan magnetik). Konsep ini memanfaatkan ketidak-unikan solusi dalam

pemodelan data medan potensial. Jika suatu model anomali menghasilkan respons model yang *fit* dengan data maka model tersebut dapat digunakan untuk menghitung data teoritik dengan konfigurasi geometri lain yang berbeda dari konfigurasi geometri saat data diukur. Konfigurasi geometri tersebut tercermin pada matriks kernel $\underline{G}$ yang dapat dimodifikasi sesuai tujuan transformasi data. Pada dasarnya semua transformasi dapat dilakukan menggunakan konsep sumber ekuivalen.

Pada data gravitasi dan magnetik transformasi data diperlukan misalnya untuk interpolasi data pada grid homogen (Mendonca dan Silva, 1994; 1995; Cooper, 2000), atau untuk menghitung data pada level ketinggian tertentu yang disebut sebagai kontinuitas (Cordell, 1992). Pada transformasi data magnetik, proses reduksi ke kutub dapat diperoleh dengan menghitung respons sumber ekuivalen dengan vektor kemagnetan vertikal (Emilia, 1973; Silva, 1986).

Sumber ekuivalen umumnya direpresentasikan oleh benda anomali (titik massa atau dipol) yang terletak hanya pada suatu lapisan tertentu untuk mempercepat perhitungan sehingga sering disebut pula sebagai *equivalent layer*. Selain itu Mendonca dan Silva (1994) menggunakan istilah data ekuivalen karena perhitungan hanya melibatkan data yang mendominasi anomali sedangkan data yang bersifat *redundant* diabaikan.

Hasil inversi data magnetik menggunakan model 3-D meskipun tidak realistis secara geologis dapat dimanfaatkan sebagai sumber ekuivalen. Dalam hal ini distribusi kemagnetan sumber ekuivalen tidak dibatasi hanya pada satu lapisan melainkan dapat diperluas dalam ruang 3-D yang diperoleh melalui pemodelan inversi. Hal ini didukung oleh ketersediaan sumberdaya komputasi yang memadai untuk inversi 3-D.

Pada pemodelan inversi linier, matriks kernel $\underline{G}$ merupakan fungsi dari geometri titik pengamatan relatif terhadap sumber anomali serta arah vektor kemagnetan induksi. Dengan menggunakan persamaan pemodelan ke depan yang identik dengan persamaan (8.1) dan model intensitas magnetisasi yang diperoleh dari hasil inversi 3-D di atas maka dapat dihitung respons sumber ekuivalen untuk kondisi yang sesuai dengan transformasi yang diinginkan melalui penyesuaian matriks kernel $\underline{G}$.

Untuk transformasi reduksi ke kutub vektor kemagnetan pada matriks kernel $\underline{\mathbf{G}}$ dibuat vertikal, sedangkan untuk transformasi reduksi ke ekuator matriks kernel $\underline{\mathbf{G}}$ tersebut dibuat horisontal. Pada proses transformasi kontinuasi ke atas maka matriks kernel $\underline{\mathbf{G}}$ disesuaikan untuk titik pengamatan pada ketinggian tertentu di atas permukaan bumi. Dengan demikian secara umum transformasi data magnetik menggunakan sumber ekuivalen 3-D dinyatakan oleh:


$$\mathbf{d}^* = \underline{\mathbf{G}}^* \mathbf{m} \quad (8.6)$$

dimana $\mathbf{d}^*$ adalah data magnetik hasil transformasi dan $\underline{\mathbf{G}}^*$ adalah matriks kernel yang sesuai untuk masing-masing tipe transformasi. Ilustrasi mengenai konsep model atau sumber ekuivalen dan aplikasinya untuk transformasi data magnetik dan untuk memperoleh data yang terdistribusi secara 3-D diperlihatkan pada Gambar 8.4.

Perbandingan antara hasil transformasi data magnetik dengan menggunakan teknik sumber ekuivalen 3-D dan pemfilteran ditampilkan pada Gambar 8.5. Skala abu-abu (*greyscale*) hanya menunjukkan besaran anomali secara relatif dari minimum (warna terang) ke maksimum (warna gelap). Secara umum transformasi menggunakan teknik sumber ekuivalen 3-D memberikan hasil yang lebih baik. Pada proses reduksi ke kutub menggunakan FFT (Gambar 8.5a, kanan), hasil yang diperoleh telah dikoreksi terhadap efek inklinasi rendah. Meskipun demikian, hasil teknik pemfilteran masih terlihat didominasi efek inklinasi rendah (Silva, 1986; Kis, 1990). Selain itu teknik pemfilteran menggunakan FFT yang merupakan perangkat utama teknik pemfilteran dalam domain frekuensi cukup sensitif terhadap adanya *noise* (frekuensi tinggi) pada data. Hal tersebut memberikan hasil yang juga kurang memuaskan pada reduksi ke ekuator dan kontinuasi ke atas (Gambar 8.5b dan 8.5c).


Penerapan teknik sumber ekuivalen pada data sintetik dan data lapangan (tidak dibahas di buku ini) menunjukkan validitas transformasi data magnetik menggunakan sumber ekuivalen 3-D. Masalah ketidakstabilan teknik pemfilteran atau FFT pada reduksi ke kutub di daerah lintang magnetik rendah dapat diatasi dengan menggunakan

teknik sumber ekuivalen. Aplikasi lain dari teknik sumber ekuivalen adalah perhitungan data yang terdistribusi secara 3-D yang dapat digunakan untuk meningkatkan resolusi vertikal pada model inversi.



Gambar 8.4

- Konsep model atau sumber ekuivalen yang didasarkan atas sifat ambiguitas solusi inversi data medan potensial.
- Aplikasi teknik sumber ekuivalen, model 3-D hasil inversi tanpa kendala digunakan sebagai sumber ekuivalen untuk memperoleh respons model pada konfigurasi geometri yang berbeda.



Gambar 8.5

Transformasi menggunakan teknik sumber ekuivalen 3-D (kiri) dan FFT (kanan). (a) Reduksi ke kutub, (b) Reduksi ke ekuator (c) Kontinuasi ke atas 50 m. Kontur anomali ditunjukkan secara relatif menggunakan skala abu-abu dari minimum (warna terang) ke maksimum (warna gelap).

8.2 Inversi Data Magnetik dengan Distribusi 3-D

Resolusi Vertikal Data magnetik

Hubungan linier antara data dan model sebagaimana dinyatakan oleh persamaan (8.1) dapat diuraikan dalam notasi penjumlahan dan menghasilkan:

$$d_i = \sum_{k=1}^M G_{ik} m_k \quad (8.7)$$

Persamaan (8.7) secara lebih eksplisit menunjukkan bahwa data adalah penjumlahan berbobot parameter fisis (rapat massa atau intensitas kemagnetan). Pada pemodelan data potensial (gravitasi dan magnetik) matriks kernel sebagai bobot merupakan fungsi yang berbanding terbalik terhadap jarak antara posisi sumber anomali dan titik pengamatan. Oleh karena itu harga fungsi pembobot tersebut mengecil terhadap kedalaman yang merupakan jarak dalam arah vertikal antara sumber anomali dengan titik observasi di permukaan bumi (Blakely, 1995).

Peluruhan faktor pembobot yang terdapat pada matriks kernel menyebabkan data medan potensial secara inheren tidak memiliki resolusi vertikal yang baik. Hal tersebut memperparah sifat ambiguitas atau ketidak-unikan solusi inversi data gravitasi dan magnetik. Untuk mengkompensasi peluruhan faktor pembobot oleh matriks kernel, Li dan Oldenburg (1996; 1998) menggunakan pembobotan model terhadap kedalaman (*depth weighting*) sebagai salah satu cara untuk memperoleh model hasil inversi dengan resolusi kedalaman yang lebih baik. Namun penentuan beberapa parameter pembobot masih bersifat subyektif sehingga perlu dilakukan secara coba-coba atau *trial and error*.

Analisis terhadap spektrum nilai singular matriks kernel yang dilakukan Fedi dan Rapolla (1999) menunjukkan bahwa data magnetik pada beberapa level ketinggian yang berbeda mengandung informasi lebih lengkap mengenai variasi intensitas magnetisasi terhadap kedalaman. Oleh karena itu inversi yang dilakukan terhadap data yang terdistribusi dalam ruang 3-D atau sebagai fungsi koordinat (x, y, z) dapat menghasilkan model dengan resolusi vertikal yang lebih baik.

Data pada level ketinggian yang berbeda seharusnya diukur secara independen, seperti pada teknik pengukuran gradiometer. Namun pengukuran dengan cara tersebut akan meningkatkan biaya survey secara sangat signifikan. Sebagai pendekatan, data pada berbagai ketinggian pada dasarnya dapat diperoleh melalui proses kontinuitas ke atas (*upward continuation*) data permukaan. Dengan demikian diperoleh data yang terdistribusi dalam ruang 3-D yang diharapkan memiliki resolusi vertikal yang lebih baik. Asumsi tersebut berlaku jika proses kontinuitas dilakukan terhadap data dengan cakupan jauh lebih luas dibanding daerah penelitian (Fedi dan Rapolla, 1999). Hal ini merupakan karakteristik kontinuitas medan potensial menggunakan teknik *Fast Fourier Transform* (FFT).

Pada sub-Bab ini proses kontinuitas ke atas dilakukan dengan menggunakan teknik sumber ekuivalen 3-D sebagaimana telah dibahas pada sub-Bab sebelumnya. Transformasi data magnetik menggunakan teknik sumber ekuivalen 3-D juga telah diuji menggunakan data lapangan dengan hasil yang baik (Grandis dan Yudistira, 2001) namun tidak dibahas pada buku ini.

Inversi Data Magnetik Sintetik

Model sintetik bawah-permukaan secara 3-D tersusun oleh kubus satuan berukuran $100 \times 100 \times 50$ meter dan berjumlah $10 \times 10 \times 7$ kubus masing-masing dalam arah x , y dan z . Gambar 8.7a menunjukkan model sintetik dalam bentuk potongan (*slice*) horisontal dengan interval 50 meter dari permukaan sampai kedalaman 300 meter. Benda anomali dengan kemagnetan positif berupa prisma berukuran $400 \times 400 \times 100$ meter dengan magnitudo 1 Ampere/meter terkonsentrasi pada kedalaman 150 sampai 250 meter. Inklinasi dan deklinasi medan magnet bumi atau medan induksi masing-masing adalah -20° dan 0° .

Data sintetik adalah respons model sintetik sebagaimana dideskripsikan di atas yang dihitung di permukaan pada daerah seluas 1000×1000 meter dengan grid 100×100 meter. Pada data sintetik tersebut ditambahkan *noise* yang terdistribusi normal dengan rata-rata nol dan standar deviasi 2.0 nanoTesla (nT).

Pemodelan inversi linier *purely under-constrained* dilakukan dengan menggunakan persamaan (8.3). Model hasil inversi adalah model ekuivalen 3-D yang kemudian digunakan untuk memperoleh data pada beberapa ketinggian yang berbeda melalui proses kontinuitas ke atas. Data tambahan pada level ketinggian tertentu ($z < 0$ ke arah atas) diperoleh sebagai hasil kali sumber ekuivalen 3-D $\mathbf{m}_e$ dengan matriks kernel untuk kontinuitas ke atas $\underline{\mathbf{G}}^u$ sebagai berikut:

$$\mathbf{d}^u = \underline{\mathbf{G}}^u \mathbf{m}_e \quad (8.8)$$

Hasil kontinuitas ke atas pada ketinggian -50, -100, -200 dan -300 meter ditampilkan pada Gambar 8.6 (sumbu z positif ke arah bawah). Sebagai pembandingan pada gambar yang sama ditampilkan pula hasil kontinuitas secara teoritik ($\mathbf{d}^t$) yang dihitung menggunakan persamaan:

$$\mathbf{d}^t = \underline{\mathbf{G}}^u \mathbf{m}_s \quad (8.9)$$

dimana $\mathbf{m}_s$ adalah model sintetik yang telah didefinisikan sebelumnya. Jadi hasil kontinuitas teoritik adalah respons model sintetik yang dihitung menggunakan matriks kernel yang telah memperhitungkan titik pengamatan pada ketinggian kontinuitas atau $\underline{\mathbf{G}}^u$ sebagaimana pada persamaan (8.8). Tampak bahwa terdapat perbedaan diantara keduanya namun perbedaan tersebut tidak terlalu signifikan.

Kontinuitas ke atas dilakukan pada sejumlah level ketinggian yang lebih besar dari pada jumlah kubus dalam arah vertikal. Dengan demikian, gabungan data di permukaan dan hasil kontinuitas ke atas menghasilkan data dengan jumlah yang lebih besar dari pada jumlah parameter model ($N > M$). Permasalahan inversi menjadi bersifat *over-determined* (Menke, 1984) sehingga solusi inversi dinyatakan oleh:

$$\mathbf{m} = [\underline{\mathbf{G}}^T \underline{\mathbf{G}}]^{-1} \underline{\mathbf{G}}^T \mathbf{d} \quad (8.10)$$

Matriks kernel $\underline{\mathbf{G}}$ pada persamaan tersebut harus melibatkan keseluruhan geometri data gabungan atau data yang terdistribusi dalam ruang 3-D, yaitu di permukaan dan pada beberapa ketinggian yang berbeda.

Untuk menghindari ketidakstabilan inversi matriks yang mendekati kondisi singular maka ditambahkan pula faktor redaman sehingga solusi inversi berbentuk mirip dengan solusi inversi *mixed-determined* seperti dibahas pada Bab 4. Penggunaan faktor redaman yang dinormalisasi menghasilkan (Barbosa dan Silva, 1994):

$$\mathbf{m} = \mathbf{D} [\mathbf{D} \mathbf{G}^T \mathbf{G} \mathbf{D} + \lambda \mathbf{I}]^{-1} \mathbf{D} \mathbf{G}^T \mathbf{d} \quad (8.11)$$

Dalam hal ini $0 < \lambda < 1$ dengan matriks $\mathbf{D}$ adalah matriks diagonal ($M \times M$) dengan elemen-elemen:


$$D_{ii} = \left(\sum_{k=1}^N G_{ki}^2 \right)^{-1/2} \quad (8.12)$$

Persamaan (8.11) dan (8.12) adalah versi lain dari persamaan (8.3) dan (8.4) namun berlaku untuk kasus inversi linier *over-determined*. Inversi matriks pada persamaan (8.11) dilakukan dengan menerapkan teknik SVD (Press dkk., 1987).

Hasil inversi data yang terdistribusi secara 2-D (hanya terdapat di permukaan) menghasilkan model anomali yang terkonsentrasi di dekat permukaan (Gambar 8.7b). Hal tersebut tidak menggambarkan model yang sebenarnya atau model sintetik sebagaimana Gambar 8.7a. Meskipun demikian, model 3-D tersebut dapat digunakan sebagai sumber ekuivalen dalam proses kontinuasi ke atas untuk menghitung data pada 9 level ketinggian sehingga diperoleh data yang terdistribusi dalam ruang 3-D yang sebagian ditampilkan pada Gambar 8.6.


Hasil inversi data yang terdistribusi secara 3-D (data pada 10 level ketinggian, termasuk data di permukaan) diperlihatkan pada Gambar 8.7c. Tampak bahwa sumber anomali lebih terkonsentrasi pada interval kedalaman 150-200 meter yaitu kedalaman model sintetik, namun dengan intensitas anomali yang lebih kecil. Hal tersebut merupakan kompensasi adanya intensitas magnetisasi tidak nol selain pada interval kedalaman 150-200 meter. Hal tersebut dapat pula disebabkan adanya *noise* pada data sintetik dan *noise* akibat proses kontinuasi menggunakan sumber

ekivalen 3-D. Meskipun demikian secara umum penggunaan data yang terdistribusi dalam ruang 3D dapat menghasilkan model inversi yang lebih baik. Perlu diingat bahwa data pada ketinggian berbeda diperoleh melalui proses kontinuasi dan bukan diukur secara gradiometri.



Gambar 8.6

(a) Respons model sintetik. (b) Respons model ekuivalen pada beberapa ketinggian yang merupakan data sintetik 3-D hasil kontinuasi ke atas menggunakan teknik sumber ekuivalen.



Gambar 8.7

(a) Model sintetik, (b) Model hasil inversi data di permukaan, (c) Model hasil inversi data dengan distribusi 3-D hasil kontinuitas ke atas menggunakan teknik sumber ekuivalen, (d) Model hasil inversi data teoritik dengan distribusi 3-D. Skala intensitas magnetisasi identik dengan skala pada Gambar 8.2.

Sebagai perbandingan dilakukan pula inversi terhadap data sintetik yang terdistribusi dalam ruang 3-D hasil perhitungan teoritis (*forward modeling*). Model hasil inversi ditampilkan pada Gambar 8.7d. Tampak bahwa model inversi dapat merekonstruksi model sintetik secara lebih baik. Perbedaan hasil inversi disebabkan karena data hasil kontinuitas menggunakan sumber ekuivalen tidak dapat merepresentasikan data 3-D secara utuh. Meskipun demikian inversi menggunakan data 3-D hasil kontinuitas menggunakan sumber ekuivalen telah memberikan hasil yang dapat dianggap memadai.

Alternatif lain dari penggunaan data yang terdistribusi secara 3-D adalah penggunaan faktor pembobot model (*model weight*). Pembobot model dimaksudkan untuk meminimumkan variasi spasial parameter model serta *positivity constrains* (Li dan Oldenburg, 1996; 1998) diharapkan dapat menghasilkan model inversi yang lebih baik.

Inversi Data Magnetik Lapangan


Pemodelan data magnetik lapangan dari daerah Ciemas, Sukabumi selatan hanya dimaksudkan sebagai uji-coba metode pemodelan inversi menggunakan data yang terdistribusi secara 3-D. Interpretasi dan implikasi geologi detail dari hasil pemodelan tersebut tidak dibahas.

Pengukuran magnetik dilaksanakan pada daerah berukuran kurang-lebih 1000×600 meter dengan lintasan ber-arah Utara-Selatan. Jarak antar lintasan adalah 50 meter dan jarak antar titik ukur pada lintasan adalah 25 meter. Data magnetik pada sebagian daerah survey yaitu 600×600 meter menunjukkan anomali utama berharga negatif (lebih kecil dari -100 nT, setelah dikurangi dengan IGRF) yang memanjang secara diagonal dalam arah Barat-Daya – Timur-Laut (Gambar 8.8). Secara kualitatif anomali negatif tersebut diperkirakan berasosiasi dengan adanya zona mineralisasi.

Kontinuitas ke atas menggunakan teknik sumber ekuivalen dilakukan dengan grid 50×50 meter untuk memperoleh data sampai ketinggian 275 m dengan interval 25 m (data 3-D). Jumlah data adalah $N = 12 \times 12 \times 12$.


Pada daerah yang dimodelkan, medium berukuran $600 \times 600 \times 300$ meter didiskretisasi menjadi susunan kubus berukuran $50 \times 50 \times 50$ meter sehingga jumlah parameter model adalah $M = 12 \times 12 \times 6$. Pada kasus data yang terdistribusi secara 3-D yang diperoleh melalui penerapan teknik sumber ekuivalen, jumlah data selalu dapat dibuat lebih banyak dari pada jumlah parameter model ($N > M$) sehingga inversi linier menjadi *over-determined* dan diselesaikan menggunakan persamaan (8.11).

Gambar 8.9 memperlihatkan hasil inversi data yang hanya terletak di permukaan dan hasil inversi data yang telah ditambah dengan data kontinuasi atau data 3-D. Tampak bahwa distribusi vertikal anomali magnetik tinggi lebih merata pada semua kedalaman jika inversi dilakukan pada data 3-D. Anomali magnetik tinggi yang memanjang secara hampir diagonal di tengah daerah survey terdapat di permukaan sampai kedalaman 200 meter. Anomali tersebut diperkirakan berasosiasi dengan adanya zona mineralisasi. Sumber anomali magnetik sangat tinggi di sebelah tenggara daerah survey terdapat pada kedalaman lebih dari 100 meter dan diperkirakan berasosiasi dengan batuan intrusif.



Gambar 8.8

Data magnetik lapangan daerah Ciemas, Sukabumi selatan (kiri) dan salah satu hasil kontinuasi ke atas (50 meter) menggunakan teknik sumber ekuivalen (kanan).



Gambar 8.9

Perbandingan antara (a) model hasil inversi data di permukaan, (b) model hasil inversi data 3-D hasil kontinuasi. Model tersebut menggambarkan distribusi sifat kemagnetan bawah-permukaan 3-D hasil inversi data magnetik daerah Ciemas (Sukabumi selatan).

Berdasarkan hasil yang diperoleh dari pemodelan 3-D data magnetik yang terdistribusi secara 3-D, model yang dihasilkan memiliki resolusi vertikal yang lebih baik. Dengan demikian kedalaman sumber anomali dapat diperkirakan secara lebih akurat. Hal tersebut tidak diperoleh jika inversi hanya dilakukan pada data yang hanya terdapat di permukaan (data 2-D). Pada dasarnya data yang terdistribusi dalam ruang 3-D dapat diperoleh melalui proses kontinuasi ke atas.

One of the advantages of being disorderly, is that one is constantly making exciting discoveries.

– Alan Alexander Milne

10.1 Minimum Peaks Function

Pada sub-Bab ini dibahas contoh aplikasi metode *Simulated Annealing* (SA) sederhana pada pencarian minimum suatu fungsi obyektif. *Peaks Function* adalah suatu fungsi dari dua variabel yang dibentuk dari pergeseran dan penskalaan fungsi distribusi normal (*Gaussian*). Sesuai dengan namanya, fungsi tersebut memiliki beberapa "puncak" (nilai maksimum) dan juga "lembah" (nilai minimum) dan didefinisikan oleh persamaan berikut:


$$\begin{aligned} f(x, y) = & 3(1-x)^2 \exp(-x^2 - (y+1)^2) \\ & - 10(x/5 - x^3 - y^5) \exp(-x^2 - y^2) \\ & - 1/3 \exp(-(x+1)^2 - y^2) \end{aligned} \quad (10.1)$$

Dari persamaan (10.1) jelas bahwa f merupakan fungsi yang sangat tidak linier dari x dan y . Pendekatan linier (lokal) untuk pencarian minimum atau maksimum $f(x, y)$ cukup sulit, meskipun gradien fungsi tersebut dapat diformulasikan dan dihitung secara analitik. *Peaks Function* sering dimanfaatkan sebagai ilustrasi permasalahan pencarian minimum atau maksimum suatu fungsi non-linier (*toy problem*) menggunakan pendekatan global. Hal ini mengingat "bentuk permukaan" fungsi $f(x, y)$ yang cukup kompleks (lihat Gambar 10.1) dengan adanya beberapa harga ekstrim (minimum atau maksimum) lokal selain harga ekstrem global yang dicari.

Pada pemodelan inversi non-linier umumnya dicari nilai minimum suatu fungsi obyektif yang berasosiasi dengan model atau solusi optimum. Oleh karena itu, permasalahan yang akan diselesaikan adalah pencarian minimum suatu fungsi obyektif berikut:


$$g(x, y) = 10 - f(x, y) \quad (10.2)$$

dimana $f(x, y)$ adalah *Peaks Function* yang didefinisikan pada persamaan (10.1). Melalui persamaan (10.2) nilai-nilai maksimum *Peaks Function* menjadi nilai-nilai minimum. Selain itu, nilai-nilai minimum tersebut menjadi lebih kontras antara satu dengan yang lainnya jika dibandingkan dengan nilai minimum fungsi $f(x, y)$ yang asli (persamaan (10.1)). Gambar 10.2 memperlihatkan bentuk permukaan dan kontur fungsi obyektif yang ditampilkan dengan orientasi yang agak berbeda dari *Peaks Function* pada Gambar 10.1. Hal tersebut dimaksudkan untuk lebih memperlihatkan posisi dan bentuk permukaan dengan nilai-nilai minimum lokal maupun global.



Gambar 10.1

Bentuk permukaan dan kontur dari *Peaks Function* (persamaan (10.1)).



Gambar 10.2

Bentuk permukaan dan kontur dari *Peaks Function* yang telah dimodifikasi (persamaan (10.2)).

Iterasi sebenarnya dapat dimulai dengan model awal yang dipilih secara acak dari ruang model yang didefinisikan oleh harga-harga x maupun y pada interval $[-3, 3]$. Meskipun demikian dipilih model awal $(x, y) = (-2, -2)$ dengan harga fungsi obyektif cukup tinggi yaitu $f(-2, -2) = 9.95$ untuk menunjukkan proses menuju solusi. Jika model dipilih secara acak maka model tersebut dapat saja berasosiasi dengan harga fungsi obyektif rendah sehingga dapat terjadi konvergensi secara dini.


Model-model pada iterasi berikutnya ditentukan secara acak. Bilangan acak dengan distribusi *uniform* pada interval $[0, 1]$ dipetakan menjadi bilangan dalam interval $[-3, 3]$ (lihat persamaan (6.8)). Hal ini berlaku untuk x maupun y . Pemetaan bilangan acak dilakukan secara kontinyu pada interval $[-3, 3]$ mengingat interval tersebut tidak terlalu lebar. Selain itu diharapkan dapat diperoleh resolusi yang lebih baik jika dibandingkan dengan pemetaan pada sub-interval diskret.

Iterasi dimulai dengan temperatur awal $T_0 = 5.0$ dan faktor penurunan temperatur $\alpha = 0.999$ sementara jumlah iterasi adalah 5000. Pemilihan parameter tersebut didasarkan pada pertimbangan bahwa perhitungan fungsi obyektif seperti pada persamaan (10.2) dapat dilakukan secara sangat cepat. Dengan demikian faktor penurunan temperatur dapat dipilih sangat lambat untuk menghindari konvergensi secara dini. Jumlah iterasi yang diperlukan cukup banyak agar pada akhir iterasi diperoleh faktor temperatur yang cukup kecil.

Pada Gambar 10.3a ditampilkan hasil iterasi dengan 20 model pertama yang diperoleh. Tampak bahwa hampir semua model pada setiap iterasi diterima sebagai solusi meskipun model-model tersebut berasosiasi dengan peningkatan atau kenaikan fungsi obyektif. Contoh yang jelas dari kondisi tersebut adalah transisi dari model 4 ke model 6 dan juga dari model 11 ke model 12. Hal tersebut disebabkan oleh faktor temperatur yang masih sangat besar sehingga peningkatan fungsi obyektif diimbangi oleh faktor temperatur. Hanya pada iterasi tertentu model ditolak. Pada tahap ini seolah dilakukan eksplorasi ruang model secara acak murni.

Gambar 10.3b memperlihatkan model pada iterasi-iterasi dengan faktor temperatur lebih kecil dari 1.0 atau iterasi-iterasi terakhir, dimana model dengan faktor temperatur makin kecil digambarkan sebagai bulatan dengan warna yang makin terang. Tampak bahwa model semakin terkonsentrasi di sekitar nilai minimum fungsi obyektif. Solusi permasalahan ini ditandai oleh titik $(x, y) = (-0.006, 1.647)$ dengan nilai fungsi obyektif $f = 1.985$ (tanda silang).

Efisiensi metode *Simulated Annealing* sederhana seperti dibahas pada contoh ini tergolong rendah. Pada saat temperatur cukup rendah, banyak model ditolak setelah dievaluasi fungsi obyektifnya. Dengan demikian metode *Simulated Annealing* sederhana ini tidak jauh berbeda dari pencarian acak murni seperti dibahas pada Bab 6. Pada pencarian acak murni solusi diperoleh dari harga minimum fungsi obyektif, misalnya dari harga konturnya, suatu hal yang sulit dilakukan jika ruang model berdimensi banyak. Pada metode *Simulated Annealing* solusi berasosiasi dengan model pada iterasi terakhir.



Gambar 10.3

- (a) Plot sampel model awal sampai model ke-20 pada saat awal iterasi atau T tinggi. Model yang diterima ($\circ$) dan ditolak ($\square$).
- (b) Plot sampel model pada akhir iterasi, titik makin terang menandakan T makin rendah. Model akhir terletak di titik dengan tanda (+).

10.2 Inversi Data Magnetotellurik 1-D

Pada pemodelan inversi non-linier dengan pendekatan linier diperlukan model awal yang cukup dekat dengan solusi atau model yang dicari. Pada pembahasan inversi data geolistrik 1-D pada Bab 9 model awal yang jauh dari solusi (dalam hal ini model homogen dengan ketebalan lapisan sebarang) tidak dapat konvergen ke model optimum. Model awal yang berbeda juga dapat menghasilkan model inversi yang berbeda dan tidak optimum. Dengan demikian diperlukan informasi "a priori" yang cukup akurat agar pemodelan inversi non-linier dengan pendekatan linier dapat menghasilkan solusi yang optimum.

Untuk mengatasi keterbatasan pendekatan linier atau lokal maka digunakan pendekatan global pada pemodelan inversi non-linier. Pada pendekatan global, tidak diperlukan perhitungan turunan atau gradien fungsi obyektif yang hanya melibatkan pendekatan orde pertama (linierisasi). Salah satu metode pendekatan global adalah metode *Simulated Annealing* (SA) yang termasuk dalam kategori *guided random search* sebagaimana telah dibahas pada Bab 6. Oleh karenanya konsep dasar metode *Simulated Annealing* tidak diulang lagi pada sub-Bab ini. Pembahasan lebih difokuskan pada implementasi metode *Simulated Annealing* untuk inversi data magnetotellurik (MT) 1-D, khususnya aspek parameterisasi model.

Pemodelan Kedepan MT 1-D

Pada kasus MT 1-D resistivitas hanya bervariasi terhadap kedalaman sehingga model dapat direpresentasikan oleh lapisan-lapisan horizontal dengan parameter model adalah resistivitas ρ_i ; $i = 1, 2, \dots, n$ dan ketebalan h_i ; $i = 1, 2, \dots, n-1$ tiap lapisan, dimana n adalah jumlah lapisan (lihat Gambar 9.2). Perhitungan *forward modeling* MT untuk memperoleh respons model 1-D didasarkan pada persamaan rekursif yang menghubungkan impedansi (perbandingan komponen horisontal medan listrik dan medan magnet) pada dua lapisan yang berurutan (Grandis, 1999). Impedansi pada lapisan ke- i dinyatakan oleh persamaan berikut:

$$Z_i = Z_{0i} \frac{1 - R_i \exp(-2k_i h_i)}{1 + R_i \exp(-2k_i h_i)} \quad (10.3)$$

$$R_i = \frac{Z_{0i} - Z_{i+1}}{Z_{0i} + Z_{i+1}} ; Z_{0i} = \sqrt{\frac{i 2\pi \mu_0 \rho_i}{T}} ; k_i = \frac{Z_{0i}}{\rho_i}$$

dimana ρ_i dan h_i masing-masing adalah resistivitas dan ketebalan lapisan ke- i , sedangkan T adalah periode dan $\mu_0 = 4\pi \times 10^{-7}$ H/meter. Z_{0i} adalah impedansi intrinsik lapisan ke- i yaitu impedansi dengan menganggap lapisan tersebut sebagai medium homogen setengah-ruang (*half-space*).


Perhitungan impedansi dimulai dari lapisan terakhir dimana impedansi lapisan tersebut adalah impedansi intrinsiknya atau $Z_n = Z_{0n}$. Kemudian persamaan rekursif (10.3) digunakan untuk menghitung impedansi lapisan di atas lapisan terakhir (lapisan $n-1$) demikian seterusnya hingga diperoleh impedansi di lapisan pertama (permukaan bumi). Algoritma perhitungan respons model MT 1-D diperlihatkan pada Gambar 10.4. Respons model MT 1-D umumnya dinyatakan sebagai resistivitas semu (ρ_a) dan fasa (ϕ) sebagai fungsi dari periode yang dihitung dari impedansi di permukaan bumi (Z_1) menggunakan persamaan berikut:

$$\rho_a = \frac{1}{\omega \mu_0} |Z_1|^2 \quad (10.4a)$$

$$\phi = \tan^{-1} \left(\frac{\text{Im } Z_1}{\text{Re } Z_1} \right) \quad (10.4b)$$

Berdasarkan persamaan (10.3) dan (10.4) pemodelan MT 1-D relatif sederhana karena hanya bersifat analitik. Meskipun demikian hubungan antara data dengan parameter model sangat tidak linier sehingga inversi MT 1-D sering dimanfaatkan sebagai contoh kasus penyelesaian inversi non-linier menggunakan pendekatan lokal maupun global. Hubungan antara data dengan parameter model yang sangat tidak linier menyebabkan inversi MT 1-D dengan pendekatan linier sering

kurang memadai. Untuk menghindari permasalahan akibat linierisasi maka dilakukan inversi secara non-linier menggunakan teknik optimasi global dalam pencarian minimum fungsi obyektif.



Gambar 10.4

Algoritma perhitungan pemodelan kedepan MT 1-D.

Parameterisasi Model

Pada model bumi berlapis horisontal dengan parameter model resistivitas dan ketebalan lapisan diperlukan informasi mengenai jumlah lapisan. Untuk menghindari pengaruh pemilihan jumlah lapisan, medium didiskretisasi menjadi sejumlah lapisan yang cukup banyak ($n = 20$ atau lebih) dengan ketebalan homogen dalam skala logaritmik. Dengan

demikian ketebalan lapisan meningkat terhadap kedalaman yang dimaksudkan untuk mengakomodasi berkurangnya resolusi metode MT terhadap kedalaman. Dalam iterasi inversi ketebalan lapisan dibuat tetap sehingga parameter model adalah resistivitas tiap lapisan yang akan menggambarkan variasi resistivitas terhadap kedalaman.

Pada awal iterasi, resistivitas tiap lapisan dibuat homogen sama dengan rata-rata data resistivitas semu atau harga lain (acak). Resistivitas lapisan ke- i didefinisikan dengan harga resistivitas tertentu dengan cara membangkitkan bilangan acak *uniform* dalam interval $[0, 1]$ yang kemudian dipetakan pada interval $[\rho_{\min}^i, \rho_{\max}^i]$ sehingga diperoleh:

$$\rho_{\min}^i \leq \rho^i \leq \rho_{\max}^i \quad (10.5)$$

Resistivitas yang dapat dipilih dalam interval tersebut adalah harga-harga diskret yang terdistribusi secara homogen dalam skala logaritmik. Hal ini mengingat besaran resistivitas dapat bervariasi meliputi jangkauan (*order of magnitude*) yang cukup besar. Selain itu pemilihan harga resistivitas secara kontinyu pada interval $[\rho_{\min}^i, \rho_{\max}^i]$ tidak menghasilkan variasi atau perturbasi yang cukup signifikan.

Jika interval $[\rho_{\min}^i, \rho_{\max}^i]$ terbagi menjadi L_i interval homogen dalam skala logaritmik maka harga-harga resistivitas yang dapat dipilih sebagai resistivitas suatu lapisan dinyatakan oleh persamaan:

$$\rho_k^i = \rho_{k-1}^i \times \exp(\ln(\rho_{\max}^i - \rho_{\min}^i) / L_i) \quad (10.6)$$

dimana $k = 1, \dots, L_i$. Interval $[\rho_{\min}^i, \rho_{\max}^i]$ dan jumlah sub-interval L_i pada prinsipnya dapat dipilih secara berbeda untuk setiap lapisan agar dapat menghasilkan resolusi yang baik. Hal tersebut berlaku terutama jika tersedia informasi "a priori" yang memadai. Meskipun demikian harga-harga tersebut dapat dipilih secara sangat umum, untuk menghindari pengaruh atau *bias* dari adanya informasi "a priori". Sebagai contoh harga $\rho_{\min} = 1$ Ohm.m dan $\rho_{\max} = 1000$ Ohm.m yang terbagi menjadi 10 dan 20 sub-interval diperlihatkan pada Tabel 10.1 umumnya dianggap dapat mewakili rentang harga resistivitas medium konduktif dan medium resistif.

Tabel 10.1

Harga-harga resistivitas diskret homogen dalam skala logaritmik pada interval 1-1000 Ohm.m.

20 sub-interval		40 sub-interval			
No.	ρ^i	No.	ρ^i	No.	ρ^i
1	1.00	21	31.62		
2	1.41	22	37.58		
3	1.99	23	44.67		
4	2.82	24	53.09		
5	3.98	25	63.10		
6	5.62	26	74.99		
7	7.94	27	89.13		
8	11.22	28	105.93		
9	15.85	29	125.89		
10	22.39	30	149.62		
11	31.62	31	177.83		
12	44.67	32	211.35		
13	63.10	33	251.19		
14	89.13	34	298.54		
15	125.89	35	354.81		
16	177.83	36	421.70		
17	251.19	37	501.19		
18	354.81	38	595.66		
19	501.19	39	707.95		
20	707.95	40	841.40		
21	1000.00	41	1000.00		

Fungsi Obyektif

Fungsi *misfit* adalah selisih kuadrat antara impedansi data dengan impedansi hasil perhitungan (respons model) sehingga variabel dari fungsi tersebut bersifat homogen. Mengingat impedansi adalah bilangan kompleks yang terdiri dari bagian riil (Z_R) dan bagian imajiner (Z_I) maka fungsi *misfit* pada metode MT 1-D dinyatakan oleh:

$$S_e = \sum_{i=1}^{ND} \left((Z_{R,i}^{\text{cal}} - Z_{R,i}^{\text{obs}})^2 + (Z_{I,i}^{\text{cal}} - Z_{I,i}^{\text{obs}})^2 \right) \quad (10.7)$$

dimana ND adalah jumlah data atau jumlah periode. Meskipun demikian data MT 1-D sering ditampilkan dalam bentuk resistivitas-semu dan fasa sehingga fungsi *misfit* dapat pula dinyatakan oleh:

$$S_e = \sum_{i=1}^{ND} \left(\left(\log \left(\frac{\rho_{a,i}^{cal}}{\rho_{a,i}^{obs}} \right) \right)^2 + \lambda (\phi_i^{cal} - \phi_i^{obs})^2 \right) \quad (10.8)$$

dimana $\lambda \leq 1.0$ merupakan faktor pembobot untuk fasa, yaitu untuk mengurangi pengaruh fasa dalam perhitungan *misfit* karena kualitas data fasa umumnya kurang baik.

Mengingat ketebalan lapisan yang relatif kecil dan jumlah lapisan yang cukup banyak maka fungsi *misfit* pada persamaan (10.7) atau (10.8) kurang sensitif terhadap perubahan resistivitas lapisan. Hal ini disebabkan oleh masalah ekivalensi atau ambiguitas dimana terdapat banyak model dengan respons yang cocok dengan data. Jika hanya fungsi *misfit* yang digunakan sebagai fungsi obyektif, maka dihasilkan model inversi dengan variasi resistivitas antar lapisannya yang cukup besar. Meskipun *misfit* model inversi cukup kecil, model dengan variasi resistivitas yang besar umumnya tidak berkorelasi dengan kondisi geologi yang sebenarnya sehingga interpretasinya lebih sulit.

Untuk mengatasi masalah akibat adanya ambiguitas tersebut maka digunakan kendala tambahan agar diperoleh model inversi yang lebih "smooth". Dalam hal ini resistivitas dua lapisan berurutan (di atas dan di bawah) yang tidak jauh berbeda memperoleh probabilitas lebih besar untuk terpilih. Faktor *smoothing* untuk lapisan ke- i adalah sebagai berikut:

$$S_m = \left(\log \left(\frac{\rho_i}{\rho_{i-1}} \right) \right)^2 + \left(\log \left(\frac{\rho_i}{\rho_{i+1}} \right) \right)^2 \quad (10.9)$$

Sebagaimana pada persamaan (10.8) untuk fungsi *misfit*, pada persamaan (10.9) digunakan harga logaritmik untuk menyatakan selisih antara dua harga resistivitas yang dapat meliputi jangkauan harga yang sangat besar.

Pada iterasi ke- n fungsi obyektif yang harus diminimumkan adalah gabungan antara fungsi *misfit* dan faktor *smoothing*:

$$E_n = S_e + \beta S_m \quad (10.10)$$

dimana β merupakan pembobot faktor *smoothing* yang dapat dipilih secara coba-coba sampai diperoleh hasil yang memadai. Evaluasi dua model pada dua iterasi yang saling berurutan didasarkan pada fungsi obyektif sebagaimana pada persamaan (10.10). Selisih fungsi obyektif tersebut digunakan pada perhitungan probabilitas penerimaan model P (lihat persamaan (6.9)).

Model dan Data Sintetik

Pengujian metode *Simulated Annealing* dilakukan melalui inversi data sintetik untuk mengetahui efektivitas metode tersebut dalam memperoleh kembali model sintetik. Dua model sintetik yang digunakan mewakili model sederhana yang terdiri dari 3 lapisan yaitu lapisan konduktif diantara medium resistif (model-1) dan lapisan resistif diantara medium konduktif (model-2). Parameter model sintetik tersebut ditampilkan pada Tabel 10.2. Data sintetik adalah resistivitas-semu dan fasa sebagai fungsi dari periode pada interval 0.001 sampai 100 detik. Data sintetik tersebut telah ditambah *noise* dengan distribusi normal dengan rata-rata 0 dan standar deviasi 10% dari data tanpa *noise* atau data teoritik.

Tabel 10.2

Parameter model sintetik

Lapisan	Model-1		Model-2	
	Resistivitas (Ohm.m)	Ketebalan (m)	Resistivitas (Ohm.m)	Ketebalan (m)
1	100	400	100	400
2	1000	1600	10	1600
3	10	—	1000	—

Hasil dan Pembahasan


Jumlah lapisan yang digunakan adalah 20 lapisan pada interval kedalaman antara 100 meter sampai 10000 meter sehingga mencakup kedalaman total model sintetik. Pada semua inversi digunakan $T_0 = 5$, $\alpha = 0.99$ dan jumlah iterasi antara 300 sampai 500 sehingga penurunan temperatur cukup lambat namun waktu eksekusi hingga diperoleh *misfit* minimum masih dapat dianggap memadai. Hasil inversi tanpa faktor *smoothing* adalah model dengan variasi resistivitas yang cukup besar. Pola umum variasi resistivitas model inversi pada dasarnya mengikuti variasi resistivitas model sintetik. Kesesuaian antara respons model inversi dengan data sintetik terlihat cukup baik (Gambar 10.5).

Inversi data sintetik dilakukan pula dengan menggunakan faktor *smoothing* yang berkisar antara 1.0 sampai 2.0 untuk memperoleh model inversi yang lebih realistis secara geologi. Gambar 10.6 memperlihatkan kesesuaian antara model hasil inversi dengan model sintetik, bersama dengan kurva *sounding* data sintetik (resistivitas-semu dan fasa sebagai fungsi dari periode). Tampak bahwa model inversi dapat merepresentasikan model sintetik dengan cukup baik meskipun terdapat perbedaan yang disebabkan oleh diskretisasi lapisan dan masalah ekivalensi. Hal tersebut berlaku secara umum untuk kedua data sintetik (model-1 dan model-2).

Metode *Simulated Annealing* untuk inversi non-linier data MT 1-D dapat mengeksplorasi ruang model secara efektif sehingga menghasilkan solusi yang optimal. Beberapa faktor atau parameter inversi yang harus dipilih dan disesuaikan dengan permasalahan yang ditinjau antara lain adalah:


- parameterisasi model dan skema perturbasi atau pemilihan model
- bentuk fungsi *misfit* dan fungsi obyektif
- penanganan masalah ekivalensi atau ketidak-unikan solusi
- skema penurunan temperatur

Faktor-faktor tersebut dapat mempengaruhi hasil inversi sehingga penentuannya perlu dilakukan secara hati-hati. Alternatif yang telah dipilih untuk inversi data MT 1-D dapat memberikan hasil yang cukup baik, meskipun terdapat keterbatasan dalam hal efisiensi perhitungan.



Gambar 10.5

Perbandingan antara data sintetik (●) dan repons model inversi (—), serta antara model sintetik (---) dan model hasil inversi (┐) untuk model-1 (kiri) dan model-2 (kanan). Inversi tanpa faktor *smoothing* ($\beta = 0$).



Gambar 10.6

Perbandingan antara data sintetik (●) dan repons model inversi (—), serta antara model sintetik (---) dan model hasil inversi (—) untuk model-1 (kiri) dan model-2 (kanan). Inversi dengan faktor *smoothing* ($\beta \neq 0$).

10.3 Adaptive Simulated Annealing (ASA)

Telah dibahas bahwa metode *Simulated Annealing* sederhana memiliki efisiensi yang rendah karena banyak model yang ditolak pada saat temperatur mencapai harga yang cukup rendah. Hal ini berkaitan dengan probabilitas *uniform* dari model yang terdapat pada ruang model. Setiap model pada ruang model memiliki peluang yang sama untuk dipilih sebagai sampel yang akan dievaluasi fungsi obyektifnya. Hasil evaluasi tersebut akan menentukan apakah model dipilih atau ditolak. Sebagai ilustrasi, pada kasus inversi data MT 1-D, interval $[\rho_{\min}, \rho_{\max}]$ ditentukan secara "a priori" untuk mendefinisikan ruang model. Semua harga resistivitas yang terdapat pada interval tersebut memiliki peluang yang sama untuk dipilih sebagai resistivitas suatu lapisan.

Sesuai dengan perkembangan iterasi dimana temperatur makin rendah maka model yang terpilih atau diterima cenderung konvergen menuju model dengan fungsi obyektif yang makin kecil. Dengan demikian konsep *guided random search* lebih tercermin pada model yang terpilih atau diterima, sementara pengambilan sampel dari ruang model dilakukan secara acak murni. Hal ini menyebabkan banyaknya model yang ditolak pada saat iterasi sudah cukup lanjut atau temperatur rendah.

Untuk menghindari masalah efisiensi metode *Simulated Annealing* standar maka digunakan interval harga parameter model yang bervariasi sesuai dengan berjalannya iterasi atau temperatur. Interval harga parameter model dibuat di sekitar harga parameter model pada suatu iterasi dan lebar interval mengecil sesuai dengan penurunan faktor temperatur. Hal ini didasarkan pada fakta bahwa secara umum harga parameter model sudah semakin mendekati harga optimumnya pada saat temperatur sudah cukup rendah. Mekanisme penurunan lebar interval harga parameter model dapat memanfaatkan fungsi distribusi probabilitas yang tidak *uniform* dan berubah sesuai dengan iterasi atau temperatur. Salah satu fungsi distribusi probabilitas yang dapat digunakan diantaranya adalah distribusi normal dengan rata-rata harga parameter model pada suatu iterasi dan standar deviasi yang berkurang sesuai dengan penurunan temperatur.

If better is possible, then good is not enough.

– anonymous

11.1 Maksimum Peaks Function

Pada sub-Bab ini dibahas contoh aplikasi Algoritma Genetika atau lebih dikenal sebagai *Genetic Algorithm* (GA) sederhana yang konsep dasarnya telah dibahas pada Bab 6. Dalam contoh ini digunakan *Peaks Function* sebagaimana telah dibahas pada Bab 10. Oleh karena itu persamaan *Peaks Function* dan gambar permukaan fungsinya ditampilkan kembali di sini sebagai berikut (Gambar 11.1):

$$\begin{aligned}
 f(x, y) = & 3(1-x)^2 \exp(-x^2 - (y+1)^2) \\
 & - 10(x/5 - x^3 - y^5) \exp(-x^2 - y^2) \\
 & - 1/3 \exp(-(x+1)^2 - y^2)
 \end{aligned} \quad (11.1)$$


Namun dalam kasus ini tidak dilakukan modifikasi persamaan *Peaks Function* dan permasalahannya adalah pencarian nilai maksimum.

Untuk menyederhanakan masalah maka digunakan pengkodean atau representasi parameter model x dan y oleh bilangan riil yang masing-masing didefinisikan dalam interval $[-3, 3]$. Sejumlah model dibangkitkan secara acak pada interval tersebut menggunakan persamaan:

$$m_i^{(k)} = m_i^{\min} + R(m_i^{\max} - m_i^{\min}) \quad (11.2)$$

dimana R adalah bilangan acak dengan distribusi *uniform* dalam interval $[0, 1]$, i adalah indeks parameter model sehingga $m_1^{(k)} = x_k$ dan $m_2^{(k)} = y_k$,

$k = 1, 2, \dots, NP$ adalah indeks model (atau dapat disebut pula sebagai individu) anggota populasi dan NP adalah jumlah populasi. Persamaan (11.2) pada dasarnya identik dengan persamaan (6.8) yang digunakan untuk men-sampel model secara acak dari ruang model yang didefinisikan oleh harga interval minimum dan maksimum parameter model.



Gambar 11.1

Bentuk permukaan dan kontur dari *Peaks Function* (persamaan (11.1)).

Sebanyak 20 model dibangkitkan secara acak sebagai populasi awal. Populasi tersebut dievaluasi *fitness*-nya $f_k(x_k, y_k)$ menggunakan persamaan (11.1). Mengingat harga *fitness* akan diakumulasi maka semua *fitness* harus berharga positif. Oleh karena itu dilakukan modifikasi dengan menambahkan suatu konstanta:

$$f_k^*(x_k, y_k) = f_k(x_k, y_k) + 10 \quad (11.3)$$


Pada kasus lain modifikasi persamaan *fitness* kemungkinan diperlukan, misalnya melalui penskalaan, agar perbedaan *fitness* tiap model yang

memang berbeda menjadi cukup signifikan. Pada inversi data geofisika *fitness* merupakan konversi dari *misfit* atau fungsi obyektif lainnya (yang diari minimumnya). Pada prinsipnya *misfit* atau fungsi obyektif kecil berasosiasi dengan harga *fitness* yang besar.

Proses seleksi dilakukan berdasarkan harga *fitness*, artinya model dengan *fitness* tinggi memiliki probabilitas tinggi pula untuk terpilih sebagai induk. Konversi *fitness* menjadi probabilitas pada dasarnya adalah normalisasi, sesuai persamaan berikut:

$$p_k = \frac{f_k^*(x_k, y_k)}{\sum_{j=1}^{NP} f_j^*(x_j, y_j)} \text{ sehingga } \sum_{k=1}^{NP} p_k = 1 \quad (11.4)$$

Pemilihan induk dari kumpulan model (x_k, y_k) masing-masing dengan bobot probabilitas p_k dapat dilakukan menggunakan prinsip roda rolet (*roulette wheel*). Setiap model berasosiasi dengan sektor roda rolet yang luasnya sebanding dengan probabilitasnya. Jika roda rolet diputar maka model dengan *fitness* dan probabilitas p_k besar memiliki kemungkinan lebih besar untuk terpilih sebagai induk. Gambar 11.2 memperlihatkan ilustrasi roda rolet untuk 4 model dengan *fitness* dan probabilitas masing-masing.




Gambar 11.2

Ilustrasi konsep roda rolet untuk kasus 4 model dengan *fitness* dan probabilitas sebagaimana ditampilkan pada tabel di samping kanan.

Secara komputasi, pemilihan model dengan bobot probabilitas p_k dapat dilaksanakan dengan menghitung terlebih dahulu probabilitas kumulatif P_k sebagai berikut:

$$P_k = \sum_{j=1}^k p_j \text{ dengan } k = 1, 2, \dots, NP \quad (11.5)$$

Dengan mengambil bilangan acak R dengan probabilitas *uniform* dalam interval $[0, 1]$ atau sering dinyatakan sebagai $R \sim [0, 1]$ kemudian setiap model diuji secara berurut dari $k = 1, 2, \dots, NP$ jika $R < P_k$ maka yang terpilih adalah model ke- k . Ilustrasi mengenai hal tersebut ditampilkan pada Gambar 11.3. Tampak bahwa probabilitas bilangan random R berada di antara 0.5 dan 1.0 lebih besar sehingga kemungkinan model M_4 terpilih juga lebih besar, relatif terhadap model-model lainnya.



Gambar 11.3

Ilustrasi pemilihan model dengan bobot p_k secara komputasi dengan memanfaatkan P_k dan bilangan acak $R \sim [0, 1]$ untuk kasus 4 model sebagaimana ditampilkan pada Gambar 11.2.

Selanjutnya dilakukan reproduksi atau penyilangan (*cross-over*) dari setiap pasangan yang terpilih. Dalam hal ini probabilitas reproduksi adalah 1.0 atau 100%. Jika probabilitas reproduksi tidak berharga 1.0 maka sebelum reproduksi perlu dilakukan pengundian apakah reproduksi dilakukan atau tidak. Mekanismenya sama dengan yang digambarkan pada Gambar 11.3 di atas, namun hanya terdapat dua pilihan dengan batas harga probabilitas reproduksi, misalnya 0.8 atau harga lainnya.

Mengingat model atau individu direpresentasikan oleh bilangan riil, maka mekanisme rekombinasi yang dapat dilakukan berbeda dengan mekanisme rekombinasi untuk representasi biner seperti dibahas pada Bab 6. Misalkan sebagai induk diidentifikasi pasangan induk-1 : (x_k, y_k) dan induk-2 : (x_{k+1}, y_{k+1}) . Pada contoh ini digunakan *single arithmetic cross-over* dimana parameter model yang disilangkan dipilih secara acak. Untuk suatu bilangan acak $R \sim [0, 1]$ dan penyilangan dilakukan pada parameter y , maka diperoleh anak (*off-spring*) sebagai berikut:

$$\text{anak-1} : (x_k, R y_{k+1} + (1 - R) y_k) \quad (11.6a)$$

$$\text{anak-2} : (x_{k+1}, R y_k + (1 - R) y_{k+1}) \quad (11.6b)$$

Alternatif lain dari rekombinasi model yang direpresentasikan oleh bilangan riil adalah *whole arithmetic cross-over* dimana untuk suatu bilangan acak $R \sim [0, 1]$ diperoleh:

$$\text{anak-1} : R (x_k, y_k) + (1 - R) (x_{k+1}, y_{k+1}) \quad (11.7a)$$


$$\text{anak-2} : R (x_{k+1}, y_{k+1}) + (1 - R) (x_k, y_k) \quad (11.7b)$$

Jika $R = 0.5$ maka dihasilkan dua anak yang identik, masing-masing dengan harga parameter model yang merupakan rata-rata dari harga parameter model induk.

Pada contoh sederhana ini mutasi dilakukan pada satu model dalam setiap generasi yang terdiri dari 20 model. Dengan demikian probabilitas mutasi adalah $1/20$ atau 5%. Mutasi untuk model yang direpresentasikan oleh bilangan riil adalah dengan memilih salah satu parameter model secara acak yang akan dimutasi. Kemudian parameter model tersebut diberi harga baru menggunakan persamaan (11.2). Mutasi dengan cara tersebut disebut sebagai mutasi *uniform* dalam interval $[m_{\min}, m_{\max}]$. Alternatif lainnya adalah mutasi *non-uniform* menggunakan probabilitas *Gaussian* ataupun *Cauchy*. Pada penggunaan distribusi *Gaussian* maka rata-ratanya adalah nol dan standar deviasi ditentukan sesuai keperluan. Demikian pula dengan interval $[m_{\min}, m_{\max}]$. Secara umum mutasi *uniform* sudah cukup memadai untuk permasalahan yang sederhana.


Implementasi Algoritma Genetika untuk mencari harga maksimum *Peaks Function* dilakukan sampai iterasi atau generasi ke-200. Variasi harga *fitness* sebagai fungsi dari iterasi ditampilkan pada Gambar 11.4. Harga *fitness* model terbaik pada setiap generasi selalu lebih tinggi dari pada harga *fitness* rata-rata dari populasi model pada generasi tersebut. Jika hanya dilihat dari model terbaik, maka solusi telah diperoleh atau konvergen pada generasi ke-50. Namun harga *fitness* rata-rata populasi setelah generasi ke-50 masih berfluktuasi di sekitar harga asimtotik tertentu (sekitar 17.0). Oleh karena itu solusi adalah model rata-rata dari populasi pada generasi terakhir. Ketidakpastian solusi (standar deviasi atau variansi) dapat diperkirakan dari statistik populasi tersebut.

Gambar 11.5 dan 11.6 memperlihatkan populasi model pada generasi ke-1 (populasi awal), ke-10, ke-50 dan ke-200. Tampak bahwa pada generasi ke-10, populasi model yang pada generasi pertama terlihat acak telah terkonsentrasi di sekitar nilai maksimum *Peaks Function*. Dari distribusi populasi model pada generasi ke-50 dan ke-200 hampir semua model menunjukkan nilai maksimum, kecuali 1 atau 2 model. Hal tersebut menjelaskan fenomena fluktuasi *fitness* seperti di bahas di atas.




Gambar 11.4

Harga *fitness* model terbaik (kurva atas) dan harga *fitness* rata-rata dari populasi model (kurva bawah) sebagai fungsi dari iterasi atau generasi.



Gambar 11.5

- (a) Plot populasi awal yang terdiri dari 20 model yang dipilih secara acak.
 (b) Plot populasi model pada generasi ke-10.



Gambar 11.6

- (a) Plot populasi model pada generasi ke-50.
 (b) Plot populasi model pada generasi ke-200.

11.2 Inversi Data Magnetotellurik 1-D

Sebagai contoh aplikasi, Algoritma Genetika juga digunakan untuk pemodelan inversi data magnetotellurik (MT) 1-D. Inversi dilakukan pada data sintetis MT 1-D yang sama seperti pada Bab 10. Harga parameter model sintetis untuk model-1 dan model-2 dapat dilihat pada Tabel 10.2 atau Tabel 11.1.

Parameterisasi dan Representasi Model

Pada contoh ini model 1-D direpresentasikan oleh lapisan-lapisan horizontal dengan jumlah lapisan tertentu yang harus ditetapkan terlebih dahulu secara "a priori". Parameter model, yaitu resistivitas dan ketebalan lapisan, dinyatakan dalam bilangan biner masing-masing 10 bit (*binary digit*). Dengan demikian untuk model yang terdiri dari 3 lapisan (atau 5 parameter model) maka setiap model direpresentasikan oleh 50 digit bilangan biner.

Konversi bilangan biner ($\mathbf{x}$) menjadi bilangan riil yang menyatakan harga parameter model m_k dalam interval $[m_{\min}, m_{\max}]$ dilakukan dengan menggunakan persamaan berikut:

$$m_k = m_{\min} + (m_{\max} - m_{\min}) \sum_{i=1}^N x_i 2^{(-i)} \quad (11.8)$$

dimana N adalah jumlah bit dari bilangan biner $\mathbf{x} = (x_1, x_2, \dots, x_N)$. Pada kasus ini, interval harga parameter model untuk resistivitas lapisan adalah $\rho_{\min} = 1 \text{ Ohm.m}$ dan $\rho_{\max} = 1000 \text{ Ohm.m}$, sedangkan untuk ketebalan lapisan adalah $h_{\min} = 50 \text{ meter}$ dan $h_{\max} = 2000 \text{ meter}$. Interval harga-harga tersebut ditentukan secara "a priori" dan telah dianggap cukup lebar sedemikian hingga tidak terlalu mempengaruhi hasil inversi.

Implementasi Algoritma Genetika

Sebanyak 200 model dibangkitkan secara acak sebagai populasi awal. Mengingat representasi model yang digunakan adalah biner maka pembangkitan model secara acak dengan mudah dilakukan menggunakan bilangan acak R dengan distribusi uniform dalam interval $[0, 1]$. Untuk

setiap bit bilangan biner jika $R < 0.5$ maka bit tersebut diisi dengan angka 1. Sebaliknya jika $R \geq 0.5$ maka bit tersebut berharga 0. Demikian seterusnya untuk 10 bit yang diperlukan untuk mendefinisikan satu parameter model dan diulang untuk parameter model lainnya.

Harga *fitness* model ditentukan oleh kesesuaian antara data pengamatan dengan data perhitungan atau sering disebut sebagai *misfit*. Salah satu alternatif perhitungan *misfit* adalah *Root Mean Square* (RMS) *Error* yang dinyatakan oleh persamaan berikut:

$$E = \sqrt{\frac{1}{ND} S_e} \quad (11.9)$$

dimana S_e adalah selisih antara data pengamatan dengan data perhitungan sebagaimana dinyatakan oleh persamaan (10.7) atau (10.8) dan ND adalah jumlah data. Pemilihan model untuk proses reproduksi didasarkan pada *misfit* yang telah dikonversi menjadi *fitness* sesuai dengan persamaan berikut:

$$f_k = \exp(-(E_k - E_{\min})) \quad (11.10)$$

dimana E_k adalah *misfit* model ke- k dan $E_{\min}$ adalah *misfit* minimum dalam satu populasi.

Persamaan (11.4) dan (11.5) digunakan untuk menghitung probabilitas berdasarkan *fitness* model. Pemilihan model dengan bobot probabilitas dilakukan dengan prinsip roda rolet seperti dijelaskan sebelumnya (lihat Gambar 11.2 dan 11.3).

Dengan probabilitas reproduksi $P_r = 0.8$ dilakukan rekombinasi terhadap pasangan induk yang terpilih dengan cara menentukan secara acak titik penyilangan, yaitu salah satu dari 10 bit yang merepresentasikan satu harga parameter model. Dengan 5 parameter model (untuk model 3 lapisan) maka reproduksi yang dilakukan pada contoh ini adalah *multi-point cross-over*. Prosedur penyilangan diperlihatkan pada Gambar 6.6b.

Mutasi dengan probabilitas $P_m = 0.1$ dilakukan dengan mengubah salah satu bit dari keseluruhan bit yang ada (yang merepresentasikan satu

model) dengan nilai kebalikannya. Jika nilai bit tersebut 1 maka diganti dengan 0, demikian pula sebaliknya.


Hasil dan Pembahasan

Pada tahap awal dilakukan inversi dengan jumlah lapisan sama dengan jumlah lapisan model sintetik. Hal ini dimaksudkan untuk menyederhanakan masalah dan juga untuk mengetahui kemampuan resolusi Algoritma Genetika untuk permasalahan yang relatif sederhana. Hasil inversi setelah 500 iterasi atau generasi secara numerik ditampilkan pada Tabel 11.1 dan secara grafis pada Gambar 11.7. Secara umum model inversi sudah mendekati model sintetik, meskipun secara numerik terdapat perbedaan harga parameter model. Kesesuaian antara respons model inversi dengan data sintetik terlihat cukup baik.


Inversi data sintetik dilakukan pula dengan menggunakan jumlah lapisan yang berbeda dengan jumlah lapisan model sintetik. Dalam hal ini jumlah lapisan model inversi dibuat sedikit melebihi jumlah lapisan model sintetik, yaitu 5 lapisan. Hasil inversi ditampilkan Gambar 11.8. Tampak bahwa secara umum model inversi dapat merekonstruksi kembali model sintetik. Tidak terdapat perbedaan yang signifikan dari segi kecocokan data sintetik dengan respons model inversi, antara model inversi dengan 3 lapisan maupun 5 lapisan.

Tabel 11.1
Parameter model sintetik dan model hasil inversi data MT 1-D.

Parameter model	Model-1		Model-2	
	Model sintetik	Model inversi	Model sintetik	Model inversi
ρ_1 (Ohm.m)	100.0	102.9	100.0	103.7
ρ_2 (Ohm.m)	1000.0	686.8	10.0	9.6
ρ_3 (Ohm.m)	10.0	11.2	1000.0	884.1
h_1 (m)	400.0	576.8	400.0	600.3
h_2 (m)	1600.0	1707.2	1600.0	1614.4




Gambar 11.7
Perbandingan antara data sintetik (●) dan repons model inversi (—), serta antara model sintetik (---) dan model hasil inversi (└) untuk model-1 (kiri) dan model-2 (kanan).



Gambar 11.8

Perbandingan antara data sintetik (●) dan repons model inversi (—), serta antara model sintetik (---) dan model hasil inversi (└) untuk model-1 (kiri) dan model-2 (kanan). Jumlah lapisan model inversi adalah 5.

Gambar 11.9 menampilkan *misfit* sebagai fungsi iterasi untuk inversi yang menggunakan model 3 lapisan. Ditinjau dari perolehan model terbaik, konvergensi telah dicapai pada generasi ke-100. Fluktuasi harga *misfit* rata-rata dari populasi model sampai generasi ke-500 menunjukkan proses eksplorasi Algoritma Genetika dalam ruang model di sekitar model optimum. Model inversi yang ditampilkan pada Gambar 11.7 dan 11.8 merupakan model hasil perata-rataan semua model pada generasi terakhir.



Gambar 11.9

Harga *misfit* model terbaik dan harga *misfit* rata-rata dari populasi model sebagai fungsi dari iterasi untuk model-1 (atas) dan model-2 (bawah).

Daftar Pustaka

- Barbosa, V.C.F., Silva, J.B.C., 1994, Generalized compact gravity inversion, *Geophysics*, **59**, 57-68.
- Blakely, R.J., 1995, *Potential Theory in Gravity and Magnetic Applications*, Cambridge University Press.
- Cooper, G.R.J., 2000, Gridding gravity data using an equivalent layer, *Computer and Geosciences*, **26**, 227 - 233.
- Cordell, L., 1992, A scattered equivalent-source method for interpolation and gridding of potential-field data in three dimensions, *Geophysics*, **57**, 629 - 636.
- Emilia, D.A., 1973, Equivalent-sources used as an analytic base of processing total magnetic field profiles, *Geophysics*, **38**, 339 - 348.
- Fedi, M., Rapolla, A., 1999, 3-D inversion of gravity and magnetic data with depth resolution, *Geophysics*, **64**, 452-460.
- Grandis, H., 1999, An alternative algorithm for one-dimensional magnetotelluric response calculation, *Computer and Geosciences*, **25**, 119-125.
- Grandis, H., Yudistira, T., 2001, Transformasi data magnetik menggunakan sumber ekivalen 3-D, *Prosiding PIT HAGI ke-26*, Jakarta.
- Guillen, A., Menichetti, V., 1984, Gravity and magnetic inversion with minimization of a specific functional, *Geophysics*, **49**, 1354-1360.
- Kis, K.I., 1990, Transfer properties of the reduction of magnetic anomalies to the pole and to the equator, *Geophysics*, **55**, 1141-1147.
- Koefoed, O., 1979, *Geosounding Principles*, Elsevier.
- Li, Y., Oldenburg, D.W., 1996, 3-D inversion of magnetic data, *Geophysics*, **61**, 394 - 408.
- Li, Y., Oldenburg, D.W., 1998, 3-D inversion of gravity data, *Geophysics*, **63**, 109 - 119.
- Mendonca, C.A., Silva, J.B.C., 1994, The equivalent data concept applied to the interpolation of potential field data, *Geophysics*, **59**, 722 - 732.

- Mendonca, C.A., Silva, J.B.C., 1995, Interpolation of potential-field data by equivalent layer and minimum curvature: A comparative analysis, *Geophysics*, **60**, 399 - 407.
- Menke, W., 1984, *Geophysical data analysis: Discrete inverse theory*, Academic Press.
- Muiuane, E., Pedersen, L.B., 1999, 1D inversion of DC resistivity data using a quality-based truncated SVD, *Geophysical Prospecting*, **49**, 387-394.
- Press, W.H., Flannery, B.P., Teukolsky, S.A., Vetterling, W.T., 1987, *Numerical recipes: The art of scientific computing*, Cambridge University Press.
- Silva, J.B.C., 1986, Reduction to the pole as an inverse problem and its application to low-latitude anomalies, *Geophysics*, **51**, 369 - 382.
- Silva, J.B.C., Barbosa, V.C.F., 2006, Interactive gravity inversion: *Geophysics*, **71**, J1-J9.
- Uchida, T., 1993, Smooth 2-D inversion for magnetotelluric data based on statistical criterion ABIC, *Journal of Geomagnetism and Geoelectricity*, **45**, 841-858.
- Zohdi, A.A.R., 1989, A new method for the automatic interpretation of Schlumberger and Wenner sounding curves, *Geophysics*, **54**, 245-253.